



TOR VERGATA
UNIVERSITÀ DEGLI STUDI DI ROMA

UNIVERSITÀ DEGLI STUDI DI ROMA TOR VERGATA

MACROAREA DI INGEGNERIA

CORSO DI LAUREA MAGISTRALE IN INGEGNERIA
INFORMATICA

A.A 2024/2025

Tesi di laurea magistrale

Scheduling adattivo carbon-aware in ambienti serverless:
gestione del trade-off energia-accuratezza tramite varianti di
funzione

RELATORI:

Prof.ssa Valeria Cardellini
Dott. Gabriele Russo Russo

CANDIDATO:

Lorenzo Grande
0350212

Indice

Abstract	6
1 Introduzione	9
1.1 Contesto e motivazioni	9
1.1.1 L’impatto ambientale dell’elaborazione e la carbon intensity . .	10
1.1.2 Approximate Computing come leva per il trade-off energia-accuratezza	11
1.1.3 Il problema della granularità nella misurazione energetica	13
1.1.4 Verso uno scheduling carbon-aware	14
1.2 Contributi e obiettivi della tesi	15
1.3 Struttura della tesi	17
2 Stato dell’arte	19
2.1 Il monitoraggio dell’energia software	19
2.1.1 Misuratori hardware del consumo energetico	21
2.1.2 Misuratori software e modelli di stima	25
2.2 Elaborazione serverless sostenibile	28
2.2.1 Scheduling energeticamente consapevole nelle piattaforme FaaS	30

2.2.1.1	Scheduling per consolidamento energetico con vincoli di deadline	32
2.2.1.2	Scheduling energy-aware in ambienti FaaS federati ed eterogenei	34
2.2.2	Approximate Computing come leva applicativa per il trade-off energia-accuratezza	37
2.2.2.1	Generazione automatica di varianti energeticamente efficienti	39
2.2.2.2	Controllo runtime del trade-off energia-accuratezza . .	41
2.2.3	Carbon-aware computing	44
2.2.3.1	Temporal shifting su scala industriale: il Carbon-Intelligent Computing System	46
2.2.3.2	Spatial shifting carbon-aware per funzioni serverless . .	49
2.3	Il paradigma FaaS in ambienti cloud-edge	51
2.3.1	La piattaforma Serverledge	52
2.4	Posizionamento del contributo	53
3	Architettura del Sistema	55
3.1	Integrazione di Kepler per il monitoraggio energetico	55
3.1.1	Funzionamento di Kepler	56
3.1.2	Infrastruttura di supporto	57
3.2	Il modello di funzione logica con varianti	59
3.2.1	Struttura della funzione e profilo energetico	59
3.2.1.1	Determinazione dei profili energetici iniziali	60
3.2.2	Il modello di output e la classificazione dell'accuratezza	63

3.2.3	Registrazione e indicizzazione delle varianti in etcd	65
3.2.3.1	Convenzione di denominazione	66
3.2.3.2	Struttura delle chiavi in etcd	66
3.3	Misurazione e aggiornamento adattivo dei profili energetici	67
3.3.1	Tracciamento dei container e conteggio delle invocazioni	68
3.3.2	Il worker periodico di raccolta	69
3.3.3	Attribuzione dell'energia per invocazione e gestione del lag	70
3.3.4	Aggiornamento del profilo tramite media mobile esponenziale	71
3.3.5	Archiviazione su InfluxDB	72
3.4	Esplorazione LCB per il raffinamento delle stime energetiche	72
3.4.1	Il principio di ottimismo sotto incertezza	73
3.4.2	Proprietà di convergenza	74
4	Lo scheduler carbon-aware	75
4.1	La carbon intensity come segnale decisionale	75
4.1.1	La Carbon Response Function	76
4.2	La frontiera di Pareto nello spazio energia-errore	78
4.3	Scalarizzazione e selezione della variante	80
4.3.1	Normalizzazione e funzione obiettivo	80
4.3.2	Analisi delle soglie di transizione	81
4.4	Formalizzazione della logica decisionale	82
5	Risultati Sperimentali	85
5.1	Setup sperimentale	85
5.1.1	Funzioni utilizzate	86
5.1.2	Strategie di confronto	90

5.2	Protocollo di valutazione	91
5.3	Esperimento 1: calibrazione europea della carbon intensity	93
5.3.1	Obiettivo	93
5.3.2	Configurazione	94
5.3.3	Risultati	96
5.3.4	Interpretazione	101
5.4	Esperimento 2: calibrazione locale della carbon intensity	102
5.4.1	Obiettivo	102
5.4.2	Configurazione	103
5.4.3	Risultati	106
5.4.4	Interpretazione	115
5.5	Esperimento 3: flusso di arrivo variabile	116
5.5.1	Obiettivo e struttura	116
5.5.2	Configurazione del workload	117
5.5.3	Confronto quantitativo tra le policy	119
5.5.4	Stabilità operativa sotto carico crescente	121
5.5.5	Interpretazione	122
5.6	Conclusioni	123
6	Conclusioni e sviluppi futuri	125
6.1	Sintesi dei contributi	125
6.2	Risultati principali	127
6.3	Limiti del lavoro attuale	128
6.4	Sviluppi futuri	131
	Elenco delle figure	134

Elenco dei codici	140
Elenco degli algoritmi	141

Abstract

Questa tesi affronta il problema della sostenibilità ambientale nell'esecuzione di funzioni serverless distribuite lungo il continuum Edge-Cloud [1]. Le piattaforme Function-as-a-Service guidano tipicamente le decisioni di scheduling in base a latenza, disponibilità e uso delle risorse, senza considerare in modo esplicito il costo carbonico dell'energia consumata. In un sistema geograficamente distribuito, tuttavia, la carbon intensity della rete elettrica varia nel tempo e nello spazio in funzione del mix energetico locale: una stessa invocazione può produrre emissioni molto diverse a seconda di dove e quando viene eseguita. Il problema studiato è quindi come ridurre l'impatto carbonico operativo delle funzioni FaaS senza imporre una degradazione indiscriminata della qualità del risultato.

Allo stato dell'arte, il problema della sostenibilità nei sistemi serverless viene affrontato lungo direzioni complementari ma parziali. Gli strumenti di monitoraggio energetico permettono di osservare i consumi, ma non stabiliscono quale versione applicativa debba essere eseguita. Le politiche carbon-aware tendono invece a spostare il carico verso zone a minore intensità carbonica o a differirne l'esecuzione nel tempo [2, 3]. Rimane quindi aperta la possibilità di intervenire localmente, scegliendo quale implementazione di una funzione eseguire sul nodo corrente in base al contesto carbonico e al compromesso tra energia e qualità.

Il risultato principale è un'estensione carbon-aware della piattaforma open-source

Serverledge [4], nella quale ogni funzione logica è associata a un insieme di varianti funzionalmente equivalenti ma differenziate per profilo energia-qualità. Uno scheduler adattivo seleziona a runtime la variante più adatta al contesto carbonico corrente, privilegiando l'accuratezza nelle fasce di bassa intensità e orientandosi verso varianti a minore consumo quando la rete è più carbon-intensive. La selezione di varianti approssimate è consentita solo se la richiesta lo dichiara esplicitamente: in assenza di consenso, la piattaforma preserva il comportamento tradizionale e invoca la variante di riferimento. Il sistema realizza così un compromesso adattivo, evitando sia una politica sempre accurata sia una politica sempre orientata al minimo consumo. La valutazione sperimentale su cinque zone europee e sei funzioni, tre numeriche e tre di classificazione ML, mostra che, rispetto alla politica che seleziona sempre la variante a massima qualità, il sistema ottiene risparmi energetici tra il 62% e il 92% e una riduzione stimata delle emissioni operative di CO₂ fino al 94,82%, con un degrado qualitativo contenuto tra lo 0,01% e lo 0,61% per le funzioni numeriche e tra il 4,34% e il 10,55% per le funzioni ML. Rispetto alla baseline che privilegia sempre il minimo consumo, lo scheduler garantisce invece un vantaggio qualitativo significativo per le funzioni ML, con guadagni tra il 23,40% e il 32,19%. Prove con carico concorrente crescente confermano inoltre che la semantica carbon-aware rimane stabile sotto pressione: in presenza di fenomeni di burst, il maggiore costo computazionale delle varianti ad alta qualità può accelerare la saturazione del server, mentre l'approccio proposto riduce la pressione computazionale media sul nodo quando il contesto carbonico rende preferibili varianti meno costose.

La metodologia combina monitoraggio energetico, normalizzazione del segnale carbonico e scheduling adattivo. Il monitoraggio si basa su Kepler [5] e Prometheus per raccogliere stime di consumo a granularità di container in Kubernetes; i profili del-

le varianti vengono aggiornati incrementalmente tramite media mobile esponenziale, adattandosi al comportamento osservato sul nodo corrente. Il segnale carbonico, ottenuto tramite API ElectricityMaps [6], viene normalizzato rispetto ai percentili storici della zona tramite la *Carbon Response Function* (CRF), una funzione logistica che restituisce un parametro $\lambda \in [0, 1]$ rappresentante la posizione della carbon intensity corrente nel contesto locale, senza ricorrere a soglie globali indipendenti dalle caratteristiche della zona considerata. Lo scheduler usa λ per scalarizzare la frontiera di Pareto energia–qualità costruita sulle varianti non dominate, con un termine di esplorazione ispirato al Lower Confidence Bound per evitare decisioni premature su varianti poco osservate.

Il contributo si colloca all’intersezione di tre linee di ricerca che, prese singolarmente, non risolvono il problema. Gli strumenti di osservabilità energetica come Kepler forniscono misure accurate ma nessuna politica di selezione applicativa; analogamente, l’approximate computing [7] modula il compromesso energia–qualità senza collegarlo alla variabilità temporale e geografica della carbon intensity. Le soluzioni carbon-aware in ambito cloud intervengono invece sul posizionamento geografico del carico o sul suo differimento temporale, trascurando la scelta della variante computazionale da eseguire localmente. Il contributo distintivo di questo lavoro consiste nel combinare profilazione energetica adattiva a livello di container, approximate computing orientato alla qualità e un segnale carbonico calibrato per zona in una piattaforma FaaS edge-oriented, dimostrando che è possibile ridurre le emissioni operative costruendo a ogni invocazione un compromesso dipendente dal contesto ambientale e dalle alternative disponibili, senza ricorrere a politiche statiche.

Capitolo 1

Introduzione

1.1 Contesto e motivazioni

Negli ultimi anni si è assistito a una progressiva trasformazione dell'architettura dei sistemi distribuiti: servizi e applicazioni, tradizionalmente eseguiti in data center centralizzati, vengono sempre più frequentemente spostati verso il bordo della rete. Questa tendenza, nota come *edge computing*, nasce dalla necessità di ridurre la latenza percepita dagli utenti, supportare applicazioni real-time e limitare il traffico verso il cloud [1]. Il paradigma emergente non è più quello di un cloud monolitico, ma di un *continuum Edge-Cloud*, in cui risorse computazionali eterogenee e geograficamente distribuite collaborano per soddisfare i requisiti applicativi. In tale contesto, l'elaborazione può essere collocata dinamicamente lungo la catena edge-cloud in funzione delle condizioni di rete, della disponibilità di risorse e dei vincoli applicativi.

Serverless Computing e FaaS nel continuum Edge-Cloud. Parallelamente all'evoluzione verso l'edge, il paradigma Serverless Computing ha acquisito crescente rilevanza come modello di programmazione cloud-native. Nel modello serverless, lo sviluppatore distribuisce codice senza occuparsi della gestione dell'infrastruttura sottostante, che viene completamente delegata al provider [8]. Il modello di fatturazione

pay-as-you-go e la scalabilità automatica hanno contribuito alla sua ampia adozione nell'industria.

All'interno dell'ecosistema serverless, il modello Function-as-a-Service (FaaS) rappresenta la forma più diffusa di esecuzione event-driven. In una piattaforma FaaS, l'unità fondamentale di esecuzione è una funzione stateless, invocata in risposta a eventi o richieste e tipicamente eseguita all'interno di container o ambienti isolati equivalenti. L'estensione del paradigma FaaS al continuum Edge-Cloud risulta particolarmente promettente: eseguire funzioni direttamente su nodi edge consente di ridurre la latenza di risposta e migliorare la qualità del servizio percepita. Recenti lavori hanno mostrato come architetture FaaS decentralizzate possano abilitare l'esecuzione distribuita di funzioni tra edge e cloud, introducendo meccanismi di offloading verticale e orizzontale [4].

1.1.1 L'impatto ambientale dell'elaborazione e la carbon intensity

La crescente diffusione di infrastrutture computazionali distribuite pone con urgenza il problema del loro impatto ambientale. L'elaborazione informatica è oggi responsabile di una quota significativa delle emissioni globali di CO₂, e la crescita prevista dei carichi di lavoro, in particolare nel continuum edge-cloud, rende la sostenibilità energetica una dimensione imprescindibile nella progettazione delle piattaforme di esecuzione [9].

Tuttavia, ridurre il consumo energetico di una singola esecuzione rappresenta una condizione necessaria ma non sufficiente per contenere l'impatto ambientale complessivo. A parità di energia consumata, la quantità effettiva di CO₂ emessa dipende da *come* quell'energia è stata prodotta, ovvero dalla composizione del mix energetico della rete elettrica a cui il nodo è connesso nel momento dell'esecuzione. Questa dimensione

contestuale è catturata dalla *carbon intensity* (CI), definita come la quantità di CO₂ emessa per ogni kilowattora prodotto dalla rete elettrica locale.

Per dare la misura del fenomeno, secondo l'International Energy Agency la carbon intensity media globale della generazione elettrica si attestava nel 2024 a 445 g CO₂/kWh [10], un valore che riflette la persistente dipendenza da fonti fossili nel mix energetico mondiale. Tale media nasconde tuttavia una forte eterogeneità geografica: nello stesso anno, la CI media dell'Unione Europea era di circa 175 g CO₂/kWh, mentre quella della Cina superava i 565 g CO₂/kWh [10].

La carbon intensity è inoltre una grandezza intrinsecamente variabile nel tempo: muta in funzione della disponibilità di fonti rinnovabili, della domanda e degli scambi tra zone di rete [6]. Ne consegue che, in una piattaforma FaaS distribuita su nodi geograficamente eterogenei, una stessa quantità di energia consumata può tradursi in emissioni molto diverse a seconda della zona e dell'istante in cui l'esecuzione ha luogo.

Questa osservazione suggerisce che le decisioni di scheduling di una piattaforma FaaS possano, e debbano, tenere conto del segnale ambientale fornito dalla CI, modulando il comportamento del sistema in funzione del contesto geografico e temporale. Si apre così la questione di quali leve siano disponibili per ridurre l'impatto ambientale dell'esecuzione senza compromettere il servizio offerto all'utente.

1.1.2 Approximate Computing come leva per il trade-off energia-accuratezza

Una direzione promettente per modulare il consumo energetico in funzione del contesto ambientale è rappresentata dal paradigma dell'*Approximate Computing*, che consente di ridurre il costo computazionale accettando, in modo controllato, una diminuzione dell'accuratezza del risultato prodotto. In letteratura, lavori come JouleGuard [7]

hanno mostrato come sia possibile progettare meccanismi di controllo runtime capaci di regolare dinamicamente il livello di approssimazione dell'esecuzione in funzione di un budget energetico, gestendo esplicitamente il compromesso tra efficienza energetica e qualità del risultato.

Applicata al paradigma FaaS, questa idea si traduce nella possibilità di associare a una stessa funzione logica più *varianti implementative*, caratterizzate da diversi profili energetici e da diversi livelli di accuratezza del risultato. Le varianti a consumo ridotto possono derivare da semplificazioni algoritmiche, da modelli più leggeri o da tecniche di approssimazione numerica, e costituiscono scelte progettuali controllate il cui impatto sull'accuratezza è noto e quantificabile.

La disponibilità di varianti con profili diversi apre la possibilità di trasformare la selezione della variante da eseguire in una decisione dello scheduler, guidata dal contesto ambientale: in condizioni di alta carbon intensity, privilegiare una variante più efficiente — accettando una riduzione controllata dell'accuratezza — produrrebbe un beneficio ambientale concreto; in condizioni di bassa carbon intensity, sarebbe invece possibile privilegiare la variante più accurata senza conseguenze ambientali significative.

Affinché tale selezione sia operativamente realizzabile, sono necessari due prerequisiti. Il primo è la disponibilità di misurazioni energetiche affidabili e aggiornate, a granularità sufficientemente fine da distinguere il consumo associato alle singole invocazioni. Il secondo è un criterio decisionale che integri il segnale ambientale con il trade-off energia-accuratezza, determinando quale variante selezionare in funzione della carbon intensity corrente.

1.1.3 Il problema della granularità nella misurazione energetica

Un prerequisito fondamentale per qualsiasi meccanismo di scheduling carbon-aware è la disponibilità di misure energetiche affidabili e aggiornate a granularità sufficientemente fine. Storicamente, la stima del consumo energetico nei sistemi virtualizzati è stata affrontata a livello di macchina fisica o di macchina virtuale, rendendo difficile attribuire il costo energetico a singoli componenti applicativi.

Nel contesto FaaS, questa difficoltà è amplificata dalla natura fine-grained delle invocazioni e dalla variabilità delle condizioni runtime, quali il carico concorrente, le interferenze tra container e la distinzione tra esecuzioni a freddo (*cold start*) e a caldo (*warm start*). Negli ultimi anni, strumenti di osservabilità energetica per ambienti containerizzati hanno reso disponibile una misurazione a granularità significativamente più fine.

In particolare, Kepler (*Kubernetes-based Efficient Power Level Exporter*) stima il consumo energetico a livello di singolo processo e container in ambienti Kubernetes, esportando metriche accessibili in tempo reale tramite Prometheus [5]. È tuttavia importante osservare che, in generale, gli strumenti di osservabilità energetica si concentrano sulle componenti computazionali principali: Kepler raccoglie energia da CPU e DRAM tramite l'interfaccia RAPL (*Running Average Power Limit*) e da GPU NVIDIA tramite NVML, escludendo i consumi associati a storage e interfacce di rete, che rimangono non osservati. La disponibilità di misurazioni energetiche a livello di container costituisce un abilitatore fondamentale: consente di caratterizzare il profilo energetico delle singole varianti di funzione e di aggiornarlo a runtime, rendendo possibile una selezione informata e adattiva da parte dello scheduler.

1.1.4 Verso uno scheduling carbon-aware

La combinazione tra (i) la crescente attenzione alla sostenibilità ambientale dell'elaborazione distribuita, (ii) la possibilità di associare a una funzione logica più varianti implementative con diversi profili energetici e di accuratezza, (iii) la variabilità geografica e temporale della carbon intensity e (iv) la disponibilità di misurazioni energetiche a granularità container-level rende oggi possibile e necessario progettare meccanismi di scheduling che integrino il segnale ambientale come variabile decisionale nativa.

Un tale scheduler deve essere in grado di modulare dinamicamente il peso attribuito all'efficienza energetica rispetto all'accuratezza del risultato, in funzione della carbon intensity della zona geografica del nodo al momento dell'invocazione. Quando la CI è elevata, come in zone alimentate prevalentemente da fonti fossili, privilegiare una variante più efficiente energeticamente, anche a scapito di una riduzione controllata dell'accuratezza, produce un beneficio ambientale concreto. Quando la CI è bassa — come in zone prevalentemente rinnovabili — l'impatto ambientale di un'esecuzione ad alta intensità computazionale è marginale, e la piattaforma può privilegiare la variante più accurata senza conseguenze significative.

Questa visione pone diverse sfide aperte. In primo luogo, occorre un modello capace di tradurre la carbon intensity corrente in un segnale decisionale normalizzato, che tenga conto delle specificità del regime energetico di ciascuna zona geografica: la stessa variazione assoluta di CI ha significati differenti in zone con distribuzioni storiche diverse. In secondo luogo, è necessario un criterio di selezione tra le varianti disponibili che gestisca formalmente il trade-off energia-accuratezza, evitando soluzioni dominate e individuando il miglior compromesso in funzione del contesto ambientale. Infine, le stime energetiche su cui si fonda la selezione devono essere aggiornate a runtime per

riflettere il comportamento effettivo delle varianti sul nodo corrente, anziché dipendere esclusivamente da profilazioni statiche soggette a deriva.

Un ulteriore vincolo è di natura contrattuale: la riduzione dell'accuratezza introdotta dalle varianti approssimate non dovrebbe essere imposta unilateralmente dalla piattaforma, ma dovrebbe richiedere il consenso esplicito dell'utente che formula la richiesta di invocazione. Solo in presenza di tale consenso lo scheduler può attivare la selezione carbon-aware; in assenza, la piattaforma deve garantire il comportamento originale, preservando la piena compatibilità retroattiva.

1.2 Contributi e obiettivi della tesi

L'obiettivo principale di questo lavoro è la progettazione e realizzazione di un'estensione carbon-aware della piattaforma FaaS Serverledge [4], in grado di adattare dinamicamente le decisioni di selezione delle varianti di funzione in funzione della carbon intensity della zona geografica del nodo, minimizzando l'impatto ambientale dell'esecuzione senza rinunciare interamente all'accuratezza del risultato.

Il sistema è progettato attorno al principio che il trade-off tra consumo energetico e qualità del risultato non debba essere risolto staticamente: è la piattaforma stessa a determinare, a runtime, il bilanciamento ottimale tra le due dimensioni, sulla base del contesto ambientale del nodo.

In particolare, il lavoro si propone di:

- **Introdurre il modello di funzione logica con varianti energetiche.** Ciascuna funzione logica è associata a un insieme di varianti implementative alternative, ognuna descritta da un profilo energetico che ne quantifica il costo stimato per invocazione, il costo di cold start e, ove applicabile, il livello di accuratezza del risultato prodotto.

- **Integrare Kepler per il monitoraggio energetico e l'aggiornamento adattivo dei profili.** Il sistema si avvale di Kepler per acquisire stime del consumo energetico a granularità di container sui nodi dell'infrastruttura, esportate tramite Prometheus. Le misurazioni sono raccolte a runtime durante l'esecuzione delle funzioni e alimentano un meccanismo periodico che aggiorna i profili energetici delle varianti tramite media mobile esponenziale, in modo che le stime riflettano il comportamento effettivo sul nodo corrente anziché dipendere da profilazioni statiche.
- **Gestire l'incertezza sulle stime iniziali tramite un meccanismo di esplorazione.** Per compensare l'inaccuratezza delle stime energetiche nelle fasi iniziali, il sistema integra un meccanismo ispirato al principio Lower Confidence Bound (LCB), che favorisce l'osservazione delle varianti meno misurate e converge progressivamente verso stime affidabili al crescere dei dati disponibili.
- **Progettare e implementare uno scheduler carbon-aware basato su frontiera di Pareto.** A seguito del consenso esplicito dell'utente, lo scheduler recupera la carbon intensity corrente della zona geografica del nodo e seleziona, tra le varianti Pareto-ottimali, quella che offre il miglior compromesso tra consumo energetico e accuratezza in funzione del contesto ambientale corrente. La frontiera di Pareto è costruita a runtime sulla base dei profili energetici aggiornati, garantendo che la selezione rifletta il comportamento effettivo delle varianti sul nodo corrente.
- **Valutare sperimentalmente il sistema su un insieme di funzioni rappresentative.** Quantificare il compromesso tra consumo energetico e accuratezza del risultato su un insieme di funzioni rappresentative, dimostrando la

fattibilità e l'efficacia di un modello di esecuzione adattivo per il paradigma Function-as-a-Service nel continuum Edge-Cloud

Il contributo complessivo della tesi consiste nell'estensione di una piattaforma FaaS open-source con un meccanismo di scheduling carbon-aware che, a fronte del consenso dell'utente, seleziona autonomamente la variante più appropriata in funzione del contesto ambientale del nodo, senza richiedere all'utente alcuna conoscenza del regime energetico locale. Il sistema introduce un trade-off controllato tra consumo energetico e accuratezza del risultato, modulato da un segnale ambientale geolocalizzato e adattivo, e ne valuta quantitativamente l'efficacia su funzioni di natura eterogenea e su zone geografiche con carbon intensity strutturalmente diverse.

1.3 Struttura della tesi

Il capitolo seguente, **Stato dell'arte**, analizzerà le principali soluzioni proposte in letteratura per la sostenibilità energetica nel Serverless Computing, a partire dagli strumenti di monitoraggio del consumo energetico del software fino alle tecniche di scheduling energy-aware, all'Approximate Computing e alle proposte di carbon-aware computing. Verrà inoltre introdotta la piattaforma Serverledge, adottata come base sperimentale per lo sviluppo del sistema, e sarà discusso il posizionamento del contributo rispetto allo stato dell'arte.

Nel capitolo **Architettura del Sistema** verrà descritto il sistema realizzato: il modello di funzione logica con varianti energetiche, l'integrazione di Kepler per il monitoraggio dei consumi a livello di container, il meccanismo di aggiornamento adattivo dei profili energetici tramite media mobile esponenziale e il meccanismo di esplorazione LCB per il raffinamento delle stime nelle fasi iniziali.

Nel capitolo **Scheduler Carbon-Aware** sarà presentata la logica decisionale del sistema: la Carbon Response Function (CRF) calibrata per zona geografica, la costruzione della frontiera di Pareto nello spazio energia-accuratezza e il criterio di selezione della variante in funzione della carbon intensity corrente.

Nel capitolo **Risultati Sperimentali** saranno riportati e discussi i risultati della valutazione sperimentale, quantificando il trade-off tra consumo energetico e accuratezza del risultato al variare della carbon intensity, della zona geografica e delle condizioni iniziali di stima.

Nell'ultimo capitolo, **Conclusioni e Sviluppi Futuri**, verranno discussi i risultati ottenuti in relazione agli obiettivi definiti e identificate le principali direzioni di ricerca futura nell'ambito della sostenibilità nel Serverless Computing.

Capitolo 2

Stato dell'arte

In questo capitolo si analizzeranno le principali soluzioni proposte in letteratura per il monitoraggio del consumo energetico e la gestione dell'efficienza energetica nel Serverless Computing. Verranno esaminate le tecniche di monitoraggio energetico a livello software, le soluzioni di scheduling energy-aware e le tecniche applicative basate sul paradigma dell'Approximate Computing. Verrà inoltre introdotto il concetto di carbon intensity come segnale di contesto per le decisioni di esecuzione, esaminando le proposte di carbon-aware computing presenti in letteratura.

2.1 Il monitoraggio dell'energia software

Il monitoraggio del consumo energetico a livello software rappresenta un tema di ricerca centrale nell'ambito dell'efficienza energetica dei sistemi informatici moderni. La crescente complessità delle architetture hardware e la diffusione di modelli di calcolo dinamici e distribuiti hanno reso sempre più difficile ottenere misure energetiche accurate e direttamente attribuibili alle singole componenti software. Questo problema risulta particolarmente rilevante nel contesto del Serverless Computing, dove le unità di esecuzione sono caratterizzate da invocazioni brevi, stateless e altamente dinamiche.

Le soluzioni tradizionali di monitoraggio dell'energia si basano prevalentemente su

misurazioni a livello hardware, che forniscono una stima del consumo complessivo di una macchina fisica o di specifici componenti, come CPU e memoria. Sebbene tali approcci offrano un'elevata precisione, la loro granularità risulta spesso insufficiente per analizzare il comportamento energetico delle applicazioni software, soprattutto in ambienti multi-tenant e containerizzati [11]. In questi scenari, il consumo energetico osservato è il risultato dell'interazione di più entità software concorrenti, rendendo complessa l'attribuzione dei costi energetici alle singole esecuzioni.

Per superare queste limitazioni, negli ultimi anni sono state proposte numerose soluzioni di monitoraggio dell'energia software, che mirano a stimare il consumo energetico a livelli di granularità più fini, quali processo, container o applicazione. Tali approcci si basano generalmente su modelli di stima che correlano metriche osservabili del sistema con misure energetiche ottenute a livello hardware, come nel caso di PowerAPI e SmartWatts [12].

Nel contesto del Serverless Computing, il problema del monitoraggio energetico è ulteriormente aggravato dalla crescente diffusione di architetture cloud-edge. Per ridurre la latenza e migliorare la qualità del servizio, sempre più spesso la computazione viene spostata verso nodi edge prossimi alla sorgente dei dati, anziché su data center remoti [1].

Come già accennato, tali nodi sono frequentemente caratterizzati da risorse computazionali ed energetiche significativamente più limitate. In questi scenari, la conoscenza del profilo energetico delle esecuzioni non è soltanto un'informazione utile ai fini dell'ottimizzazione, ma diventa un prerequisito per qualsiasi decisione consapevole sull'esecuzione. Le condizioni operative dei nodi edge possono variare nel tempo in funzione del carico di lavoro, delle caratteristiche dell'hardware sottostante e, in alcuni casi, della disponibilità energetica stessa del nodo. Di conseguenza, metriche

energetiche statiche o ottenute tramite profilazione offline risultano spesso inadeguate a rappresentare il comportamento reale delle esecuzioni. Diventa quindi fondamentale disporre di metriche energetiche aggiornate nel tempo, in grado di supportare decisioni di esecuzione che tengano conto sia del consumo energetico sia della qualità del risultato prodotto, ponendo le basi per politiche di scheduling capaci di gestire in modo controllato il compromesso tra queste due dimensioni.

2.1.1 Misuratori hardware del consumo energetico

I misuratori hardware del consumo energetico rappresentano l'approccio più diretto per la misurazione dell'energia assorbita da un sistema di calcolo. Tali soluzioni si basano su sensori fisici, esterni o integrati nell'hardware, e forniscono misure caratterizzate da un'elevata accuratezza, in quanto l'energia viene misurata direttamente a livello fisico. Il monitoraggio può avvenire a livello di intera macchina o di specifici componenti hardware, come CPU e memoria.

Una prima categoria è rappresentata dai misuratori hardware esterni, ovvero dispositivi interposti fisicamente tra la sorgente di alimentazione e il sistema sotto analisi. Questi strumenti consentono di misurare l'energia realmente dissipata dall'intero ecosistema hardware, includendo componenti spesso non osservabili tramite sensori software, come gli alimentatori (PSU), i sistemi di raffreddamento e le perdite resistive dei circuiti. Per tale motivo, essi forniscono una visione completa del consumo energetico del sistema.

Tuttavia, come ampiamente documentato in letteratura [13], l'adozione di misuratori hardware esterni introduce una serie di criticità che ne limitano l'applicabilità in contesti operativi su larga scala. In primo luogo, la misurazione avviene tipicamente a livello di intero sistema (*full-system power*), rendendo complesso isolare il contributo

Tabella 2.1: Confronto tra principali tipologie di misuratori hardware esterni per il monitoraggio del consumo energetico.

Categoria	Esempio di Dispositivo	Costo Stimato	Ambito di utilizzo
Entry-level	TP-Link Kasa, Kill-A-Watt	€30 – €60	Analisi preliminari e misure indicative su singole workstation.
Enterprise	APC Metered Rack PDU, Raritan PX	€800 – €2.500	Monitoraggio energetico di rack o gruppi di server in data center.
Laboratorio / R&D	Yokogawa WT310E, ZES ZIMMER LMG	€2.500 – €6.000+	Misurazioni ad alta precisione per validazione scientifica e ricerca accademica.

energetico di singoli componenti hardware o di specifiche entità software senza ricorrere a strumentazione aggiuntiva e altamente invasiva. In secondo luogo, l'integrazione di tali dispositivi in infrastrutture distribuite o in ambienti di data center comporta costi economici e complessità operative significative, legate sia all'acquisizione dell'hardware sia alla gestione del cablaggio e della raccolta dei dati.

Per fornire un ordine di grandezza dell'investimento richiesto, nella Tabella 2.1 sono riportate alcune delle principali categorie di strumenti utilizzati per il monitoraggio energetico hardware, insieme ai relativi ambiti di applicazione.

I dispositivi di fascia entry-level offrono generalmente frequenze di campionamento limitate, dell'ordine di pochi Hertz, risultando adeguati per analisi preliminari su singole macchine. Al contrario, gli strumenti utilizzati in ambito di ricerca e validazione scientifica consentono misurazioni ad alta frequenza e un'elevata precisione, a fronte di costi significativamente più elevati.

Oltre ai misuratori hardware esterni, i moderni processori integrano sensori energetici direttamente a livello di chip, rendendo possibile l'accesso a stime del consumo

energetico tramite interfacce software. Un esempio significativo è rappresentato dalla tecnologia *Running Average Power Limit* (RAPL), introdotta da Intel, che consente di ottenere informazioni sul consumo energetico di diversi domini di potenza interni al processore [14, 15].

RAPL suddivide il consumo energetico del sistema in un insieme di domini logici, ciascuno dei quali rappresenta una porzione specifica dell'hardware. In particolare, il dominio *Package* (PKG) rappresenta il consumo energetico complessivo del processore, includendo i core, le cache e le interconnessioni interne. Il dominio *Power Plane 0* (PP0) è invece associato principalmente ai core di calcolo della CPU, mentre altri domini, come *DRAM*, forniscono una stima del consumo energetico della memoria principale, quando supportati dall'architettura.

La Figura 2.1 illustra un esempio di suddivisione del consumo energetico secondo il modello RAPL, evidenziando come i diversi domini di potenza corrispondano a specifiche componenti hardware del sistema. Questa rappresentazione consente di comprendere come le misure fornite da RAPL siano intrinsecamente legate all'organizzazione fisica del processore e non alle singole entità software in esecuzione.

Il funzionamento di RAPL si basa su modelli energetici interni al processore, calibrati dal produttore, che stimano l'energia consumata a partire da eventi hardware e contatori interni. Sebbene tali misure non rappresentino una misurazione fisica diretta dell'energia, diversi studi hanno dimostrato come esse offrano un buon compromesso tra accuratezza e semplicità di utilizzo, risultando particolarmente adatte al monitoraggio energetico a runtime[16]. Le informazioni rese disponibili da RAPL possono essere lette tramite interfacce standard del sistema operativo, consentendo la loro integrazione in strumenti di monitoraggio software.

Nonostante questi vantaggi, i sensori hardware integrati presentano limiti strut-




Figura 2.1: Esempio di domini di potenza definiti dal modello RAPL. Il dominio *Package* rappresenta il consumo energetico complessivo della CPU, mentre domini più specifici, come *PP0* e *DRAM*, forniscono stime riferite rispettivamente ai core di calcolo e alla memoria principale.

turali quando applicati a contesti software moderni. La granularità delle misure è tipicamente limitata al livello di macchina o di componente hardware e non consente di attribuire in modo diretto il consumo energetico alle singole applicazioni, ai container o alle singole invocazioni. In ambienti multi-tenant e containerizzati, come quelli tipici del Serverless Computing, il consumo energetico osservato è quindi il risultato dell'esecuzione concorrente di più entità software, rendendo complessa l'analisi del comportamento energetico delle singole funzioni.

Inoltre, le misure fornite da RAPL sono di natura cumulativa e non distinguono in modo esplicito tra le diverse fasi di esecuzione, quali inizializzazione, esecuzione vera e propria e periodi di inattività. Questo aspetto risulta particolarmente critico nel Serverless Computing, dove fenomeni come il cold start e il riutilizzo dei container hanno un impatto significativo sul consumo energetico complessivo. Di conseguenza, pur costituendo una base affidabile per la stima dell'energia a livello di sistema, i

sensori hardware integrati non risultano sufficienti per supportare analisi a grana fine e decisioni di gestione energetica a livello software.

Alla luce di queste considerazioni, sebbene i misuratori hardware costituiscano una base affidabile per la misurazione dell'energia, essi risultano insufficienti per supportare il monitoraggio continuo e a grana fine richiesto da ambienti dinamici e distribuiti. In tali contesti emerge la necessità di soluzioni in grado di offrire una maggiore flessibilità e di integrarsi in modo più stretto con i meccanismi di esecuzione del software.

2.1.2 Misuratori software e modelli di stima

Le limitazioni intrinseche dei misuratori hardware, quali la scarsa granularità temporale, i costi elevati di implementazione su larga scala e l'impossibilità di attribuire direttamente il consumo energetico a singole entità logiche in sistemi multi-tenant, hanno favorito l'emergere dei misuratori software. Questi strumenti non si basano su sensori fisici dedicati per ogni applicazione, ma utilizzano modelli di stima che correlano l'attività del software con il consumo energetico complessivo del sistema. Il principio fondamentale consiste nell'impiegare metriche di utilizzo delle risorse hardware, come cicli di clock della CPU, istruzioni eseguite, accessi alla cache e operazioni di input/output, come base per stimare l'energia assorbita dalle singole entità di esecuzione. Questo approccio consente di ottenere una visibilità energetica più granulare rispetto alle sole misure hardware, risultando particolarmente adatto a contesti moderni quali il cloud computing, le architetture a microservizi e i sistemi containerizzati.

Uno dei framework più rappresentativi in questo ambito è PowerAPI, una libreria modulare progettata per il monitoraggio del consumo energetico a livello di processo attraverso componenti indipendenti e meccanismi di raccolta dati asincroni e scalabili [12]. L'architettura di PowerAPI è progettata per separare nettamente la fase di

raccolta delle metriche da quella di stima energetica, favorendo l'estendibilità e la portabilità del sistema. Il pilastro tecnologico di PowerAPI è rappresentato dall'**HWPC Sensor** (*Hardware Performance Counter Sensor*), un componente specializzato nel campionamento ad alta frequenza dei contatori di prestazione hardware [17]. Il sensore si interfaccia direttamente con il sottosistema `perf_event` del kernel Linux, permettendo di raccogliere metriche dettagliate sull'attività della CPU associate a specifici *Control Groups* (cgroups). Tale sottosistema offre un'interfaccia standard per osservare eventi hardware e software a basso livello, come cicli di clock, istruzioni eseguite e accessi alla cache, rendendo possibile una raccolta delle metriche coerente con la granularità richiesta dal modello di stima. In parallelo, l'HWPC Sensor interroga i *Model Specific Registers* (MSR) tramite l'interfaccia *Running Average Power Limit* (RAPL), ottenendo misure cumulative del consumo energetico dei principali domini della CPU [16].

La Figura 2.2 mostra una rappresentazione concettuale dell'architettura di PowerAPI. Le metriche di utilizzo delle risorse e le informazioni energetiche fornite dai sensori hardware vengono elaborate dal modello di stima **SmartWatts**, adottato da PowerAPI per attribuire il consumo energetico ai singoli processi.

SmartWatts utilizza tecniche di regressione lineare per scomporre il consumo energetico globale in una componente statica e una dinamica, consentendo un'attribuzione più accurata rispetto a modelli puramente statici [18]. Tale approccio richiede una fase di auto-calibrazione *online* e l'accesso diretto all'hardware sottostante.

Tali requisiti rendono PowerAPI particolarmente adatto a scenari *bare-metal*, ma ne limitano l'applicabilità in ambienti virtualizzati e cloud pubblici, dove l'accesso ai registri hardware della CPU e ai performance counter è spesso inibito dagli hypervisor per motivi di sicurezza e isolamento. In questi contesti emerge la necessità di strumenti




Figura 2.2: Architettura concettuale di PowerAPI. I contatori di prestazione hardware e le misure energetiche aggregate (RAPL) vengono combinati dal modello SmartWatts per stimare il consumo energetico dei singoli processi.

di monitoraggio energetico progettati nativamente per ambienti orchestrati.

Un approccio rappresentativo in questa direzione è **Kepler** (*Kubernetes-based Efficient Power Level Exporter*), un progetto *cloud-native* orientato al monitoraggio energetico di container e Pod in cluster Kubernetes [19, 20]. A differenza di PowerAPI, Kepler non richiede accesso diretto ai registri hardware della CPU, ma sfrutta la tecnologia *eBPF* (*Extended Berkeley Packet Filter*) per raccogliere metriche a livello kernel in modo non intrusivo e con overhead computazionale ridotto.

La Figura 2.3 mostra l'architettura complessiva di Kepler. Il sistema utilizza un *eBPF Program Generator* per generare dinamicamente programmi eBPF che vengono agganciati ai *tracepoint* del kernel e ai performance counter della CPU. Questi programmi intercettano eventi di schedulazione e statistiche di esecuzione, consentendo di associare l'attività computazionale ai singoli container in modo fine-grained.

Le informazioni raccolte tramite eBPF vengono arricchite dal *Pod Lister*, che in-

terroga le API di Kubernetes per mappare gli identificativi dei container ai rispettivi Pod e raccoglie statistiche aggiuntive dai *control groups*. Parallelamente, il componente *Energy Stats Reader* acquisisce informazioni energetiche aggregate dal nodo, utilizzando diverse fonti a seconda della disponibilità dell'hardware sottostante, tra cui RAPL, sensori hardware esterni, interfacce GPU (NVML) e modelli basati su benchmark standardizzati.

Quando le misure hardware dirette non risultano accessibili, scenario tipico delle macchine virtuali nei cloud pubblici, Kepler ricorre a modelli di stima basati su *Machine Learning*, denominati *Estimators*. Tali modelli, addestrati offline su differenti architetture hardware e carichi di lavoro, ricevono in input le metriche raccolte a livello kernel e producono una stima della potenza assorbita dai container, che viene successivamente integrata nel tempo per ottenere una stima energetica complessiva.

Le metriche prodotte da Kepler vengono infine esposte tramite un *Prometheus Exporter*, rendendo il consumo energetico direttamente interrogabile attraverso i meccanismi di *scraping* standard e facilmente integrabile con strumenti di visualizzazione. Questa integrazione nativa con l'ecosistema di osservabilità cloud consente di affiancare le metriche energetiche a quelle di performance, abilitando analisi congiunte e politiche di gestione consapevoli dal punto di vista energetico.

2.2 Elaborazione serverless sostenibile

Nel paradigma serverless, e in particolare nelle piattaforme Function-as-a-Service (FaaS), il consumo energetico è strettamente legato alla natura del modello di esecuzione: le funzioni sono entità effimere, stateless e isolate in ambienti containerizzati, invocate su richiesta con cicli di vita che si misurano spesso in millisecondi. Tale granularità, combinata con l'elevata variabilità del carico di lavoro, rende la gestione dell'energia




Figura 2.3: Architettura di Kepler.

una dimensione strutturalmente più complessa rispetto ai contesti HPC o ai data center tradizionali, nei quali le tecniche consolidate operano tipicamente a livello di nodo fisico e su scale temporali più ampie.

Allo stato dell'arte, la sostenibilità energetica in ambienti serverless è affrontata attraverso soluzioni che si collocano a livelli diversi dello stack di esecuzione. Un primo insieme di approcci opera a livello infrastrutturale, integrando il consumo energetico tra i criteri che guidano le decisioni di scheduling e di allocazione delle risorse: in questa prospettiva, l'obiettivo è determinare *dove* eseguire una funzione, su quale nodo o in quale data center, in modo da ridurre il consumo complessivo dell'infrastruttura.

Una direzione complementare consiste nell'agire sulla funzione stessa piuttosto che sull'infrastruttura. Attraverso il paradigma dell'*Approximate Computing*, è possibile associare a una medesima funzione logica più varianti implementative, caratterizzate da profili energetici e livelli di accuratezza differenti. La decisione non riguarda più soltanto dove eseguire la funzione, ma *quale* variante della funzione eseguire, introducendo un trade-off esplicito tra consumo energetico e qualità del risultato.

Più recentemente, un ulteriore filone di ricerca ha introdotto la *carbon intensity* della rete elettrica come segnale di contesto per guidare le decisioni di esecuzione.

In questi approcci, denominati *carbon-aware*, il criterio di ottimizzazione si estende dal solo consumo energetico all'impatto ambientale complessivo, tenendo conto della composizione del mix energetico disponibile al momento dell'invocazione.

Nei paragrafi successivi vengono analizzati i principali contributi proposti in ciascuna di queste direzioni, delineando il contesto nel quale si colloca il contributo della presente tesi.

2.2.1 Scheduling energeticamente consapevole nelle piattaforme FaaS

Nel paradigma Function-as-a-Service (FaaS), lo scheduling costituisce il punto di decisione centrale attraverso il quale la piattaforma determina le modalità di esecuzione di ciascuna invocazione. In una piattaforma FaaS tradizionale, le decisioni di scheduling sono guidate prevalentemente da criteri prestazionali: disponibilità delle risorse, bilanciamento del carico, minimizzazione della latenza e rispetto degli accordi di servizio. In questa prospettiva, il consumo energetico associato all'esecuzione è una conseguenza delle scelte effettuate, non un parametro che le orienta.

L'integrazione della dimensione energetica nel processo decisionale trasforma lo scheduling da meccanismo di allocazione delle risorse a strumento di controllo del profilo energetico dell'infrastruttura. In uno scheduler *energy-aware*, il consumo energetico diventa un criterio esplicito nella valutazione delle alternative di esecuzione: non si tratta soltanto di determinare se un nodo dispone di risorse sufficienti per eseguire una funzione, ma di valutare quale tra le opzioni disponibili produca il risultato desiderato con il minor impatto energetico complessivo.

Nel contesto serverless, questa integrazione è resa più complessa dalla natura stessa del modello di esecuzione. Le funzioni FaaS sono entità effimere, con cicli di vita che

si misurano spesso in millisecondi o pochi secondi, il che implica una frequenza di decisioni di scheduling significativamente superiore rispetto a quella tipica dei sistemi HPC o dei workload tradizionali su macchine virtuali. Ogni decisione ha un orizzonte temporale ridotto, ma la frequenza con cui tali decisioni si ripetono fa sì che anche differenze marginali nel consumo per singola invocazione si traducano, su base oraria o giornaliera, in variazioni apprezzabili del profilo energetico complessivo del nodo. L'inizializzazione di nuovi ambienti di esecuzione (*cold start*) rappresenta un'ulteriore fonte di variabilità: il costo energetico della prima invocazione su un container appena creato può essere sensibilmente superiore a quello delle invocazioni successive sullo stesso ambiente (*warm start*), rendendo la gestione del riutilizzo dei container una dimensione rilevante anche dal punto di vista energetico.

A questa granularità temporale si aggiunge, nelle architetture cloud-edge, una significativa eterogeneità spaziale. I nodi che compongono l'infrastruttura possono differire per architettura hardware, capacità computazionale, profilo di consumo, disponibilità energetica e connettività di rete. In ambienti edge, alcuni nodi possono essere alimentati da fonti rinnovabili intermittenti o da batterie con capacità limitata, introducendo una variabilità temporale nella stessa disponibilità delle risorse di esecuzione. In ambienti federati o multi-sito, la decisione di *placement* deve inoltre considerare il costo — anche energetico — della movimentazione dei dati tra siti, che in alcuni scenari può dominare il bilancio complessivo dell'invocazione. Questa molteplicità di fattori rende la progettazione di scheduler energeticamente consapevoli per piattaforme FaaS un problema intrinsecamente multi-dimensionale.

È importante osservare che, in tutti gli approcci proposti in letteratura per lo scheduling energy-aware nel contesto FaaS, la consapevolezza energetica riguarda esclusivamente *dove* eseguire la funzione, trattando quest'ultima come un'entità con profilo

energetico invariante. Questa delimitazione caratterizza lo scheduling energy-aware come una famiglia di soluzioni che opera esclusivamente a livello infrastrutturale.

Nei paragrafi seguenti vengono analizzati due contributi rappresentativi di questa famiglia, ciascuno dei quali affronta il problema con formulazione e obiettivi distinti. E²FIS [21] adotta una strategia di consolidamento del carico, formulando il problema di allocazione come un'istanza di ottimizzazione vincolata con l'obiettivo di minimizzare il numero di nodi attivi e, di conseguenza, il consumo energetico dell'infrastruttura. GreenFaaS [22] estende invece la prospettiva agli ambienti federati multi-sito, integrando nella funzione di scheduling una stima del costo energetico associato ai trasferimenti dati tra domini eterogenei.

2.2.1.1 Scheduling per consolidamento energetico con vincoli di deadline

Un primo approccio alla riduzione del consumo energetico in piattaforme FaaS consiste nel *workload consolidation*: anziché distribuire uniformemente il carico tra tutti i nodi disponibili, lo scheduler concentra le invocazioni su un sottoinsieme selezionato, consentendo ai nodi rimanenti di essere portati in stato inattivo. L'intuizione alla base di questa strategia è che il consumo di un nodo in stato di *idle* — pur non eseguendo alcuna funzione — rappresenta una quota non trascurabile del budget energetico totale, e la sua eliminazione può produrre risparmi significativi a livello di infrastruttura.

E²FIS (*Energy-Efficient Function Invocation Scheduling*) [21], proposto per piattaforme FaaS nell'edge-cloud continuum, adotta questo paradigma formulando il problema di allocazione come un'istanza di Programmazione Lineare Intera Mista (MILP). Il sistema assume un insieme di nodi eterogenei, ciascuno caratterizzato da capacità computazionale, memoria disponibile, throughput effettivo e profilo di consumo energetico. Le funzioni sono descritte tramite requisiti di memoria, carico computazionale

e *deadline* di completamento; la stima del tempo di esecuzione tiene conto delle differenze architetturali tra nodi, consentendo allo scheduler di verificare la compatibilità di ciascuna assegnazione con i vincoli temporali imposti.




Figura 2.4: Architettura di E²FIS. I nodi edge sono caratterizzati da differenti capacità computazionali e profili di consumo. Il modulo di *Scheduling computation* determina periodicamente l’allocazione delle funzioni e il sottoinsieme di nodi da mantenere attivi.

Come illustrato in Figura 2.4, l’approccio adotta una pianificazione periodica basata su epoche temporali discrete. Prima dell’inizio di ciascuna epoca, la funzione obiettivo minimizza il consumo energetico associato ai nodi attivi nell’intervallo considerato, selezionando il sottoinsieme minimo necessario a soddisfare tutte le richieste entro le rispettive deadline. Ne deriva una logica di consolidamento: quando il carico complessivo lo consente, le invocazioni vengono concentrate sui nodi con il miglior rapporto tra capacità computazionale e consumo energetico, mentre i restanti possono essere portati in stato inattivo.

Per garantire robustezza operativa in presenza di istanze computazionalmente onerose o di vincoli particolarmente stringenti, il sistema prevede un limite temporale per la risoluzione del problema di ottimizzazione: qualora la soluzione ottima non sia ottenibile entro la soglia stabilita, viene adottata la migliore soluzione ammissibile disponibile. In condizioni limite, il framework può inoltre ricorrere a una politica di fallback ispirata a EDF (*Earliest Deadline First*), privilegiando il rispetto delle deadline rispetto all'ottimizzazione energetica. Tale meccanismo evidenzia un compromesso ricorrente nella progettazione di scheduler energy-aware: in presenza di vincoli temporali stringenti, il rispetto delle deadline può richiedere l'adozione di assegnazioni energeticamente subottimali pur di garantire il completamento delle invocazioni entro i termini stabiliti. E²FIS gestisce ciò attraverso una gerarchia esplicita tra gli obiettivi, nella quale le deadline assumono priorità rispetto all'efficienza energetica.

2.2.1.2 Scheduling energy-aware in ambienti FaaS federati ed eterogenei

In ambienti FaaS federati o multi-sito, la decisione di *placement* si arricchisce di una dimensione ulteriore rispetto agli scenari considerati da E²FIS. Quando risorse eterogenee e geograficamente distribuite — tra cui cluster HPC, workstation e infrastrutture cloud — partecipano alla stessa piattaforma di esecuzione, le funzioni possono operare su dataset residenti in domini amministrativi distinti. In tali scenari, il trasferimento dei dati di input verso il nodo selezionato per l'esecuzione introduce un costo energetico aggiuntivo che può risultare, in alcune configurazioni, paragonabile o superiore a quello dell'esecuzione stessa. Ne consegue che l'allocazione ottimale deve considerare congiuntamente il costo di *computation* e di *communication*, evitando scelte che riducono il consumo di esecuzione introducendo al contempo overhead energetici significativi dovuti alla movimentazione dei dati.

GreenFaaS [22] affronta questo problema progettando un framework di orchestrazione per invocazioni FaaS in ambienti distribuiti, nel quale la decisione di scheduling integra una stima esplicita del costo energetico dei trasferimenti. Come mostrato in Figura 2.5, l'architettura si articola in tre componenti principali: un modulo di *Resource Monitoring*, un *Transfers Manager* e uno *Scheduler*.




Figura 2.5: Architettura di alto livello di GreenFaaS: monitoraggio degli endpoint, stima del costo energetico dei trasferimenti e scheduling energy-aware per l'allocazione dei task in ambienti federati eterogenei.

Il modulo di monitoraggio raccoglie a runtime metriche energetiche e prestazionali dei nodi, sfruttando interfacce hardware — tra cui RAPL per CPU e NVML per GPU — per derivare stime di potenza e caratterizzare il comportamento energetico delle risorse disponibili. Tali misure consentono di stimare il costo di esecuzione su piattaforme eterogenee, superando la limitazione di approcci che utilizzano il solo tempo di esecuzione come proxy indiretto del consumo.

Il *Transfers Manager* modella il contributo energetico associato alla movimentazio-

ne dei dati tra siti. Quando l'input risiede in un dominio diverso da quello candidato all'esecuzione, il trasferimento introduce un costo legato alla trasmissione in rete e alle operazioni di I/O agli estremi della comunicazione. GreenFaaS stima tale costo in funzione della dimensione dei dati e delle caratteristiche del collegamento, consentendo di quantificare l'impatto energetico della scelta del sito anche nei casi in cui il nodo remoto risulti computazionalmente più efficiente ma geograficamente distante.

Sulla base di queste informazioni, lo *Scheduler* effettua una selezione multi-criterio che integra il consumo energetico previsto per l'esecuzione sul nodo candidato e il costo energetico dei trasferimenti eventualmente necessari, affiancando a tali grandezze una stima del tempo di completamento. Il peso relativo delle componenti è configurabile, consentendo di modulare il compromesso tra efficienza energetica e prestazioni in funzione degli obiettivi applicativi. Per mantenere la reattività in presenza di carichi dinamici e infrastrutture di grandi dimensioni, il framework adotta strategie euristiche che evitano la necessità di risolvere un problema di ottimizzazione globale a ogni invocazione.

GreenFaaS amplia dunque la nozione di consapevolezza energetica nello scheduling FaaS oltre la sola efficienza del nodo di calcolo, estendendola al costo di comunicazione tra siti. Questo contributo è particolarmente rilevante in architetture con forte dispersione geografica, dove i trasferimenti dati possono incidere in modo significativo sul bilancio energetico complessivo di un'invocazione.

Nel complesso, gli approcci analizzati in questa sottosezione condividono un elemento strutturale comune: la consapevolezza energetica si traduce in una decisione che riguarda esclusivamente il contesto di esecuzione — la scelta del nodo, la topologia dei nodi attivi, il percorso dei dati — mentre il contenuto dell'esecuzione rimane invariante. E²FIS concentra le invocazioni su un sottoinsieme di nodi selezionato per

minimizzare il consumo complessivo dell'infrastruttura; GreenFaaS estende la valutazione incorporando il costo energetico della comunicazione tra siti. In entrambi i casi, la funzione invocata è trattata come un'entità con un profilo computazionale e un consumo energetico per invocazione dati e non modificabili: lo scheduler determina *dove* eseguirla, ma non può influenzare *come* viene eseguita né il consumo che ne deriva.

Questa delimitazione evidenzia come l'intero spazio di ottimizzazione esplorato da questi approcci sia circoscritto al livello infrastrutturale. La possibilità di agire sul consumo energetico modulando la logica applicativa della funzione — ad esempio selezionando, tra più implementazioni della stessa funzione, quella che offre il miglior compromesso tra consumo e qualità del risultato in funzione delle condizioni correnti — rappresenta una direzione complementare, esplorata nella letteratura attraverso il paradigma dell'*Approximate Computing*, analizzato nella sottosezione successiva.

2.2.2 Approximate Computing come leva applicativa per il trade-off energia-accuratezza

La sottosezione precedente ha evidenziato come le strategie di scheduling energeticamente consapevole nelle piattaforme FaaS si concentrino esclusivamente sulla selezione del contesto di esecuzione, trattando la funzione invocata come un'entità atomica, il cui consumo energetico per invocazione è assunto come dato e immutabile. Tale impostazione, tuttavia, delimita lo spazio di ottimizzazione, lasciando inesplorata una prospettiva concettualmente distinta: anziché intervenire su *dove* eseguire la funzione, è possibile agire su *cosa* viene effettivamente eseguito al fine di ottenere un profilo energetico più favorevole.

Il paradigma dell'*Approximate Computing* fornisce il fondamento teorico per questa direzione. L'idea centrale è che molte computazioni ammettono risultati approssimati,

e che accettare una riduzione controllata della precisione può tradursi in un consumo di risorse computazionali — e quindi energetiche — significativamente inferiore. Questo principio è stato ampiamente studiato in contesti HPC e di calcolo scientifico, dove tecniche quali la *loop perforation* (eliminazione selettiva di iterazioni in cicli computazionali), la riduzione della precisione numerica e la semplificazione algoritmica sono state impiegate per ottenere compromessi controllati tra accuratezza e costo computazionale [23].

Applicato al contesto delle piattaforme FaaS, il paradigma dell'approximate computing si traduce nella possibilità di associare a una stessa funzione logica più *varianti implementative*, ciascuna caratterizzata da un diverso profilo energetico e da un diverso livello di accuratezza del risultato. Le varianti possono differire per molteplici aspetti: la complessità dell'algoritmo impiegato (ad esempio, un modello di machine learning con un numero ridotto di parametri rispetto alla versione completa), il numero di iterazioni o campioni utilizzati nel calcolo, il linguaggio di programmazione — e di conseguenza il runtime di esecuzione — o la granularità dei dati elaborati. L'elemento comune è che tutte le varianti risolvono lo stesso problema funzionale: producono un risultato semanticamente equivalente per lo stesso input ma con costi computazionali ed energetici differenti, e con livelli di accuratezza potenzialmente diversi.

L'esistenza di varianti con profili energia-accuratezza differenziati introduce un nuovo spazio decisionale per lo scheduler: la selezione della variante da eseguire diventa una decisione che può essere guidata da informazioni energetiche, da vincoli definiti dall'utente o da segnali di contesto esterni.

È importante osservare che la generazione delle varianti e la loro selezione a runtime sono due problemi distinti, affrontati in letteratura con approcci diversi. La generazione riguarda il modo in cui le varianti vengono create: manualmente, tramite tecniche di

trasformazione del codice, o attraverso la sostituzione di componenti algoritmici. La selezione riguarda invece il criterio con cui, al momento dell'invocazione, il sistema decide quale variante eseguire. Nei paragrafi seguenti vengono analizzati due contributi che affrontano questi problemi da prospettive complementari: *Code Once, Run Green* [24] si concentra sulla generazione automatica di varianti attraverso la traduzione del codice verso linguaggi più efficienti dal punto di vista energetico; JouleGuard [7] affronta il problema della selezione dinamica, introducendo un meccanismo di controllo runtime che regola il livello di approssimazione in funzione di un vincolo energetico esplicito.

2.2.2.1 Generazione automatica di varianti energeticamente efficienti

Un primo aspetto del problema riguarda la possibilità di ottenere varianti con profili energetici differenti senza richiedere una riprogettazione manuale della funzione. In ambienti serverless, la piattaforma dispone tipicamente dell'accesso al codice sorgente delle funzioni e del controllo completo sull'ambiente di esecuzione: questa combinazione apre la possibilità di intervenire sull'implementazione delle funzioni in modo trasparente per lo sviluppatore.

Code Once, Run Green [24] esplora questa possibilità proponendo ReFaaS, un servizio integrato nella piattaforma serverless Fission che traduce automaticamente funzioni da un linguaggio di programmazione a un altro utilizzando modelli linguistici di grandi dimensioni (LLM). L'obiettivo è generare una versione funzionalmente equivalente della funzione originale, ma eseguita su un runtime con un profilo energetico più favorevole. La motivazione alla base dell'approccio risiede nella significativa variabilità del consumo energetico tra linguaggi di programmazione differenti, documentata in letteratura con differenze che possono raggiungere un ordine di grandezza a parità di funzionalità implementata [24].




Figura 2.6: Pipeline di traduzione automatica proposta in *Code Once, Run Green*. La trasformazione avviene in fase di build tramite un processo iterativo di conversione e validazione del codice, con passaggi di recupero in caso di errori di compilazione o di test.

Come illustrato in Figura 2.6, la traduzione avviene in fase di build attraverso una pipeline iterativa strutturata in tre fasi: traduzione del codice tramite LLM, compilazione e verifica della correttezza mediante test black-box sugli stessi input della funzione originale. In caso di errori di compilazione o di discrepanze nei risultati, la pipeline prevede passaggi di recupero che reinviano il codice al modello linguistico con il messaggio di errore, consentendo tentativi iterativi di correzione fino a un numero massimo predefinito. Se la traduzione ha successo e la funzione tradotta supera tutti i test, il nuovo artefatto sostituisce quello originale nel ciclo di esecuzione della piattaforma; in caso contrario, la funzione originale viene mantenuta senza alcuna interruzione del servizio.

I risultati sperimentali riportati dagli autori mostrano che le funzioni tradotte con successo possono ridurre il consumo energetico per invocazione fino al 70%, con un costo di traduzione che si ammortizza tipicamente dopo alcune migliaia di invocazioni.

Tuttavia, l'approccio presenta limitazioni significative: il tasso di traduzione valida si attesta intorno al 43% con i modelli linguistici testati, e alcune categorie di funzioni — in particolare quelle con dipendenze complesse o con logica di gestione degli errori specifica del linguaggio sorgente — risultano difficilmente traducibili in modo automatico.

Dal punto di vista concettuale, il contributo di *Code Once, Run Green* è rilevante perché dimostra empiricamente un principio fondamentale: la stessa funzione logica, implementata con tecnologie diverse, può presentare profili energetici significativamente differenti a parità di correttezza funzionale. Questo principio è alla base del concetto di *variante* utilizzato nei sistemi che, come quello descritto nella presente tesi, associano a una funzione logica un insieme di implementazioni alternative tra cui selezionare a runtime.

È opportuno osservare, tuttavia, che in *Code Once, Run Green* la decisione su quale variante eseguire è determinata staticamente, in fase di build: se la traduzione ha successo, la funzione tradotta sostituisce permanentemente quella originale. Non è previsto alcun meccanismo di selezione dinamica che consenta al sistema di scegliere tra la variante originale e quella tradotta in funzione delle condizioni operative correnti.

2.2.2.2 Controllo runtime del trade-off energia-accuratezza

Se *Code Once, Run Green* affronta il problema della generazione delle varianti, JouleGuard [7] affronta il problema complementare: dato un insieme di configurazioni applicative con diversi profili di accuratezza e consumo, come selezionare dinamicamente quella più appropriata in funzione di un obiettivo energetico. JouleGuard è un sistema di controllo runtime progettato per uno scenario in cui l'utente specifica un budget energetico — una quantità massima di energia che il sistema può consumare per

unità di lavoro — e il sistema deve rispettare tale budget massimizzando al contempo l'accuratezza del risultato prodotto.

L'intuizione fondamentale di JouleGuard consiste nel decomporre il problema di ottimizzazione in due sotto-problemi coordinati. Il primo, denominato *System Energy Optimizer* (SEO), ha il compito di individuare la configurazione di sistema — intesa come combinazione di risorse hardware, quali frequenza del processore, numero di core attivi e impostazioni del sottosistema di memoria — che massimizza l'efficienza energetica, definita come il rapporto tra lavoro svolto ed energia consumata. A tal fine, il SEO impiega medie mobili esponenziali ponderate (EWMA) per stimare l'efficienza delle diverse configurazioni sulla base delle misurazioni raccolte a runtime, bilanciando in modo adattivo l'esplorazione di configurazioni meno osservate con lo sfruttamento della configurazione attualmente più efficiente.




Figura 2.7: Schema concettuale di JouleGuard. Il *System Energy Optimizer* (SEO) identifica la configurazione di sistema più efficiente; l'*Application Accuracy Optimizer* (AAO) regola il livello di approssimazione dell'applicazione per rispettare il budget energetico, massimizzando l'accuratezza.

Il secondo sotto-problema, affidato all'*Application Accuracy Optimizer* (AAO), interviene quando la sola ottimizzazione delle risorse di sistema non è sufficiente a rispettare il budget energetico. In questo caso, è necessario ridurre ulteriormente il consumo agendo sull'applicazione stessa: l'AAO determina di quanto l'applicazione

debba accelerare la propria esecuzione — riducendo il lavoro computazionale svolto, e di conseguenza l'accuratezza del risultato — per colmare la distanza residua tra il consumo ottenuto con la configurazione di sistema ottimale e il budget richiesto dall'utente. Come illustrato in Figura 2.7, i due componenti operano in modo coordinato: il SEO comunica all'AAO le stime di prestazione e potenza della configurazione di sistema selezionata, e l'AAO utilizza queste informazioni per determinare il livello di approssimazione appropriato.

JouleGuard seleziona la configurazione con la massima accuratezza tra quelle che forniscono prestazioni sufficienti a rispettare il budget energetico. Questo meccanismo non richiede una quantificazione precisa dell'accuratezza delle configurazioni, ma soltanto un ordinamento totale: è sufficiente sapere che una configurazione è più accurata di un'altra, senza necessità di assegnare valori numerici assoluti alla qualità del risultato.

I risultati sperimentali riportati dagli autori, condotti su tre piattaforme hardware (mobile, tablet, server) con otto applicazioni approssimate costruite con due framework diversi (PowerDial e Loop Perforation), mostrano che JouleGuard rispetta i budget energetici con un errore relativo contenuto entro pochi punti percentuali e raggiunge un'accuratezza prossima all'ottimo teorico — calcolato come la migliore accuratezza ottenibile da un oracolo con conoscenza perfetta del futuro. Il sistema si adatta inoltre alle variazioni di fase del carico applicativo, aumentando automaticamente l'accuratezza quando le condizioni lo consentono.

Dal punto di vista concettuale, JouleGuard stabilisce diversi principi rilevanti nell'ambito dell'elaborazione serverless sostenibile: dimostra che il trade-off tra consumo energetico e accuratezza del risultato può essere gestito in modo formale e adattivo attraverso un ciclo di controllo runtime, e introduce l'uso di medie mobili esponen-

ziali per la stima delle grandezze operative a partire da misurazioni raccolte durante l'esecuzione.

È opportuno osservare, tuttavia, che JouleGuard opera su un'applicazione singola, con configurazioni di approssimazione predefinite e profilate offline. Il sistema non prevede la gestione di un insieme di varianti di funzione con profili energetici indipendenti, né contempla l'aggiornamento delle stime energetiche delle configurazioni applicative sulla base di misurazioni raccolte durante l'esecuzione: le stime delle risorse di sistema sono apprese a runtime, ma i profili energia-accuratezza delle configurazioni applicative sono determinati staticamente prima del deployment. In ambienti FaaS, dove il consumo per invocazione può variare in funzione del carico concorrente, dello stato del container e delle caratteristiche dei dati di input, questa assunzione di stazionarietà dei profili energetici costituisce un elemento da considerare.

In entrambi i casi esaminati, la decisione è guidata da grandezze interne al sistema: il budget energetico dell'utente in JouleGuard, il profilo di consumo del runtime in *Code Once, Run Green*. Nessuno dei due approcci incorpora segnali di contesto esterni che riflettano le condizioni della rete elettrica al momento dell'invocazione. Un filone di ricerca distinto, analizzato nella sottosezione successiva, esplora questa direzione introducendo la *carbon intensity* come criterio per modulare le decisioni di esecuzione.

2.2.3 Carbon-aware computing

Le sottosezioni precedenti hanno analizzato approcci che perseguono la sostenibilità energetica dell'elaborazione serverless operando su due leve distinte: la scelta del nodo di esecuzione (scheduling energy-aware) e la modulazione della logica applicativa (approximate computing). In entrambi i casi, il criterio di ottimizzazione è il consumo energetico in sé: l'obiettivo è ridurre i Joule consumati per invocazione o rispettare

un budget energetico prefissato, indipendentemente dal momento in cui tale consumo avviene.

Questa impostazione non cattura una dimensione rilevante del problema: come discusso nella Sezione 1.1.1, l'impatto ambientale di un'unità di energia consumata non è costante, ma dipende dalla carbon intensity della rete elettrica nel momento e nel luogo dell'esecuzione. Il paradigma del *carbon-aware computing* si fonda su questa osservazione: anziché trattare ogni kilowattora come equivalente, le decisioni di esecuzione possono essere modulate in funzione della carbon intensity corrente, spostando il criterio di ottimizzazione dal solo consumo energetico all'impatto ambientale complessivo dell'esecuzione.

In letteratura, le strategie carbon-aware sono state declinate attraverso due leve principali. La prima, denominata *temporal shifting*, consiste nel posticipare l'esecuzione di carichi di lavoro tolleranti al ritardo verso momenti in cui la carbon intensity della rete locale è prevista più bassa. La seconda, denominata *spatial shifting*, consiste nel distribuire i carichi di lavoro tra data center situati in regioni geografiche con diversi livelli di carbon intensity, privilegiando l'esecuzione nei siti con il mix energetico più favorevole al momento dell'invocazione. Entrambe le strategie presuppongono la disponibilità di dati sulla carbon intensity in tempo reale o tramite previsioni a breve termine, tipicamente forniti da servizi specializzati quali ElectricityMaps [6] o WattTime.

Nei paragrafi seguenti vengono analizzati due contributi che rappresentano queste direzioni in contesti distinti: il *Carbon-Intelligent Computing System* (CICS) di Google [2], che costituisce il primo sistema carbon-aware in produzione su scala industriale e opera attraverso temporal shifting di workload batch nei data center; e GreenCourier [3], che porta il paradigma carbon-aware specificamente nel contesto delle piatta-

forme FaaS/serverless, adottando una strategia di spatial shifting per la schedulazione delle funzioni tra regioni geografiche distribuite.

2.2.3.1 Temporal shifting su scala industriale: il Carbon-Intelligent Computing System

Il *Carbon-Intelligent Computing System* (CICS) [2], sviluppato e operato da Google, rappresenta il primo sistema carbon-aware implementato in produzione su scala globale. Il sistema opera su oltre 20 data center distribuiti in 4 continenti e gestisce un consumo elettrico superiore a 15,5 terawattora annui, rendendolo il caso di studio di riferimento per l'applicazione del carbon-aware computing a infrastrutture di calcolo reali.

Il problema affrontato dal CICS può essere descritto in termini intuitivi. I data center di Google eseguono due tipologie di carichi di lavoro con caratteristiche temporali molto diverse. La prima comprende i servizi rivolti agli utenti — ricerca, mappe, streaming — e le macchine virtuali dei clienti cloud: questi carichi sono *inflexible*, nel senso che devono essere eseguiti nel momento in cui vengono richiesti, senza possibilità di posticipazione. La seconda tipologia comprende processi batch — compressione dei dati, addestramento di modelli di machine learning, pipeline di elaborazione video — che tollerano ritardi purché il lavoro venga completato entro 24 ore: questi carichi sono *flexible*. Il CICS sfrutta la flessibilità temporale di questa seconda categoria: se la carbon intensity della rete elettrica locale è alta in un determinato momento della giornata, il sistema riduce la quantità di lavoro batch ammesso in quel momento, accumulandolo per eseguirlo nelle ore successive in cui la rete è alimentata da fonti più pulite. Il volume complessivo di lavoro giornaliero non cambia — viene soltanto redistribuito nel tempo per allinearli al profilo della carbon intensity.

Il meccanismo con cui il CICS realizza questa redistribuzione è la *Virtual Capacity Curve* (VCC). Per ciascun cluster di calcolo, il sistema genera giornalmente una curva

che definisce, ora per ora, il limite massimo di risorse computazionali disponibili per i workload flessibili nel giorno successivo. Questa curva non è uniforme: nelle ore in cui la carbon intensity è prevista alta, il limite viene abbassato, impedendo allo scheduler dei job (Borg) di ammettere nuovi job batch; nelle ore con carbon intensity bassa, il limite viene alzato, consentendo l'esecuzione del lavoro accumulato. Il risultato, illustrato in Figura 2.8, è uno spostamento del carico flessibile dalle ore centrali della giornata — tipicamente caratterizzate da carbon intensity più elevata — verso le prime ore del mattino e la sera, quando la rete tende ad essere più pulita.




Fig. 2: Effect of using the VCC mechanism for load shaping in a cluster.

Figura 2.8: Effetto della Virtual Capacity Curve (VCC) sul profilo di carico di un cluster. La barra superiore indica i livelli di carbon intensity nel corso della giornata. La curva VCC (in rosso) riduce la capacità disponibile per i workload flessibili nelle ore ad alta carbon intensity, spostando il carico (aree arancione e blu) verso le ore più pulite della giornata. Il carico inflessibile (in viola) non viene alterato.

È importante osservare che la VCC non interviene sui singoli job: non decide quali job eseguire o in quale ordine, né modifica la logica dei job stessi. La VCC agisce a un livello superiore, impostando un vincolo aggregato sulla quantità totale di risorse disponibili per i workload flessibili in ciascuna ora. Lo scheduler dei job (Borg) continua a operare normalmente entro questo vincolo, senza necessità di modifiche: se la capacità disponibile è ridotta, semplicemente meno job vengono ammessi e quelli in attesa rimangono in coda fino a quando la capacità non viene ripristinata.

I valori orari della VCC sono calcolati giornalmente attraverso un processo di ottimizzazione che utilizza previsioni di domanda per i workload flessibili e inflexible, modelli di traduzione dell'utilizzo CPU in consumo elettrico, e previsioni di carbon intensity oraria fornite da ElectricityMaps [6] per ciascuna zona della rete in cui risiedono i data center.

I risultati operativi riportati dagli autori mostrano che, nei cluster in cui il CICS è attivo, il consumo di potenza si riduce dell'1–2% nelle ore con la carbon intensity più alta rispetto ai cluster non ottimizzati.

Dal punto di vista concettuale, il CICS stabilisce il principio fondamentale del carbon-aware computing: la carbon intensity della rete elettrica può essere utilizzata come segnale operativo per modulare le decisioni di esecuzione, trasformando l'ottimizzazione del consumo energetico in un'ottimizzazione dell'impatto ambientale. È opportuno osservare, tuttavia, che il sistema opera esclusivamente attraverso temporal shifting di workload batch tolleranti al ritardo, su orizzonti temporali di 24 ore e a granularità di cluster. Non considera la possibilità di agire sulla logica applicativa dei workload né di selezionare tra varianti di esecuzione con profili diversi. Inoltre, il contesto operativo — data center hyperscale con job batch — è significativamente diverso da quello delle piattaforme FaaS, dove le funzioni sono invocate su richiesta

con requisiti di latenza stringenti.

2.2.3.2 Spatial shifting carbon-aware per funzioni serverless

Se il CICS affronta il carbon-aware computing attraverso il temporal shifting di workload batch in data center hyperscale, GreenCourier [3] porta il paradigma nel contesto specifico delle piattaforme serverless, adottando una strategia di spatial shifting: anziché posticipare l'esecuzione nel tempo, il sistema distribuisce le invocazioni delle funzioni tra cluster Kubernetes situati in regioni geografiche diverse, privilegiando l'esecuzione nella regione con la carbon intensity marginale più bassa al momento dell'invocazione.

Come illustrato in Figura 2.9, il framework si integra con la piattaforma serverless Knative e si articola in tre componenti principali. Il *Metrics Server* raccoglie e normalizza in tempo reale i punteggi di carbon intensity per ciascuna regione geografica, utilizzando come fonti dati servizi quali WattTime o il Carbon-aware SDK della Green Software Foundation. Lo scheduler custom, implementato come plugin di scoring nel framework di scheduling di Kubernetes, assegna a ciascun nodo candidato un punteggio proporzionale alla carbon efficiency della regione in cui è localizzato. L'infrastruttura multi-cluster, realizzata tramite Liko, consente il *peering* tra cluster indipendenti distribuiti geograficamente e l'offloading trasparente delle funzioni verso regioni remote.

Il meccanismo decisionale opera per ciascuna invocazione: quando una funzione viene sottomessa, lo scheduler interroga il Metrics Server per ottenere i punteggi di carbon intensity correnti delle regioni disponibili, normalizza i valori e seleziona il nodo con il punteggio più favorevole. I punteggi vengono aggiornati con una granularità di cinque minuti, coerente con la frequenza di aggiornamento dei dati forniti dalle sorgenti di carbon intensity, e mantenuti in cache locale per ridurre l'overhead di comunicazione




Figura 2.9: Architettura di GreenCourier. Il management cluster ospita lo scheduler carbon-aware e il Metrics Server, che interroga sorgenti di carbon intensity (WattTime, ElectricityMaps). I provider cluster, distribuiti in diverse regioni europee, sono collegati tramite Liqo come nodi virtuali. Lo scheduler assegna ciascuna invocazione alla regione con la carbon intensity più favorevole.

durante lo scheduling.

I risultati sperimentali, condotti su Google Kubernetes Engine con cluster distribuiti tra Spagna, Francia, Belgio e Paesi Bassi e utilizzando tracce di invocazione reali da Azure Functions, mostrano che GreenCourier riduce le emissioni di carbonio per invocazione in media del 13,25% rispetto alla strategia di scheduling predefinita di Kubernetes e del 17,8% rispetto a una strategia basata sulla prossimità geografica. Questo risultato è ottenuto al costo di un incremento medio del 10,26% nei tempi di risposta delle funzioni, dovuto all'esecuzione in regioni geograficamente più distanti ma con carbon intensity più favorevole.

Dal punto di vista della relazione con il contesto analizzato in questo capitolo,

GreenCourier è il primo lavoro che applica il paradigma carbon-aware specificamente allo scheduling di funzioni serverless. A differenza del CICS, che opera su workload batch con flessibilità temporale, GreenCourier gestisce invocazioni on-demand con requisiti di risposta immediata, dimostrando che il spatial shifting carbon-aware è applicabile anche in contesti con vincoli di latenza.

I due contributi analizzati in questa sottosezione introducono la carbon intensity della rete elettrica come segnale di contesto per le decisioni di esecuzione, estendendo il criterio di ottimizzazione dal solo consumo energetico all'impatto ambientale complessivo. Entrambi gli approcci condividono tuttavia una caratteristica comune con le famiglie di soluzioni esaminate nelle sottosezioni precedenti: la carbon intensity viene utilizzata per decidere *dove* o *quando* eseguire un carico di lavoro, ma la funzione eseguita rimane invariante rispetto alle condizioni della rete elettrica, senza che il segnale ambientale orienti la selezione tra varianti con profili energia-accuratezza differenziati.

2.3 Il paradigma FaaS in ambienti cloud-edge

Negli ambienti cloud-edge l'elaborazione è distribuita su un insieme eterogeneo di nodi di calcolo, caratterizzati da differenti capacità computazionali, disponibilità di memoria, ampiezza di banda e latenza di rete. Nel paradigma Function-as-a-Service, le applicazioni sono scomposte in funzioni stateless invocate su richiesta, la cui esecuzione è demandata alla piattaforma. In un contesto cloud-edge, ciascuna funzione può essere eseguita localmente su un nodo edge, oppure instradata verso altri nodi o verso il cloud, in funzione dello stato delle risorse disponibili al momento dell'invocazione.

Le differenze strutturali tra nodi cloud e nodi edge rendono il consumo energetico un fattore particolarmente rilevante in questi scenari. I nodi edge dispongono tipicamente di risorse limitate e operano in condizioni di maggiore variabilità del carico, spesso in

assenza di infrastrutture di raffreddamento dedicate. Di conseguenza, le decisioni di allocazione e gestione delle funzioni non possono basarsi esclusivamente su metriche prestazionali, ma devono tenere conto dell'impatto energetico delle scelte effettuate, soprattutto in presenza di vincoli operativi stringenti.

Le tecniche discusse nelle sezioni precedenti — scheduling energeticamente consapevole, meccanismi applicativi basati su approximate computing e approcci carbon-aware — sono state sviluppate prevalentemente in contesti cloud o HPC, con assunzioni sull'infrastruttura che non sempre si trasferiscono direttamente all'ambiente cloud-edge. In particolare, la modularità della piattaforma serverless di riferimento è un requisito determinante: affinché meccanismi di controllo energetico possano essere integrati senza alterare il modello di interazione lato utente, l'architettura della piattaforma deve esporre punti di estensione adeguati a livello di scheduling e gestione delle funzioni.

In questa prospettiva, la scelta della piattaforma serverless su cui condurre la sperimentazione non è indifferente. Nella sezione seguente viene presentata Serverledge, la piattaforma adottata come riferimento nel presente lavoro, descrivendone le caratteristiche architettoniche rilevanti ai fini della ricerca.

2.3.1 La piattaforma Serverledge

Serverledge è una piattaforma Function-as-a-Service progettata per ambienti cloud-edge [4], caratterizzata da un'architettura decentralizzata che consente l'esecuzione di funzioni serverless all'interno di container. La piattaforma separa le componenti di controllo da quelle di esecuzione, permettendo una gestione distribuita delle istanze e delle informazioni di stato tra i nodi che compongono l'infrastruttura.

Ogni nodo Serverledge espone un'interfaccia per la creazione, l'eliminazione e l'invocazione delle funzioni, supportando sia la modalità sincrona sia quella asincrona. Le

decisioni di esecuzione sono affidate a uno scheduler, responsabile del *placement* delle richieste sui nodi disponibili. L'esecuzione avviene tramite container Docker, mantenuti attivi per un intervallo di tempo limitato successivamente all'invocazione, con l'obiettivo di ridurre l'impatto dei *cold start* sulle invocazioni successive.

La condivisione delle informazioni tra nodi è realizzata tramite un meccanismo di storage distribuito, che consente di propagare metadati e informazioni di stato all'interno del cluster. Tali informazioni sono accessibili dallo scheduler al momento della decisione di *placement*, permettendo di scegliere tra l'esecuzione locale sul nodo ricevente e l'offloading verso altri nodi edge o verso il cloud, in funzione delle condizioni operative rilevate.

Dal punto di vista architetturale, Serverledge è progettata per essere estensibile: le logiche di scheduling e di gestione delle funzioni sono separate dal modello di interazione lato utente, rendendo possibile l'integrazione di componenti aggiuntivi di monitoraggio e controllo senza modificare l'interfaccia esposta agli utenti. Questa proprietà è particolarmente rilevante nel contesto del presente lavoro, in quanto consente di introdurre meccanismi di gestione energetica direttamente a livello di scheduler, sfruttando i punti di estensione nativi della piattaforma senza alterarne il comportamento di base.

2.4 Posizionamento del contributo

Le tre famiglie di soluzioni analizzate in questo capitolo — scheduling energy-aware, approximate computing e carbon-aware computing — operano su dimensioni distinte del problema: la scelta del contesto di esecuzione, la modulazione della logica applicativa e la sensibilità al segnale ambientale. Tuttavia, nessuno degli approcci esaminati le integra in un unico meccanismo decisionale.

In particolare, nessuno degli approcci esaminati affronta il problema di selezionare, al momento dell'invocazione, la variante di una funzione che offra il miglior compromesso tra consumo energetico e accuratezza del risultato in funzione dell'impatto ambientale corrente dell'esecuzione. Manca un meccanismo che utilizzi la carbon intensity non come criterio di *placement* geografico o temporale, ma come segnale per modulare il punto operativo sul trade-off energia-accuratezza della funzione stessa — spostando la selezione verso varianti a minor consumo quando la rete è alimentata da fonti ad alta intensità di carbonio, e verso varianti a maggiore accuratezza quando le condizioni della rete lo consentono.

A ciò si aggiunge una seconda lacuna, trasversale agli approcci esaminati: in ambienti FaaS, il consumo energetico di una funzione non è una grandezza stabile nel tempo, ma varia in funzione del carico concorrente sul nodo, dello stato del container e delle caratteristiche dei dati di input. Fondare le decisioni di selezione su profili energetici determinati offline significa operare su stime potenzialmente disallineate rispetto alle condizioni operative correnti, con conseguenze dirette sull'efficacia del meccanismo decisionale.

Il presente lavoro si propone di colmare questo spazio, integrando le tre dimensioni identificate in un unico sistema di scheduling che operi a livello di singola invocazione, selezionando tra varianti della stessa funzione sulla base di stime energetiche aggiornate continuamente e di un segnale di carbon intensity contestualizzato rispetto alla zona geografica di esecuzione.

Capitolo 3

Architettura del Sistema

In questo capitolo verranno descritte le scelte architetturali adottate per estendere la piattaforma Serverledge con le componenti necessarie a una schedulazione carbon-aware. Verranno presentati il modello di funzione logica con varianti, l'integrazione di Kepler per il monitoraggio dei consumi a livello di container, il meccanismo di aggiornamento adattivo dei profili energetici tramite media mobile esponenziale e il meccanismo di esplorazione LCB per il raffinamento delle stime nelle fasi iniziali. Lo scheduler che utilizza queste componenti per la selezione carbon-aware delle varianti è oggetto del Capitolo 4.

3.1 Integrazione di Kepler per il monitoraggio energetico

Il monitoraggio dei consumi energetici a livello di container costituisce il fondamento del sistema realizzato. A tal fine è stato adottato Kepler (Kubernetes-based Efficient Power Level Exporter), uno strumento open source sviluppato nell'ambito della CNCF (Cloud Native Computing Foundation) che stima il consumo energetico di processi, container e pod Kubernetes attraverso l'accesso diretto alle interfacce hardware del sistema operativo host [25].

La scelta di Kepler è motivata principalmente dalla sua granularità di misurazione, che opera a livello di singolo container Docker: questa corrisponde esattamente all'unità di esecuzione delle funzioni serverless in Serverledge. Kepler espone inoltre le proprie metriche nel formato standard Prometheus, consentendo un'integrazione diretta con l'ecosistema di monitoraggio senza richiedere componenti aggiuntivi per la raccolta dei dati.

3.1.1 Funzionamento di Kepler

Kepler opera combinando due meccanismi complementari per associare i consumi energetici ai singoli container. Il primo è un programma eBPF (Extended Berkeley Packet Filter) integrato nel kernel, che traccia l'attività dei processi e li associa ai container tramite il file `/proc/PID/cgroup`, consentendo di correlare il Process ID di ciascun processo all'identificatore del container che lo ospita. Il secondo è l'interfaccia RAPL (Running Average Power Limit), disponibile sui processori Intel e AMD moderni, che permette di leggere i contatori energetici cumulativi direttamente dai registri hardware della CPU.

Una volta raccolti i dati di utilizzo dei processi e di consumo energetico del sistema, Kepler applica il *Ratio Power Model* per attribuire a ciascun container la propria quota di consumo: la potenza dinamica viene distribuita tra i container in proporzione alla loro attività rispetto al carico complessivo del sistema. Il risultato viene aggregato a livello di container e reso disponibile tramite Prometheus nella metrica `kepler_container_cpu_joules_total`, un contatore cumulativo espresso in Joule che cresce monotonicamente nel tempo per ogni container attivo.

Come illustrato in Figura 3.1, il comportamento di Kepler varia in base all'ambiente di esecuzione. In ambienti bare-metal, Kepler accede direttamente ai contatori




Figura 3.1: Architettura di Kepler per la raccolta dei consumi energetici in ambienti bare-metal e virtuali. In ambienti bare-metal, Kepler accede direttamente ai contatori hardware tramite RAPL, ottenendo misurazioni real-time senza necessità di modelli predittivi.

RAPL, ottenendo misurazioni energetiche real-time senza ricorrere a modelli predittivi pre-addestrati. In ambienti virtualizzati, invece, l'assenza di accesso diretto all'hardware richiede l'uso di modelli di regressione, introducendo le relative limitazioni di accuratezza.

Per accedere alle interfacce hardware necessarie, Kepler deve essere eseguito con privilegi elevati sull'host: richiede accesso a `/sys` e `/proc` per leggere i contatori RAPL e i cgroup, e al socket Docker per identificare i container attivi e associarvi le metriche energetiche.

3.1.2 Infrastruttura di supporto

L'avvio dell'infrastruttura di monitoraggio è gestito dallo script `StartMetrics.sh`, che inizializza come container Docker tutti i servizi necessari al funzionamento del sistema.




Figura 3.2: Architettura dell'infrastruttura di monitoraggio energetico e scheduling carbon-aware. I componenti di monitoraggio esterni (Kepler, Prometheus, Grafana) sono separati dagli store interni (etcd, InfluxDB), con Serverledge al centro che interagisce con entrambi i livelli. Lo scheduler carbon-aware integra la logica di selezione della variante — basata su frontiera di Pareto, scalarizzazione tramite λ , esplorazione LCB e consenso utente — e riceve il segnale di carbon intensity tramite query periodica a una sorgente esterna.

I componenti avviati, come mostrato anche in Figura 3.2, sono i seguenti:

- **Kepler**: eseguito in modalità privilegiata con accesso a `/sys`, `/proc` e al socket Docker dell'host, condizioni necessarie per la lettura dei contatori RAPL e l'associazione dei consumi ai container tramite cgroup.
- **Prometheus**: configurato per effettuare lo scraping periodico delle metriche esposte da Kepler, rendendole disponibili tramite API di interrogazione.
- **InfluxDB**: database a serie temporali utilizzato per l'archiviazione storica dei campioni energetici prodotti dal sistema ad ogni ciclo di raccolta.

- **etcd**: store distribuito chiave-valore che funge da registro delle funzioni e delle relative varianti, inclusi i profili energetici aggiornati dinamicamente a runtime.
- **Grafana**: strumento di visualizzazione utilizzato per il monitoraggio in tempo reale dei consumi durante gli esperimenti.

Una volta avviata, l'infrastruttura opera in modo autonomo: Kepler rileva i container Docker presenti sull'host e ne aggiorna le metriche energetiche ad ogni ciclo di campionamento; Prometheus le raccoglie e le rende interrogabili; il sistema interno di Serverledge, descritto nelle sezioni successive, le legge periodicamente — limitatamente ai container attivi da esso gestiti — per aggiornare i profili energetici delle varianti di funzione. Il segnale di carbon intensity, necessario allo scheduler per la selezione carbon-aware della variante, non è parte di questa infrastruttura: viene acquisito dallo scheduler a runtime tramite query periodica a una sorgente esterna, come descritto nella Sezione 4.

3.2 Il modello di funzione logica con varianti

Il supporto all'esecuzione energeticamente consapevole richiede che il sistema possa rappresentare, per una stessa funzione, implementazioni alternative con diversi profili di consumo energetico e livello di accuratezza. A tal fine è stato introdotto il concetto di *funzione logica con varianti*: un'astrazione che raggruppa sotto un unico identificatore logico più implementazioni della stessa funzione, ciascuna caratterizzata da un proprio profilo energetico e da un modello di output che ne quantifica l'accuratezza.

3.2.1 Struttura della funzione e profilo energetico

In Serverledge, ogni funzione è rappresentata dalla struttura **Function**, estesa in questo lavoro con i campi necessari al supporto delle varianti energetiche. I campi rilevanti

per il sistema proposto sono i seguenti:

- **LogicalName**: identificatore condiviso da tutte le varianti appartenenti alla stessa funzione logica. Costituisce il riferimento con cui il client invoca la funzione, indipendentemente dalla variante che verrà selezionata a runtime. La registrazione delle varianti avviene su consenso esplicito dell'utente in fase di creazione della funzione;
- **VariantID**: identificatore univoco della specifica variante all'interno del gruppo logico;
- **EnergyProfile**: struttura che mantiene la stima energetica della variante, composta da due campi:
 - **ColdStartJoule**: energia stimata per l'avvio a freddo del container, comprensiva dell'inizializzazione del runtime;
 - **InvocationJoule**: energia media stimata per una singola invocazione della funzione in warm start.
- **OutputModel**: struttura che descrive la qualità dell'output della variante, utilizzata dallo scheduler per il confronto tra varianti in termini di accuratezza. Il suo contenuto è descritto in dettaglio nella Sezione 3.2.2.

3.2.1.1 Determinazione dei profili energetici iniziali

I valori iniziali di **EnergyProfile** sono stati determinati offline tramite una campagna di misurazioni preliminari condotta con Kepler. La metodologia adottata tiene conto della natura delle metriche esposte da Kepler: trattandosi di contatori cumulativi,

l'energia osservata al termine di n invocazioni consecutive sullo stesso container rappresenta la somma dei contributi di tutte le esecuzioni, inclusa quella iniziale soggetta al cold start.

Per separare i due contributi energetici si è proceduto nel modo seguente. Dato un container su cui vengono eseguite n invocazioni consecutive, si indica con E_{tot} l'energia cumulativa totale rilevata da Kepler al termine dell'ultima invocazione e con E_1 l'energia della prima invocazione, che comprende sia il costo di inizializzazione del container che quello di esecuzione della funzione. Le invocazioni successive, eseguite a container già attivo, sono invece soggette al solo costo di esecuzione. Il costo medio di invocazione in warm start è quindi stimato come:

$$E_{inv} = \frac{E_{tot} - E_1}{n - 1} \quad (3.2.1)$$

e il costo di cold start come:

$$E_{cold} = E_1 - E_{inv} \quad (3.2.2)$$

La ripetizione delle misurazioni su un numero statisticamente significativo di invocazioni consente di attenuare la varianza introdotta dal sistema operativo e dal runtime, ottenendo stime robuste per entrambi i contributi. I valori così ottenuti vengono codificati nel file JSON di definizione delle varianti e costituiscono la stima iniziale del profilo energetico. Il Codice 3.1 mostra un esempio concreto per la funzione `PiLeibniz`, che espone tre varianti esatte a runtime diverso e sei varianti approssimate con numero di iterazioni ridotto.

Codice 3.1: File di definizione delle varianti per la funzione `PiLeibniz`. Le prime due varianti sono esatte (`is_approximate: false`) e differiscono per runtime e consumo. (omesse per brevità le quattro varianti intermedie).

```
1 {  
2   "variants": [  
3     {  
4       "id": "base",
```

```
5     "runtime": "python310",
6     "entry_point": "piLeibniz.handler",
7     "src": "piLeibniz.py",
8     "energy": {
9         "cold_start_joule": 0.070134,
10        "invocation_joule": 0.007823
11    },
12    "output": { "type": "error",
13                "error_estimate": 0.0 },
14    "is_approximate": false
15 },
16 {
17     "id": "c",
18     "runtime": "native",
19     "entry_point": "piLeibniz_base",
20     "src": "piLeibniz_base",
21     "energy": {
22         "cold_start_joule": 0.008847,
23         "invocation_joule": 0.001052
24     },
25     "output": { "type": "error",
26                 "error_estimate": 0.0 },
27     "is_approximate": false
28 },
29 {
30     "id": "n1000",
31     "runtime": "python310",
32     "entry_point": "piLeibniz_n1000.handler",
33     "src": "piLeibniz_n1000.py",
34     "energy": {
35         "cold_start_joule": 0.070681,
36         "invocation_joule": 0.000196
37     },
38     "output": { "type": "error",
39                 "error_estimate": 0.001999 },
40     "is_approximate": true
41 },
42 {
43     "id": "n200000",
44     "runtime": "python310",
45     "entry_point": "piLeibniz_n200000.handler",
46     "src": "piLeibniz_n200000.py",
47     "energy": {
48         "cold_start_joule": 0.069587,
49         "invocation_joule": 0.001534
```



```
50     },  
51     "output": { "type": "error",  
52                 "error_estimate": 0.000010 },  
53     "is_approximate": true  
54 }  
55 ]  
56 }
```

I valori iniziali del profilo energetico sono progressivamente raffinati a runtime attraverso due meccanismi complementari, descritti nelle Sezioni 3.3 e 3.4: il worker periodico aggiorna le stime delle varianti effettivamente eseguite tramite filtro EMA, mentre il meccanismo di esplorazione LCB permette di correggere le stime delle varianti sotto-campionate, prevenendo che una stima inizialmente errata le escluda permanentemente dalla selezione. I risultati numerici delle misurazioni preliminari per tutte le varianti sono riportati nel Capitolo 5.

3.2.2 Il modello di output e la classificazione dell'accuratezza

Per consentire allo scheduler di confrontare le varianti in termini di accuratezza, ciascuna variante è dotata di un `OutputModel` che descrive la qualità del suo output. Il modello supporta due tipologie di classificazione, scelte in base alla natura computazionale della funzione:

- **Tipo error:** adatto a funzioni il cui output è un valore numerico misurabile. L'accuratezza è espressa tramite il campo `error_estimate`, che rappresenta l'errore relativo atteso rispetto alla variante di riferimento. Una variante esatta presenta `error_estimate = 0.0`, mentre varianti approssimate presentano valori positivi proporzionali alla deviazione introdotta dalla semplificazione algoritmica adottata.

- **Tipo quality:** adatto a funzioni il cui output non è facilmente quantificabile con un errore numerico, come classificatori o modelli di machine learning. L'accuratezza è espressa tramite il campo numerico `quality_score` $\in [0, 1]$, dove 1 corrisponde all'accuratezza massima;

Il Codice 3.2 mostra un esempio applicativo del tipo `quality` per la funzione `ImageClassification`, in cui la variante base utilizza un modello ViT più accurato ma più oneroso energeticamente, mentre le varianti successive adottano architetture più compatte (EfficientNet-B0, MobileNet-V2, MobileNet-V2-Tiny) a qualità progressivamente ridotta.

Codice 3.2: File di definizione delle varianti per la funzione `ImageClassification`. Il campo `quality_score` riporta la Top-1 accuracy su ImageNet pubblicata dagli autori di ciascun modello, espressa in $[0, 1]$.

```

1 {
2   "variants": [
3     {
4       "id": "vit-base",
5       "runtime": "python-ml",
6       "entry_point": "ImageClassification.handler",
7       "src": "ImageClassification.py",
8       "energy": { "cold_start_joule": 1.895,
9                   "invocation_joule": 1.455 },
10      "output": { "type": "quality",
11                  "quality": "high",
12                  "quality_score": 0.818 },
13      "is_approximate": false
14    },
15    {
16      "id": "efficientnet-b0",
17      "runtime": "python-ml",
18      "entry_point":
19        "ImageClassificationEfficientNetB0.handler",
20      "src":
21        "ImageClassificationEfficientNetB0.py",
22      "energy": { "cold_start_joule": 1.183,
23                  "invocation_joule": 0.418 },
24      "output": { "type": "quality",
25                  "quality": "medium-high",

```

```

26         "quality_score": 0.771 },
27     "is_approximate": true
28 },
29 {
30     "id": "mobilenet-v2",
31     "runtime": "python-ml",
32     "entry_point":
33         "ImageClassificationLight.handler",
34     "src": "ImageClassificationLight.py",
35     "energy": { "cold_start_joule": 1.071,
36                 "invocation_joule": 0.229 },
37     "output": { "type": "quality",
38                 "quality": "medium-low",
39                 "quality_score": 0.718 },
40     "is_approximate": true
41 },
42 {
43     "id": "mobilenet-v2-tiny",
44     "runtime": "python-ml",
45     "entry_point":
46         "ImageClassificationMobileNetTiny.handler",
47     "src":
48         "ImageClassificationMobileNetTiny.py",
49     "energy": { "cold_start_joule": 0.779,
50                 "invocation_joule": 0.077 },
51     "output": { "type": "quality",
52                 "quality": "low",
53                 "quality_score": 0.603 },
54     "is_approximate": true
55 }
56 ]
57 }

```

3.2.3 Registrazione e indicizzazione delle varianti in etcd

Le varianti di una funzione logica vengono definite tramite un file JSON collocato nella directory `variants/<LogicalName>/` del progetto. Al momento della registrazione, il sistema legge questo file attraverso il componente `FileSource`, prepara il codice sorgente di ciascuna variante in formato tar e materializza le varianti in etcd attraverso la funzione `CreateInternalVariants`.

3.2.3.1 Convenzione di denominazione

La prima variante definita nel file JSON —corrispondente alla funzione di base— mantiene come nome interno esattamente il `LogicalName`, preservando la compatibilità con le invocazioni che non specificano alcuna preferenza energetica. Le varianti successive ricevono un nome nella forma `<LogicalName>-<VariantID>`. Per la funzione `PiLeibniz` (Codice 3.1), ad esempio, i nomi interni assegnati sono `PiLeibniz`, `PiLeibniz-optimization-py`, `PiLeibniz-c`, `PiLeibniz-n1000`, e così via.

3.2.3.2 Struttura delle chiavi in etcd

Il sistema mantiene in etcd due livelli distinti di chiavi, come illustrato in Figura 3.3. Il prefisso `/function/` contiene una chiave per ogni variante registrata, il cui valore è la serializzazione JSON completa della struttura `Function` — runtime, codice sorgente, profilo energetico (`ColdStartJoule` e `InvocationJoule`) e modello di output. Il prefisso `/index/logical/<LogicalName>/` costituisce invece un indice che, tramite una singola query a prefisso, consente allo scheduler di recuperare tutte le varianti di una funzione logica senza scorrere l'intero `/function/` contenendo in tal modo la latenza introdotta dalla selezione della variante nel path della richiesta di invocazione.




Figura 3.3: Struttura delle chiavi etcd per la funzione logica PiLeibniz. Le chiavi sotto `/function/` contengono i profili completi; l'indice sotto `/index/logical/` consente la lookup efficiente delle sole varianti richieste.

3.3 Misurazione e aggiornamento adattivo dei profili energetici

Una volta introdotto il modello di funzione logica con varianti multiple, è necessario dotare il sistema di un meccanismo capace di aggiornare dinamicamente i profili energetici sulla base dei consumi effettivamente osservati a runtime. Un approccio statico, in cui il costo energetico di una variante viene stimato offline e rimane invariato nel tempo, risulta inadeguato in contesti di esecuzione reali: il consumo energetico di un container è influenzato da fattori mutevoli quali il carico del nodo, le interferenze tra istanze concorrenti e le variazioni dinamiche della frequenza di CPU.

La soluzione adottata è un *feedback loop* periodico che trasforma il profilo energe-

tico in una grandezza adattiva, aggiornata continuamente in funzione del contesto di esecuzione. Il componente responsabile è un worker di raccolta eseguito in background, illustrato in Figura 3.4.




Figura 3.4: Schema del feedback loop energetico. Il worker periodico legge le metriche cumulative da Kepler tramite Prometheus e il numero di invocazioni dal contatore locale, calcola i delta, applica un filtro EMA e aggiorna il profilo persistito in etcd, archiviando contestualmente i campioni in InfluxDB.

3.3.1 Tracciamento dei container e conteggio delle invocazioni

Per attribuire correttamente il consumo energetico alle singole varianti, il sistema deve mantenere una corrispondenza stabile tra i container Docker attivi e le funzioni in esecuzione. A tal fine il package `energy` mantiene un registro in memoria che associa a ciascun container una struttura `ContainerState` contenente:

- l'identificatore del container (`ContainerID`);
- il nome interno della variante (`FunctionName`), il `LogicalName` e il `VariantID`;

- i valori di baseline dell'energia cumulativa e del numero di invocazioni (`LastJoule`, `LastInvocations`), impiegati per il calcolo dei delta incrementali;
- gli accumulatori `PendingEnergyJ` e `PendingInvocations`, necessari per gestire il disallineamento temporale tra metriche energetiche e contatori locali.

La registrazione avviene sia alla creazione del container sia, in modo difensivo, al momento dell'invocazione, così da gestire correttamente il caso di *warm start*. Se un container è già presente nel registro, la sua identità (mapping container-variante) non viene modificata, garantendo coerenza per l'intero ciclo di vita del container.

Parallelamente, viene mantenuto un contatore atomico di invocazioni per container, incrementato al completamento di ogni richiesta.

3.3.2 Il worker periodico di raccolta

Il worker è implementato come una goroutine avviata all'inizializzazione della piattaforma. Con cadenza di 10 secondi, esegue un ciclo di raccolta (`Collect`) operando su uno snapshot thread-safe del `ContainerRegistry`, in modo da isolare la lettura dallo stato condiviso senza bloccare le operazioni concorrenti.

Per ciascun container attivo vengono acquisiti:

- il valore cumulativo di energia E_{now} , esposto da Kepler e reso disponibile tramite l'endpoint Prometheus;
- il numero cumulativo di invocazioni N_{now} , mantenuto aggiornato dal contatore locale.

Vengono quindi calcolati i delta rispetto all'osservazione precedente:

$$\Delta E = E_{now} - E_{last} \quad \Delta N = N_{now} - N_{last} \quad (3.3.1)$$

La presenza di valori negativi segnala un reset del container o del contatore, condizione possibile ad esempio in seguito a un riavvio dell'istanza, e comporta la reinizializzazione delle variabili senza produzione di campioni, evitando attribuzioni energetiche errate.

3.3.3 Attribuzione dell'energia per invocazione e gestione del lag

Le metriche esposte da Kepler hanno natura cumulativa e sono soggette a un ritardo di campionamento intrinseco al ciclo di scraping di Prometheus. Il contatore locale di invocazioni, al contrario, viene aggiornato immediatamente al termine di ogni esecuzione. Può quindi verificarsi la condizione:

$$\Delta N > 0 \quad \text{e} \quad \Delta E = 0$$

in cui nuove invocazioni sono già state completate ma il relativo consumo energetico non è ancora riflesso nella metrica cumulativa. Calcolare in questo caso il consumo medio per invocazione produrrebbe una sottostima sistematica.

Per gestire questo disallineamento, i delta vengono accumulati nei campi `PendingEnergyJ` e `PendingInvocations`. L'attribuzione effettiva avviene solo quando entrambi gli accumulatori risultano positivi, garantendo che l'energia osservata e il numero di esecuzioni considerate siano coerenti tra loro:

$$e_{inv} = \frac{E_{pending}}{N_{pending}} \tag{3.3.2}$$

Il valore e_{inv} rappresenta la stima istantanea del consumo medio per invocazione nel periodo considerato e costituisce l'ingresso per la fase di aggiornamento adattivo del profilo.

3.3.4 Aggiornamento del profilo tramite media mobile esponenziale

La stima istantanea e_{inv} può essere affetta da rumore dovuto a interferenze tra container, variazioni dinamiche della frequenza di CPU o fluttuazioni del carico di sistema. Applicare direttamente tale valore al profilo energetico potrebbe causare oscillazioni indesiderate nelle decisioni dello scheduler.

Per stabilizzare la stima viene applicata una *Exponential Moving Average* (EMA):

$$J_{new} = \alpha \cdot e_{inv} + (1 - \alpha) \cdot J_{old} \quad (3.3.3)$$

con $\alpha = 0.2$. Il parametro α governa il compromesso tra due esigenze contrastanti:

- **Reattività:** valori elevati rendono il profilo rapidamente adattabile a variazioni strutturali del consumo energetico;
- **Stabilità:** valori ridotti attenuano il contributo di singoli campioni anomali, producendo una stima più robusta.

La scelta di $\alpha = 0.2$ rappresenta un equilibrio empirico: il sistema filtra efficacemente i picchi transitori, mantenendo al contempo una capacità di adattamento progressivo al nuovo regime energetico nell'arco di circa $1/\alpha$ cicli di aggiornamento, corrispondenti a circa 50 secondi con la cadenza attuale del worker.

Il valore aggiornato J_{new} viene scritto nel campo `InvocationJoule` della variante corrispondente e persistito in etcd, rendendolo immediatamente disponibile allo scheduler per le decisioni di selezione successive.

3.3.5 Archiviazione su InfluxDB

Contestualmente all'aggiornamento in etcd, ogni campione viene archiviato in InfluxDB come punto della *measurement* `energy_sample`, con tag `container_id`, `logical_name`, `function_name`, `variant_id` e campo `invocation_joule`.

La separazione tra i due store riflette le loro funzioni distinte: etcd fornisce allo scheduler la stima corrente con latenza minima; InfluxDB preserva la serie storica dei campioni, che costituisce la base statistica per il meccanismo di esplorazione descritto nella Sezione 3.4.

3.4 Esplorazione LCB per il raffinamento delle stime energetiche

Il meccanismo EMA descritto nella sezione precedente consente di raffinare i profili energetici a runtime, ma presenta un prerequisito implicito: aggiorna solo le varianti che vengono effettivamente eseguite. Se la stima iniziale di una variante è sovrastimata rispetto al suo consumo reale, lo scheduler tenderà a non selezionarla, il worker non raccoglierà mai campioni su di essa, impedendo la correzione dell'errore. Il problema si manifesta in particolare nelle fasi iniziali del sistema, quando i profili offline (determinati su un hardware di riferimento) potrebbero non riflettere il comportamento reale sul nodo edge in produzione, sia per la *dipendenza dall'hardware* (CPU, workload e condizioni termiche differenti), sia per la *non stazionarietà* del consumo energetico (che varia con il carico concorrente, la temperatura del processore e lo stato della cache del runtime). In queste condizioni, una variante con consumo energetico sovrastimato tende ad essere sistematicamente penalizzata nella scalarizzazione Pareto e a non venire mai selezionata, impedendo al meccanismo EMA di raccogliere campioni reali su di

Simbolo	Significato
μ_i^{EMA}	Stima EMA dell'energia della variante i , letta da etcd ($\alpha = 0.2$)
σ_i	Deviazione standard calcolata sui campioni InfluxDB.
n_i^{eff}	Numero effettivo di campioni: $n_i + 0.5$
β	Parametro di esplorazione (configurabile, default 1.0)

Tabella 3.1: Simboli della formula LCB e relativi valori.

lei e correggere l'errore. È necessario quindi introdurre un meccanismo che promuova l'esplorazione di varianti poco osservate, indipendentemente dalla loro stima corrente.

3.4.1 Il principio di ottimismo sotto incertezza

Il meccanismo adottato si basa sul principio di *ottimismo sotto incertezza* (Optimism in the Face of Uncertainty) [26]. Tale meccanismo incentiva l'esplorazione di varianti sotto-campionate, raccogliendo dati reali e convergendo progressivamente a stime accurate.

Per applicare il principio alla minimizzazione del consumo energetico si utilizza il Lower Confidence Bound (LCB), al più comune UCB:

$$\text{LCB}(i) = \mu_i^{\text{EMA}} - \beta \cdot \frac{\sigma_i}{\sqrt{n_i^{\text{eff}}}} \quad (3.4.1)$$

dove $n_i^{\text{eff}} = n_i + 0.5$, con n_i il numero di campioni InfluxDB disponibili per la variante i . L'addendo costante 0.5 evita la divisione per zero nel caso $n_i = 0$ e assicura la massima correzione ottimistica per varianti mai osservate. La Tabella 3.1 descrive i simboli della formula.

Una LCB bassa segnala che la variante è sotto-esplorata: il sistema la favorisce nella selezione per raccogliere dati aggiuntivi. All'aumentare di n_i , la correzione si azzerà e la stima converge alla media empirica.

3.4.2 Proprietà di convergenza

La formula (3.4.1) gode delle seguenti proprietà asintotiche, che ne garantiscono il corretto bilanciamento tra esplorazione e sfruttamento:

- quando n_i è grande (variante ben esplorata), il termine $\sigma_i/\sqrt{n_i^{\text{eff}}}$ tende a zero e $\text{LCB}(i) \rightarrow \mu_i^{\text{EMA}}$: il sistema sfrutta la stima corrente senza alterarla;
- quando $n_i = 0$ (variante mai osservata), la correzione è massima ($n_i^{\text{eff}} = 0.5$)
- $\beta = 0$ disabilita completamente l'esplorazione, riducendo la formula alla sola stima EMA;
- in caso di indisponibilità di InfluxDB, il sistema degrada a μ^{EMA} senza correzione, garantendo il funzionamento anche in assenza del componente esterno.

Le componenti descritte in questo capitolo costituiscono l'infrastruttura su cui si fonda la schedulazione carbon-aware: il modello di funzione logica con varianti fornisce lo spazio decisionale, Kepler ne misura i consumi a runtime, il worker periodico aggiorna i profili energetici tramite filtro EMA e il meccanismo LCB garantisce che anche le varianti sotto-campionate vengano esplorate nelle fasi iniziali. Il capitolo seguente descrive come questi elementi vengano integrati nello scheduler carbon-aware, che li utilizza per selezionare, a ogni invocazione, la variante più appropriata in funzione della carbon intensity della zona geografica del nodo.

Capitolo 4

Lo scheduler carbon-aware

In questo capitolo verrà descritto lo scheduler carbon-aware, il componente decisionale che costituisce il nucleo dell'estensione proposta. Verranno presentati il meccanismo di normalizzazione della carbon intensity in un peso decisionale contestualizzato per zona geografica, la costruzione della frontiera di Pareto nello spazio energia-accuratezza e la logica di scalarizzazione che seleziona, a ogni invocazione, la variante più appropriata in funzione del segnale ambientale corrente.

4.1 La carbon intensity come segnale decisionale

Come già detto precedentemente, la carbon intensity (CI) esprime la quantità di CO₂ equivalente emessa per ogni kilowattora prodotto dalla rete elettrica locale, misurata in g CO₂eq/kWh. Questo valore riflette la composizione del mix energetico di una zona geografica in un dato istante: una rete alimentata prevalentemente da fonti rinnovabili presenta valori di CI ridotti, mentre una rete dipendente da combustibili fossili mostra valori elevati.

Nel contesto di questo lavoro, la CI viene utilizzata come segnale per derivare il parametro di trade-off $\lambda \in (0, 1)$ che governa la selezione della variante (Sezione 4.2): quando l'energia disponibile è a bassa intensità carbonica, il sistema può privilegiare

l'accuratezza del risultato senza un costo ambientale significativo; quando la rete è carbon-intensive, è preferibile ridurre i consumi a scapito dell'accuratezza.

Tuttavia, il valore assoluto della CI non è sufficiente per prendere questa decisione: una CI di 100 g CO₂/kWh rappresenta un picco anomalo per la Norvegia, ma è del tutto ordinaria per la Spagna. Stabilire se l'energia è più o meno "green" in un dato momento richiede quindi un riferimento contestuale, ovvero la distribuzione storica della CI per la zona geografica considerata.

È necessario pertanto un modello di normalizzazione che trasformi la CI corrente in un peso $\lambda \in (0, 1)$ relativo al contesto storico della zona. La semantica adottata è la seguente:

- $\lambda \rightarrow 1$: la CI corrente è bassa rispetto alla distribuzione storica della zona (rete elettrica relativamente *pulita*); il sistema privilegia l'accuratezza del risultato;
- $\lambda \rightarrow 0$: la CI corrente è elevata (rete *sporca*); il sistema privilegia l'efficienza energetica.

4.1.1 La Carbon Response Function

Per tradurre la CI corrente in un valore di λ relativo al contesto storico della zona, si adotta una funzione logistica monotona decrescente, denominata *Carbon Response Function* (CRF), nella forma:

$$\lambda(CI) = \frac{1}{1 + \exp\left(k \cdot \frac{CI - \mu_z}{s_z}\right)} \quad (4.1.1)$$

dove μ_z è la media storica della CI per la zona geografica z (punto di simmetria in cui $\lambda = 0,5$), s_z è un fattore di scala derivato dalla dispersione storica locale, e $k > 0$ è un parametro di pendenza che controlla la velocità di transizione. La scelta di

questa famiglia di funzioni è motivata da tre proprietà desiderabili nel contesto dello scheduling:

- **Monotonicità decrescente:** λ decresce monotonamente al crescere di CI, associando in modo coerente condizioni di rete più carbon-intensive a un peso maggiore sull'efficienza energetica.
- **Saturazione:** λ tende asintoticamente a 1 per CI basse e a 0 per CI alte.
- **Sensibilità contestuale:** i parametri μ_z e s_z sono calibrati a partire dalla distribuzione storica della CI nella zona z , permettendo alla CRF di adattarsi al contesto locale. In questo modo, il valore di λ esprime una misura relativa rispetto alla norma locale, rendendo confrontabili le decisioni di scheduling tra aree geografiche diverse, anche quando i livelli assoluti di carbon intensity differiscono significativamente.

Calibrazione dei parametri. I parametri μ_z , s_z e k sono stimati a partire dai dati storici di carbon intensity per ciascuna zona, recuperati da [6]. La procedura è la seguente:

1. μ_z è posto pari alla *media* storica della CI per la zona, garantendo $\lambda(\mu_z) = 0,5$, ovvero che il punto di bilanciamento neutro corrisponda al valore tipico della zona;
2. s_z è ricavato dal quinto e novantacinquesimo percentile della distribuzione storica:

$$s_z = \frac{CI_{95} - CI_5}{2 \ln\left(\frac{1-\alpha}{\alpha}\right)} \quad (4.1.2)$$

con $\alpha = 0,01$. L'utilizzo dei percentili estremi consente di catturare l'intervallo di variabilità tipica della CI nella zona, trascurando i valori anomali. In particolare,

il 90 % centrale della distribuzione storica viene mappato nell'intervallo $[\alpha, 1 - \alpha]$ di λ , garantendo che la funzione sia sufficientemente sensibile alle variazioni reali della CI, senza risultare distorta dalla presenza di outlier.

3. k è un parametro di pendenza configurabile per zona: valori più alti producono una transizione più netta attorno a μ_z , valori più bassi una risposta più graduale.

Calcolo a runtime.

Algoritmo 1 Calcolo del peso λ dalla carbon intensity corrente

Require: zona geografica z , soglia di fallback $\lambda_0 = 0,5$

Ensure: $\lambda \in (0, 1)$

```

1: CI  $\leftarrow$  GETCARBONINTENSITY( $z$ )                                 $\triangleright$  API ElectricityMaps
2: if CI non disponibile then
3:   return  $\lambda_0$ 
4:  $\mu_z \leftarrow$  GETMEAN( $z$ )
5:  $s_z \leftarrow \frac{CI_{95}(z) - CI_5(z)}{2 \ln\left(\frac{1 - \alpha}{\alpha}\right)}$ 
6:  $k \leftarrow$  GETSLOPEPARAM( $z$ )
7: return  $\frac{1}{1 + \exp\left(k \cdot \frac{CI - \mu_z}{s_z}\right)}$ 

```

Al momento dell'invocazione, lo scheduler recupera la CI corrente tramite l'API di ElectricityMaps [6], legge i parametri della zona, e calcola λ secondo l'Equazione (4.1.1), come descritto nell'algoritmo 1. In caso di indisponibilità dell'API, il sistema degrada a $\lambda = 0,5$ (bilanciamento neutro tra accuratezza ed efficienza energetica).

4.2 La frontiera di Pareto nello spazio energia-errore

Il valore di λ derivato nella sezione precedente costituisce il segnale che guida la selezione della variante da eseguire: un λ prossimo a 1 orienta lo scheduler verso le varianti

più accurate, mentre un λ prossimo a 0 privilegia quelle a minore consumo energetico. Tuttavia, prima di applicare tale peso, è necessario determinare l'insieme di varianti su cui operare. Non tutte le varianti disponibili rappresentano scelte razionali: alcune sono dominate da altre, ovvero esistono alternative che consumano meno energia e producono un errore inferiore. Includere tali varianti nella selezione introdurrebbe ridondanza senza apportare benefici decisionali. Il sistema restringe quindi il dominio di scelta alle sole varianti *Pareto-ottimali*, ovvero quelle per cui non esiste alcuna alternativa migliore in entrambe le dimensioni simultaneamente.

Definizione. Sia $V = \{v_1, \dots, v_n\}$ l'insieme delle varianti disponibili. Una variante v_i è *dominata* da v_j se:

$$E(v_j) \leq E(v_i) \wedge Err(v_j) \leq Err(v_i) \wedge (E(v_j) < E(v_i) \vee Err(v_j) < Err(v_i)) \quad (4.2.1)$$

La frontiera di Pareto $\mathcal{P} \subseteq V$ è l'insieme delle varianti non dominate:

$$\mathcal{P} = \{v \in V \mid \nexists v' \in V : v' \text{ domina } v\} \quad (4.2.2)$$

Ogni variante sulla frontiera rappresenta un compromesso efficiente: ridurre una delle due grandezze implica necessariamente aumentare l'altra. È su questo insieme ridotto che λ esercita la propria funzione di selezione.

Costruzione. La frontiera è costruita a runtime immediatamente prima di ogni selezione, a partire dai profili energetici correnti. La scelta di ricostruire la frontiera a ogni invocazione, anziché mantenerla precalcolata, è motivata dal fatto che i profili energetici sono aggiornati dinamicamente: nella fase iniziale, quando le misurazioni sono ancora scarse, la frontiera evolve a ogni invocazione in funzione delle nuove osservazioni raccolte. Man mano che le stime energetiche convergono, la frontiera si stabilizza, e le ricostruzioni successive producono risultati sostanzialmente invariati. Il costo com-

putazionale della ricostruzione a runtime è quindi giustificato nella fase esplorativa e diventa trascurabile a regime, quando la frontiera è ormai stabile.

Come coordinata energetica non viene utilizzata la stima EMA grezza, bensì la stima LCB descritta nella Sezione 3.4. Questa scelta è intenzionale: il termine di esplorazione abbassa la stima energetica delle varianti sotto-campionate, rendendole apparentemente più convenienti. Di conseguenza, tali varianti tendono a posizionarsi più favorevolmente sulla frontiera e a essere selezionate più frequentemente, accumulando osservazioni reali che affinano progressivamente la stima EMA. L'esplorazione non è quindi un meccanismo separato dalla selezione, ma è integrata nella costruzione stessa della frontiera: ogni invocazione rappresenta simultaneamente una decisione di scheduling e un'opportunità di apprendimento.

4.3 Scalarizzazione e selezione della variante

Una volta costruita la frontiera $\mathcal{P}$, il problema si riduce alla scelta del compromesso più appropriato dato il contesto ambientale corrente. La selezione è realizzata tramite una funzione di scalarizzazione lineare pesata da λ , che collassa le due dimensioni in un unico punteggio confrontabile.

4.3.1 Normalizzazione e funzione obiettivo

Energia ed errore sono grandezze eterogenee, espresse in unità di misura diverse e potenzialmente caratterizzate da ordini di grandezza differenti. Per renderle confrontabili, entrambe vengono normalizzate nell'intervallo $[0, 1]$ rispetto al minimo e al massimo

osservati sulla frontiera $\mathcal{P}$:

$$\hat{E}(v) = \frac{E(v) - E_{\min}}{E_{\max} - E_{\min}} \quad (4.3.1)$$

$$\widehat{Err}(v) = \frac{Err(v) - Err_{\min}}{Err_{\max} - Err_{\min}} \quad (4.3.2)$$

La normalizzazione è calcolata esclusivamente sulle varianti Pareto-ottimali, in modo che i valori estremi della scala corrispondano sempre ai casi limite effettivamente raggiungibili lungo la frontiera. La funzione di scalarizzazione lineare è quindi:

$$S(v, \lambda) = (1 - \lambda) \hat{E}(v) + \lambda \widehat{Err}(v) \quad (4.3.3)$$

La variante selezionata v^* è quella che minimizza S sulla frontiera:

$$v^* = \arg \min_{v \in \mathcal{P}} S(v, \lambda) \quad (4.3.4)$$

Per costruzione, v^* appartiene sempre a $\mathcal{P}$ ed è quindi non dominata: nessuna alternativa è contemporaneamente più efficiente e più accurata. I casi limite sono immediati: per $\lambda = 1$ la funzione si riduce a $S = \widehat{Err}(v)$ e viene selezionata la variante più accurata; per $\lambda = 0$ si ha $S = \hat{E}(v)$ e viene selezionata quella a consumo minimo. Per valori intermedi la selezione bilancia le due dimensioni in modo continuo e proporzionale al segnale ambientale.

4.3.2 Analisi delle soglie di transizione

La linearità della funzione di scalarizzazione consente di identificare analiticamente i valori di λ in corrispondenza dei quali la variante selezionata cambia. Sviluppando l'Equazione (4.3.3) si ottiene:

$$S_i(\lambda) = \hat{E}_i + \lambda (\widehat{Err}_i - \hat{E}_i) \quad (4.3.5)$$

Per ogni variante $v_i \in \mathcal{P}$, lo score è una funzione lineare in λ . Nel piano (λ, S) , ciascuna variante è rappresentata da una retta e lo scheduler seleziona, per ogni valore di λ , la variante associata alla retta con valore minimo.

I punti di transizione corrispondono alle intersezioni tra queste rette. Uguagliando gli score di due varianti v_i e v_j si ottiene:

$$\lambda_{ij} = \frac{\hat{E}_j - \hat{E}_i}{(\hat{E}_j - \hat{E}_i) + (\widehat{Err}_i - \widehat{Err}_j)} \quad (4.3.6)$$

Per $\lambda < \lambda_{ij}$ è preferita la variante a minore energia, mentre per $\lambda > \lambda_{ij}$ quella a minore errore.

Ne segue che la variante selezionata varia a tratti costanti al variare di λ , dando luogo a un andamento a gradini: tra due soglie consecutive la scelta rimane invariata, mentre al superamento di una soglia si verifica una transizione verso una variante più accurata. All'aumentare di λ , la selezione si sposta progressivamente lungo la frontiera di Pareto, dalle varianti a minimo consumo verso quelle a minima imprecisione. Il comportamento a gradini che ne deriva verrà illustrato sperimentalmente nel Capitolo 5, dove la selezione lungo la frontiera di Pareto è analizzata su funzioni rappresentative al variare di λ .

4.4 Formalizzazione della logica decisionale

La logica complessiva dello scheduler carbon-aware è formalizzata nell'Algoritmo 2, che integra le fasi descritte nelle sezioni precedenti: valutazione delle varianti con stima LCB, costruzione della frontiera di Pareto, acquisizione del segnale ambientale tramite l'Algoritmo 1 e scalarizzazione finale.

Algoritmo 2 SELECTPARETOVARIANT: selezione carbon-aware

```

1: function SELECTPARETOVARIANT( $r$  : Request)
2:    $base \leftarrow r.Fun$ 
3:    $V \leftarrow \text{GETFUNCTIONSBYLOGICALNAME}(base.LogicalName)$ 
4:   if  $V = \emptyset$  then
5:     return ( $base$ , “fallback-base”)
6:
7:                                      $\triangleright$  Valutazione delle varianti (energia LCB + errore)
8:    $Eval \leftarrow []$ 
9:   for  $v \in V$  do
10:     $warm \leftarrow \text{HASWARMCONTAINER}(v)$ 
11:     $E(v) \leftarrow \text{ENERGYLCB}(v, warm, \beta, k)$ 
12:     $Err(v) \leftarrow \text{ERRORSCORE}(v)$ 
13:     $Eval.APPEND(v, E(v), Err(v))$ 
14:
15:                                      $\triangleright$  Frontiera di Pareto —  $O(n \log n)$ 
16:    $\mathcal{P} \leftarrow \text{PARETOFILTER}(Eval)$ 
17:   if  $|\mathcal{P}| = 1$  then
18:     return ( $\mathcal{P}[0]$ , “pareto-singleton”)
19:
20:                                      $\triangleright$  Peso  $\lambda$  dalla CI corrente — Algoritmo 1
21:    $\lambda \leftarrow \text{GETLAMBDA}(r.Zone)$ 
22:
23:                                      $\triangleright$  Normalizzazione e scalarizzazione
24:    $E_{\min}, E_{\max} \leftarrow \text{MINMAX}([E(v) : v \in \mathcal{P}])$ 
25:    $Err_{\min}, Err_{\max} \leftarrow \text{MINMAX}([Err(v) : v \in \mathcal{P}])$ 
26:    $v^* \leftarrow \arg \min_{v \in \mathcal{P}} [(1 - \lambda) \hat{E}(v) + \lambda \widehat{Err}(v)]$ 
27:   return ( $v^*$ , “pareto-scalarisation”)

```

L'algoritmo evidenzia la separazione netta tra le quattro fasi: valutazione dei profili con stima ottimistica, costruzione della frontiera, acquisizione del segnale ambientale e scalarizzazione. La struttura modulare consente di sostituire ciascun componente indipendentemente dagli altri: il modello di normalizzazione della CI, la funzione di scalarizzazione e il criterio di dominanza di Pareto sono tutti intercambiabili senza modificare l'architettura complessiva. La chiamata GETLAMBDA opera su dati mantenuti in memoria locale (la CI è aggiornata in background ogni 15 minuti) evitando latenze

di rete nel percorso critico della richiesta.

Lo scheduler carbon-aware descritto in questo capitolo integra in un unico meccanismo decisionale le tre famiglie di soluzioni identificate nel Capitolo 2: la selezione tra varianti con diversi profili energia-accuratezza, la sensibilità al contesto carbonico della rete elettrica e l'adattività delle stime energetiche alle condizioni operative correnti. La Carbon Response Function calibrata per zona traduce la carbon intensity in un peso λ contestualizzato rispetto alla distribuzione storica locale; la frontiera di Pareto restringe lo spazio decisionale alle sole varianti non dominate; la scalarizzazione lineare seleziona il compromesso più appropriato in funzione del segnale ambientale. Due casi limite della scalarizzazione — la politica *always-accurate* ($\lambda = 1$) e la politica *always-efficient* ($\lambda = 0$) — costituiranno i termini di confronto nella valutazione sperimentale del Capitolo 5, dove verrà quantificato il beneficio del controllo adattivo rispetto a strategie statiche che ignorano il segnale ambientale.

Capitolo 5

Risultati Sperimentali

Questo capitolo valuta sperimentalmente l'estensione carbon-aware di Serverledge proposta in questa tesi. L'obiettivo è verificare se lo scheduler carbon-aware seleziona varianti coerenti con la carbon intensity della zona, muovendosi lungo la frontiera di Pareto in funzione del contesto carbonico dell'esecuzione. Il consumo è considerato una dimensione del trade-off con la qualità del risultato: lo scheduler privilegia varianti più efficienti quando il costo carbonico dell'energia è elevato, mantenendo varianti più accurate quando tale costo è ridotto.

5.1 Setup sperimentale

La valutazione è stata condotta su un'installazione di Serverledge estesa con i componenti descritti nei Capitoli 3 e 4. L'ambiente è composto da tre macchine virtuali ospitate su una macchina fisica equipaggiata con processore Intel Core i5-12400, tutte eseguite su Ubuntu Server 22.04 LTS. La prima macchina virtuale (4 vCPU, 12 GB RAM) ospita il nodo Serverledge insieme all'intero stack di monitoraggio e al registro delle varianti in `etcd`. La seconda (2 vCPU, 4 GB RAM) è dedicata alla generazione del carico, tramite la CLI di Serverledge e gli script di benchmark. La terza (2 vCPU, 4 GB RAM) esegue InfluxDB, separata dal nodo principale per evitare contesa sulle

risorse durante la raccolta delle metriche.

5.1.1 Funzioni utilizzate

Le funzioni usate negli esperimenti coprono due famiglie applicative: *funzioni numeriche* e *funzioni di classificazione* (ML). Questa scelta consente di valutare lo scheduler su due modalità di approssimazione strutturalmente diverse, con implicazioni distinte sul comportamento della frontiera di Pareto.

Funzioni numeriche. Le tre funzioni numeriche calcolano grandezze matematiche note tramite serie o metodi iterativi, e la qualità è misurata come errore relativo rispetto al valore esatto. *PiLeibniz* approssima π mediante la serie di Leibniz troncata a un numero variabile di termini; le varianti si distinguono per il numero di iterazioni e per il linguaggio di implementazione (Python e C). *LnHarmonic* stima $\ln 2$ tramite la serie armonica alternata, con un insieme analogo di varianti a granularità crescente. *MonteCarlo* stima π tramite campionamento casuale; in questo caso l'intervallo energetico tra varianti è particolarmente ampio ($1575\times$), poiché il numero di campioni varia su più ordini di grandezza.

Funzioni di classificazione. Le tre funzioni ML eseguono compiti di classificazione su testo o immagini; per queste funzioni la qualità è espressa come `quality_score` normalizzato in $[0, 1]$, assegnato a ciascuna variante e usato dallo scheduler come misura comparabile di accuratezza. *SentimentAnalysis* classifica il tono di un testo e dispone di quattro modelli: RoBERTa-large, DistilBERT, BERT-tiny e VADER, classificatore a dizionario privo di inferenza neurale. *SpamDetection* individua messaggi indesiderati con un insieme di varianti analogo, con RoBERTa-spam come variante a massima accuratezza e un classificatore a parole chiave come variante a minima

energia. *ImageClassification* classifica immagini su 1000 categorie ImageNet tramite quattro architetture: ViT-Base, EfficientNet-B0, MobileNet-V2 e MobileNet-V2-Tiny.

Nelle funzioni numeriche la relazione tra numero di iterazioni ed errore è continua: la frontiera di Pareto è densa e lo scheduler può modulare il compromesso energia–qualità in modo graduale. Nelle funzioni ML, invece, ogni variante corrisponde a un modello architetaturalmente distinto: la frontiera è composta da pochi punti discreti e il passaggio a una variante più leggera può comportare un salto qualitativo più marcato. Questa differenza strutturale si riflette direttamente nelle scelte dello scheduler e sarà visibile nei risultati sperimentali.

La Tabella 5.1 riassume il numero di varianti disponibili e l’intervallo di energia di invocazione per ciascuna funzione. Le Figure 5.1 e 5.2 mostrano due casi rappresentativi, uno per famiglia, mettendo in relazione il costo energetico con la misura di qualità usata dallo scheduler. A partire da questi profili, le Figure 5.3 e 5.4 mostrano, per gli stessi casi rappresentativi, la frontiera di Pareto e le soglie di selezione lungo l’asse λ . Queste strutture sono proprietà della funzione e delle sue varianti, indipendenti dallo specifico esperimento. Ciò che cambia tra gli esperimenti è il modo in cui la carbon intensity viene trasformata nel valore corrente di λ , e quindi la regione della frontiera effettivamente attraversata durante l’esecuzione.

Tabella 5.1: Funzioni utilizzate nella valutazione sperimentale e profili energetici iniziali delle varianti.

Funzione	Famiglia	Varianti	$E_{\min}$ (J)	$E_{\max}$ (J)
PiLeibniz	Numerica	9	0.000196	0.007823
LnHarmonic	Numerica	7	0.000196	0.007700
MonteCarlo	Numerica	6	0.000147	0.231480
SentimentAnalysis	ML	4	0.002400	0.091579
SpamDetection	ML	4	0.002000	0.085000
ImageClassification	ML	4	0.077000	1.455263




Figura 5.1: Energia di invocazione ed errore relativo delle varianti di PiLeibniz. Le varianti esatte presentano errore nullo, mentre le varianti approssimate riducono progressivamente l'energia diminuendo il numero di termini della serie. L'errore resta contenuto per le varianti intermedie e cresce solo per le approssimazioni più spinte, evidenziando una frontiera energia-accuratezza densa e modulabile.






Figura 5.2: Energia di invocazione e `quality_score` delle varianti di SentimentAnalysis. Il passaggio a modelli più leggeri riduce sensibilmente il costo energetico, ma la qualità diminuisce per salti discreti, riflettendo la natura architetturalmente distinta delle varianti ML.




(a) PiLeibniz




(b) SentimentAnalysis

Figura 5.3: Frontiere di Pareto per le due funzioni rappresentative. Le varianti dominate non vengono considerate dallo scheduler; i punti non dominati definiscono i soli candidati selezionabili tramite scalarizzazione.



(a) PiLeibniz



(b) SentimentAnalysis

Figura 5.4: Regioni di selezione delle varianti al variare di λ . Le soglie verticali derivano dai profili energia–qualità delle varianti Pareto-ottimali; nei diversi esperimenti cambia la traiettoria dei valori di λ , non questa mappa di selezione.

5.1.2 Strategie di confronto

In tutti gli esperimenti vengono confrontate tre strategie. La prima, *always-accurate* (Λ_1), rappresenta il comportamento legacy della piattaforma: viene selezionata sempre la variante a massima accuratezza, cioè con errore minimo nelle funzioni numeriche o `quality_score` massimo nelle funzioni ML, indipendentemente dalle condizioni ambientali. La seconda, *always-energy* (Λ_0), seleziona sempre la variante con minore

energia di invocazione, senza considerare la qualità del risultato; questa politica non costituisce un caso operativo realistico, ma fornisce il limite inferiore del consumo ottenibile con il modello di varianti adottato. La terza è lo scheduler carbon-aware oggetto di questa tesi: quando l'utente autorizza l'uso di varianti approssimate tramite il parametro `AllowApprox=true`, il sistema costruisce la frontiera di Pareto nello spazio energia-qualità e seleziona la variante in base alla scalarizzazione descritta nel Capitolo 4.

Il parametro $\lambda \in [0, 1]$ regola il peso relativo tra qualità del risultato e risparmio energetico: valori elevati di λ privilegiano la qualità, valori ridotti favoriscono l'efficienza energetica. Il valore di λ è derivato dalla carbon intensity (CI) della zona di esecuzione tramite la Carbon Response Function (CRF), garantendo che la selezione della variante sia contestuale all'impatto carbonico dell'energia disponibile.

5.2 Protocollo di valutazione

Per ciascuna zona è disponibile una traccia storica di carbon intensity oraria estratta da ElectricityMaps [6], utilizzata per guidare le decisioni dello scheduler durante la simulazione.

Gli Esperimenti 1 e 2 sono condotti a tempo discreto: per ciascuna zona viene riletta una traccia di invocazioni da file e ogni richiesta viene valutata rispetto alla CI associata al passo temporale corrente, estratta dalle serie storiche orarie di ElectricityMaps. Questo approccio isola il comportamento decisionale dello scheduler da eventuali variazioni del carico e consente di confrontare due diverse calibrazioni del segnale carbon-aware. L'Esperimento 1 mantiene fissa la CRF per tutte le zone: le tracce di CI restano diverse, ma vengono trasformate in λ tramite la stessa mappa decisionale. L'Esperimento 2 utilizza invece una calibrazione locale, più aderente a un

deployment reale, in cui la CI corrente viene interpretata rispetto alla distribuzione storica della zona. L'Esperimento 3 adotta infine un modello a tempo continuo, con richieste che arrivano secondo un profilo di carico variabile, al fine di valutare la stabilità del sistema.

Metriche comuni. In tutti gli esperimenti, oltre alle metriche energetiche e prestazionali, viene stimata anche l'emissione di CO₂ associata a ciascuna invocazione. Il valore è calcolato combinando l'energia consumata dall'invocazione con la carbon intensity corrente della zona:

$$\text{CO}_2(r) = \frac{E(r)}{3,6 \cdot 10^6} \cdot \text{CI}(r) \quad (5.2.1)$$

dove $E(r)$ è l'energia dell'invocazione r espressa in joule e $\text{CI}(r)$ è la carbon intensity corrente in gCO₂eq/kWh. Il fattore $3,6 \cdot 10^6$ converte l'energia da joule a kWh, poiché $1 \text{ kWh} = 3,6 \cdot 10^6 \text{ J}$.

Zone considerate. Le zone geografiche considerate in tutti gli esperimenti sono Francia (FR), Spagna (ES), Italia (IT), Germania (DE) e Polonia (PL), ordinate per CI media crescente. La scelta copre un intervallo ampio e rappresentativo del panorama europeo: la Francia rappresenta un regime a bassa CI (prevalente energia nucleare), la Polonia un regime ad alta CI (prevalente energia da carbone), mentre Spagna, Italia e Germania occupano fasce intermedie con mix energetici diversificati. La Tabella 5.2 riporta le statistiche sintetiche della traccia impiegata, mentre la Figura 5.5 ne mostra la distribuzione per zona.

Tabella 5.2: Statistiche della carbon intensity nelle zone considerate.

Zona	CI media (g/kWh)	CI minima (g/kWh)	CI massima (g/kWh)
Francia	14.8	2.4	64.3
Spagna	91.3	30.8	260.9
Italia	197.4	60.0	332.3
Germania	279.2	72.1	566.7
Polonia	519.3	249.6	728.4




Figura 5.5: Distribuzione della carbon intensity oraria per zona nella traccia usata negli esperimenti. Le zone sono ordinate per CI media crescente da sinistra a destra.

5.3 Esperimento 1: calibrazione europea della carbon intensity

5.3.1 Obiettivo

Il primo esperimento considera una politica carbon-aware in cui la CRF è fissata una sola volta a livello europeo. Le zone mantengono le proprie tracce di carbon intensity,

che possono avere valori e distribuzioni molto diversi; ciò che resta invariato è la funzione che converte ciascun valore di CI nel parametro λ . L'esperimento serve quindi a osservare come cambiano le scelte dello scheduler quando segnali carbonici diversi vengono interpretati tramite la stessa mappa decisionale.

5.3.2 Configurazione

La normalizzazione del segnale di carbon intensity utilizza una CRF calibrata su un riferimento europeo comune, con punto medio fissato al valore medio europeo [27]. In questo modo la medesima funzione $\lambda(\text{CI})$ viene applicata a tutte le zone, pur in presenza di tracce di CI differenti. Le differenze osservate dipendono quindi dai valori di CI propri di ciascuna zona e dalla loro posizione rispetto alla CRF comune. La Figura 5.6 mostra la CRF europea e la collocazione delle zone lungo l'asse decisionale.




Figura 5.6: Carbon Response Function europea utilizzata per trasformare la CI nel parametro λ e collocazione delle zone considerate. La funzione mappa le CI più basse verso $\lambda \approx 1$ (preferenza per la qualità) e le CI più alte verso $\lambda \approx 0$ (preferenza per il risparmio energetico).

Per ogni coppia funzione-zona viene eseguita la stessa traccia nei tre regimi *always-accurate*, *always-energy* e *carbon-aware*.

Metriche raccolte. Per ogni invocazione vengono raccolti l'energia consumata, il tempo di esecuzione, la qualità associata alla variante selezionata e l'identità della variante scelta. A partire da queste misure e dalla CI corrente si calcolano anche le emissioni stimate, le medie aggregate per zona e funzione e la distribuzione percentuale delle varianti selezionate.

5.3.3 Risultati

Un primo indicatore del comportamento dello scheduler è la distribuzione delle varianti selezionate. Le Figure 5.7 e 5.8 riportano, per ciascuna funzione, la composizione percentuale delle varianti scelte dallo scheduler con calibrazione europea nelle cinque zone, ordinate per CI media crescente.

Distribuzione delle varianti. Le distribuzioni mostrano l'effetto atteso di una CRF europea comune. In Francia, dove la CI è molto inferiore al riferimento europeo, il valore di λ resta nella regione che privilegia la qualità: le varianti a massima accuratezza sono dominanti. Questo comportamento è coerente con la semantica di Λ_1 : quando il costo carbonico dell'energia è basso, lo scheduler non ha motivo di spostarsi verso varianti più approssimate.

All'estremo opposto, la Polonia presenta valori di CI sistematicamente più alti e viene quindi mappata in una regione di λ orientata al risparmio energetico. La scelta si sposta quindi verso varianti più leggere: in LnHarmonic e MonteCarlo crescono le quote delle varianti con meno iterazioni, mentre nelle funzioni ML compaiono o diventano dominanti modelli più compatti come VADER, BERT-tiny o il classificatore a parole chiave. Questo non implica però che la Polonia selezioni sempre e solo la variante a minima energia: anche in una rete mediamente carbon-intensive, la CI oraria resta variabile. Nei timestamp meno sfavorevoli il valore di λ risale e può attraversare soglie che riportano lo scheduler su varianti intermedie o più accurate.

Le zone intermedie mostrano il passaggio tra questi due regimi. Spagna e Italia restano vicine al lato qualitativo quando la loro CI è ancora relativamente bassa rispetto alla CRF europea, ma iniziano a distribuire le scelte su varianti più leggere quando la traccia attraversa valori più alti. PiLeibniz rende bene questo comportamento: già




Figura 5.7: Distribuzione delle varianti selezionate per le funzioni numeriche nell'Esperimento 1.




Figura 5.8: Distribuzione delle varianti selezionate per le funzioni ML nell'Esperimento 1.

in Spagna non compare una sola variante dominante, ma più approssimazioni con numero diverso di termini. La Germania è il caso più misto: la CI media è alta, ma la traccia presenta oscillazioni sufficienti ad attraversare più soglie di selezione. In ImageClassification, per esempio, nella stessa zona compaiono tutte le architetture disponibili.

La frontiera di Pareto determina come queste oscillazioni della CI si traducono in scelte concrete. Nelle funzioni numeriche la frontiera contiene più punti vicini e lo scheduler può muoversi gradualmente tra varianti adiacenti. Nelle funzioni ML, al contrario, ogni variante corrisponde a un modello distinto; il passaggio tra RoBERTa-large, DistilBERT, BERT-tiny e VADER, oppure tra ViT-Base, EfficientNet-B0 e MobileNet, produce transizioni più discrete. La CI determina quindi quando lo scheduler si sposta lungo la frontiera, mentre la struttura della frontiera determina quali varianti diventano selezionabili al superamento delle diverse soglie.

Trade-off aggregato. La Figura 5.9 riassume l'effetto aggregato della selezione su due casi rappresentativi, uno numerico e uno ML, mostrando energia media e qualità media al variare della zona. In PiLeibniz lo spostamento verso zone a CI più alta riduce l'energia media mantenendo una perdita qualitativa contenuta, perché la frontiera offre molte varianti intermedie con errore simile. In SpamDetection il risparmio energetico è più marcato, ma il passaggio verso il classificatore keyword produce una riduzione qualitativa evidente. Il confronto mette in evidenza che lo stesso segnale carbon-aware può avere costi qualitativi diversi a seconda delle varianti disponibili.

Il confronto con le baseline quantifica la posizione dello scheduler tra due estremi: Λ_1 , che privilegia sempre la qualità, e Λ_0 , che privilegia sempre il consumo minimo. La Tabella 5.3 riporta, per energia, qualità e tempi di risposta, la variazione percentuale




Figura 5.9: Trade-off energia–qualità per due funzioni rappresentative nell’Esperimento 1. PiLeibniz mostra una riduzione progressiva dell’energia con perdita qualitativa contenuta; SpamDetection evidenzia invece un risparmio più netto accompagnato da un costo qualitativo maggiore quando viene selezionata la variante keyword.

dello scheduler rispetto a entrambe le baseline. Il pedice della metrica indica la baseline usata come riferimento.

Tabella 5.3: Variazione percentuale dello scheduler carbon-aware rispetto alle baseline Λ_1 e Λ_0 nell’Esperimento 1. Valori negativi di ΔE , ΔCO_2 e ΔT indicano un risparmio rispetto alla baseline indicata dal pedice; valori positivi di ΔQ indicano qualità superiore alla baseline indicata dal pedice.

Funzione	Zona	ΔE_{Λ_1}	$\Delta \text{CO}_{2\Lambda_1}$	ΔT_{Λ_1}	ΔQ_{Λ_1}	ΔE_{Λ_0}	$\Delta \text{CO}_{2\Lambda_0}$	ΔT_{Λ_0}	ΔQ_{Λ_0}
PiLeibniz	Francia	0.00%	0.00%	0.00%	0.00%	+436.73%	+436.73%	+318.40%	+0.20%
	Spagna	-5.34%	-60.75%	-3.92%	-0.01%	+408.10%	+110.69%	+298.60%	+0.20%
	Italia	-53.62%	-69.19%	-39.14%	-0.12%	+148.94%	+65.38%	+109.22%	+0.08%
	Germania	-68.34%	-73.57%	-50.87%	-0.14%	+69.92%	+41.84%	+51.38%	+0.06%
	Polonia	-81.37%	-80.79%	-60.53%	-0.20%	0.00%	0.00%	0.00%	0.00%
LnHarmonic	Francia	0.00%	0.00%	0.00%	0.00%	+493.37%	+493.37%	+376.40%	+0.14%
	Spagna	0.00%	0.00%	0.00%	0.00%	+493.37%	+493.37%	+376.40%	+0.14%
	Italia	-89.33%	-91.03%	-70.82%	-0.01%	+319.22%	+252.23%	+241.60%	+0.14%
	Germania	-92.12%	-93.81%	-74.36%	-0.01%	+209.44%	+143.08%	+159.30%	+0.13%
	Polonia	-94.62%	-96.45%	-77.19%	-0.02%	+111.35%	+39.60%	+84.70%	+0.13%
MonteCarlo	Francia	-85.44%	-85.44%	-68.35%	-0.29%	+22831.97%	+22831.97%	+16924.30%	+4.94%
	Spagna	-90.80%	-88.30%	-73.82%	-0.43%	+14384.80%	+18328.68%	+10643.50%	+4.79%
	Italia	-93.82%	-93.49%	-76.10%	-0.50%	+9633.26%	+10144.54%	+7091.80%	+4.71%
	Germania	-93.82%	-96.68%	-76.10%	-0.50%	+9633.26%	+5135.07%	+7091.80%	+4.71%
	Polonia	-95.85%	-99.35%	-78.23%	-1.13%	+6439.04%	+915.80%	+4712.60%	+4.06%
SentimentAnalysis	Francia	0.00%	0.00%	0.00%	0.00%	+3715.79%	+3715.79%	+2812.50%	+43.03%
	Spagna	-57.74%	-49.39%	-46.82%	-5.29%	+1512.50%	+1831.15%	+1162.40%	+35.46%
	Italia	-56.01%	-81.14%	-45.38%	-5.13%	+1578.60%	+619.49%	+1214.30%	+35.69%
	Germania	-56.59%	-88.20%	-45.91%	-5.18%	+1556.57%	+350.36%	+1193.60%	+35.61%
	Polonia	-66.46%	-96.97%	-54.12%	-10.74%	+1179.75%	+15.56%	+892.30%	+27.66%
SpamDetection	Francia	0.00%	0.00%	0.00%	0.00%	+4150.00%	+4150.00%	+3087.50%	+38.19%
	Spagna	-5.29%	-87.58%	-3.97%	-0.27%	+3925.00%	+427.95%	+2916.40%	+37.82%
	Italia	-69.01%	-88.24%	-52.48%	-3.99%	+1217.00%	+400.00%	+905.60%	+32.68%
	Germania	-75.58%	-90.53%	-57.14%	-15.87%	+938.00%	+302.35%	+698.80%	+16.26%
	Polonia	-97.65%	-96.58%	-74.38%	-27.64%	0.00%	0.00%	0.00%	0.00%
ImageClassification	Francia	0.00%	0.00%	0.00%	0.00%	+1789.95%	+1789.95%	+1347.20%	+35.66%
	Spagna	-0.71%	-61.04%	-0.58%	-0.06%	+1776.48%	+636.36%	+1334.80%	+35.58%
	Italia	-47.18%	-73.68%	-38.12%	-4.45%	+898.35%	+397.47%	+678.40%	+29.61%
	Germania	-60.13%	-85.29%	-48.67%	-10.76%	+653.44%	+178.05%	+492.30%	+21.06%
	Polonia	-93.54%	-94.38%	-75.42%	-25.26%	+22.14%	+6.25%	+16.82%	+1.39%

Come atteso, lo scheduler tende a coincidere con Λ_1 nelle zone a bassa CI e si avvicina a Λ_0 nelle zone più carbon-intensive; la distanza tra i due estremi cresce progressivamente spostandosi dalla Francia alla Polonia.

5.3.4 Interpretazione

I risultati mostrano l’effetto della calibrazione europea sulle scelte dello scheduler. Poiché tutte le zone sono valutate rispetto alla stessa funzione $\lambda(\text{CI})$, il valore assoluto

della CI determina la posizione lungo la frontiera: le reti più pulite si avvicinano a Λ_1 , mentre quelle più carbon-intensive si avvicinano a Λ_0 .

La Tabella 5.3 quantifica questo spostamento. Nelle zone a bassa CI lo scheduler tende a coincidere con Λ_1 : in Francia diverse funzioni non mostrano alcuna perdita di qualità rispetto alla baseline più accurata. Al crescere della CI, aumentano invece gli scostamenti negativi in energia e tempo rispetto a Λ_1 , segnalando il passaggio verso varianti più leggere. Il fenomeno è più evidente in Polonia, dove la riduzione energetica rispetto alla baseline accurata diventa marcata, soprattutto per le funzioni con un ampio divario tra variante più accurata e variante più efficiente.

Il confronto con Λ_0 mostra il lato opposto del compromesso. Lo scheduler consuma in genere più della baseline energeticamente minima, ma mantiene una qualità media superiore. Questo comportamento è il risultato atteso della scalarizzazione: la politica carbon-aware non minimizza sempre il consumo, ma sceglie un punto della frontiera energia-qualità coerente con la CI osservata.

5.4 Esperimento 2: calibrazione locale della carbon intensity

5.4.1 Obiettivo

Il secondo esperimento valuta lo stesso scheduler in una configurazione locale. A differenza dell'Esperimento 1, in cui tutte le zone condividono un riferimento europeo, qui la CRF è calibrata sulla distribuzione storica di ciascuna zona. Il valore di λ non dipende quindi soltanto dalla CI assoluta, ma anche dalla sua posizione rispetto al regime abituale della rete considerata. Questa configurazione rappresenta il caso più vicino a un deployment reale, in cui un nodo interpreta il segnale carbon-aware rispetto al contesto elettrico in cui opera.

5.4.2 Configurazione

La struttura sperimentale è la stessa dell'Esperimento 1: per ogni zona viene rieseguita la stessa traccia nei tre regimi. Cambia la normalizzazione del segnale ambientale: per ogni zona z , la CRF utilizza la media storica locale μ_z e i percentili locali P_5 e P_{95} stimati dalle serie ElectricityMaps [6]. La media locale definisce il punto centrale della transizione, mentre P_5 e P_{95} identificano le regioni in cui la CI è rispettivamente molto bassa o molto alta per quella zona, cioè dove λ tende a 1 o a 0. La Figura 5.11 mostra due esempi rappresentativi di questa calibrazione. Rispetto all'Esperimento 1, la stessa CI assoluta può generare valori di λ differenti in zone diverse, poiché rappresenta una condizione ordinaria in una rete e un'anomalia in un'altra: questo aspetto motiva l'adozione di una calibrazione locale rispetto a una soglia globale uniforme.

Nell'Esperimento 2 la traccia di carbon intensity non viene campionata per giornate prestabilite, come nell'Esperimento 1, ma a livello di singoli timestamp orari. A partire dalla distribuzione annuale della CI di ciascuna zona, i valori orari sono ordinati e suddivisi in tre fasce rappresentative: bassa, media e alta intensità carbonica. Questo approccio permette di osservare lo scheduler in condizioni ambientali eterogenee e rilevanti per la decisione carbon-aware, includendo sia momenti in cui la rete è relativamente pulita rispetto alla propria storia, sia momenti più carbon-intensive. La Figura 5.10 mostra, per ciascuna zona, la distribuzione annuale della CI e la suddivisione usata per individuare le fasce rappresentative.

Nei due esempi della Figura 5.11, il punto medio della CRF coincide con la media storica locale: per la Francia la transizione avviene a valori assoluti di CI molto bassi, mentre per la Polonia la stessa logica decisionale è centrata su valori molto più elevati. Questa differenza evidenzia il ruolo della calibrazione locale: λ non misura quanto una






Figura 5.10: Distribuzione annuale della carbon intensity per zona e fasce utilizzate per il campionamento dei timestamp dell'Esperimento 2. La selezione bilanciata tra valori bassi, medi e alti evita che il campione sia concentrato solo attorno alle condizioni più frequenti della rete.



(a) Francia (FR)



(b) Polonia (PL)

Figura 5.11: Esempi di Carbon Response Function locali utilizzate nell'Esperimento 2 per trasformare la carbon intensity oraria nel parametro λ . Francia e Polonia rappresentano due estremi della distribuzione osservata: la stessa funzione decisionale viene traslata e scalata rispetto ai valori tipici della zona. Il parametro k controlla la rapidità della transizione: valori più alti rendono più brusco il passaggio da $\lambda \approx 1$ a $\lambda \approx 0$, mentre valori più bassi producono una variazione più graduale.

CI sia alta in senso assoluto, ma quanto sia alta rispetto al comportamento usuale della zona considerata.

5.4.3 Risultati

Come nell'Esperimento 1, il primo indicatore osservato è la distribuzione delle varianti selezionate. Le Figure 5.12 e 5.13 riportano le quote di selezione ottenute con calibrazione locale della CI.

Un primo segnale del corretto funzionamento dello scheduler è che la calibrazione locale evita il collasso sistematico su uno dei due estremi della frontiera di Pareto. La CRF produce valori di λ molto alti o molto bassi solo quando il timestamp è anomalo rispetto alla storia della zona; la maggior parte dei timestamp ordinari ricade in una regione intermedia, e lo scheduler converge su varianti di compromesso. Le scelte estreme compaiono quindi come risposta a episodi di minimo o picco relativo della CI locale, con frequenza diversa a seconda della volatilità del mix energetico della zona e della frontiera disponibile per la funzione.

A differenza della calibrazione europea, λ non misura il livello assoluto di CI, ma quanto il timestamp si discosta dal profilo storico locale della rete: anche una zona con CI media elevata produce λ simili a quelli di una zona più pulita quando il momento è ordinario per quella rete. La struttura zona per zona delle distribuzioni riflette pertanto la forma del profilo storico di ciascuna griglia.

Francia (15 g/kWh). Francia è la zona con il profilo di CI più stabile, dominato dalla generazione nucleare. La bassa volatilità si traduce in una distribuzione di λ molto concentrata attorno a valori medi, e lo scheduler converge quasi interamente su varianti intermedie della frontiera: $n=50\,000$ al 62% in LnHarmonic, $n=100\,000$ al 45% in MonteCarlo, $n=10\,000$ al 55% in PiLeibniz; nelle funzioni ML, EfficientNet-B0 al

75% in ImageClassification, DistilBERT al 56% in SentimentAnalysis, BERT-tiny al 90% in SpamDetection. Le varianti a massima accuratezza sono praticamente assenti ($\leq 3\%$): la griglia francese opera già quasi sempre ai propri valori minimi di CI, e non vi sono episodi di CI insolitamente bassa rispetto alla norma locale. Le varianti a minima energia compaiono al 10–12% in corrispondenza delle fluttuazioni occasionali al rialzo della CI locale: anche in una griglia stabile, questi episodi producono valori di λ sufficientemente bassi da attivare le varianti più leggere.

Spagna e Italia. Nelle zone intermedie la distribuzione si sposta progressivamente verso varianti più leggere. In Spagna, il contributo di solare ed eolico introduce una volatilità maggiore rispetto alla Francia: le varianti intermedie restano le più frequenti (44% in LnHarmonic, 45% in MonteCarlo), ma emergono quote non trascurabili delle varianti più accurate — ViT-Base al 19% in ImageClassification, RoBERTa-large al 20% in SentimentAnalysis — generate dagli episodi di CI insolitamente bassa che la variabilità rinnovabile produce. In Italia il baricentro si sposta ulteriormente verso varianti più efficienti: $n=10\,000$ sale al 33% in LnHarmonic e $n=5\,000$ domina al 52% in PiLeibniz; anche nelle funzioni ML la struttura bimodale si conferma, con varianti accurate (ViT-Base al 17%, RoBERTa-large al 18%) e varianti a minima energia ancora contenute (3–10%).

Germania La Germania presenta la distribuzione più ampia tra le cinque zone. In ImageClassification ViT-Base raggiunge il 22%, il valore più alto dell'intero esperimento: nonostante la CI media sia elevata, la griglia tedesca alterna tra generazione rinnovabile (eolico) e fossile, producendo oscillazioni ampie che la calibrazione locale registra come episodi di λ sia molto alti (CI insolitamente pulita) sia molto bassi (CI insolitamente elevata). Il risultato è una distribuzione allargata verso entram-

bi gli estremi: $n=10\,000$ al 30% e MobileNet-V2 al 21% nei timestamp più pesanti; ViT-Base e RoBERTa-large nei momenti insolitamente puliti. La variante a minima energia rimane comunque residuale (9% in LnHarmonic, 6–14% nelle funzioni ML, con SpamDetection al 6% e ImageClassification al 14%).

Polonia La Polonia, con la CI media più alta, mostra la distribuzione più spostata verso le varianti intermedie leggere: $n=10\,000$ al 38% in LnHarmonic, $n=5\,000$ al 55% in PiLeibniz, BERT-tiny al 50% in SentimentAnalysis. Tuttavia, anche la Polonia mantiene presenze significative delle varianti più accurate (ViT-Base al 20%, RoBERTa-large al 20%), confermando che nemmeno la zona più carbon-intensive produce λ costantemente bassi: le ore notturne o i weekend abbassano periodicamente la CI sotto la norma locale, generando episodi di λ elevati. Specularmente, la variante a minima energia è più contenuta rispetto alle attese (5–6% nelle funzioni numeriche, ad esempio LnHarmonic al 5% e PiLeibniz al 6%): la CI alta è la norma polacca, non un picco, e la calibrazione locale non la interpreta come evento eccezionale.

Trade-off energia–qualità. Le Figure 5.14 e 5.15 riportano il trade-off aggregato tra energia media per invocazione e qualità media. In tutte le funzioni e in tutte le zone lo scheduler carbon-aware rimane tra le due baseline: riduce energia ed emissioni rispetto a Λ_1 e mantiene una qualità superiore a Λ_0 . Il punto operativo è quindi coerente con quanto osservato nelle distribuzioni delle varianti: la calibrazione locale non spinge stabilmente verso un estremo, ma produce scelte di compromesso lungo la frontiera.

La differenza più rilevante è tra funzioni numeriche e funzioni ML. Nelle prime, la qualità resta quasi ottimale anche con riduzioni energetiche elevate, perché la frontiera contiene varianti adiacenti con errori molto simili. Nelle funzioni ML, invece, il costo

qualitativo è più visibile: ogni variante corrisponde a un modello distinto e il passaggio tra modelli introduce salti discreti di accuratezza. La qualità rimane comunque sostanzialmente stabile tra le zone; a variare è soprattutto l'energia media, determinata dal diverso mix di modelli selezionati.

La Tabella 5.4 quantifica, per la configurazione locale, gli scostamenti di energia, emissioni stimate di CO₂, tempo e qualità rispetto alle due baseline.




Figura 5.12: Distribuzione delle varianti selezionate per le funzioni numeriche nell'Esperimento 2. La calibrazione locale mantiene lo scheduler in una regione intermedia della frontiera: le varianti più efficienti crescono nei timestamp più sfavorevoli, ma le scelte non collasano sistematicamente sulla variante a energia minima.



Figura 5.13: Distribuzione delle varianti selezionate per le funzioni ML nell'Esperimento 2. Le transizioni sono discrete perché ogni variante corrisponde a un modello distinto; la calibrazione locale produce quindi combinazioni diverse di modelli nelle cinque zone, senza imporre una soglia globale unica.




Figura 5.14: Trade-off energia–qualità per le funzioni numeriche nell’Esperimento 2. Il costo qualitativo resta molto contenuto: le curve di qualità sono quasi sovrapposte alla baseline accurata, mentre l’energia media si riduce sensibilmente.




Figura 5.15: Trade-off energia–qualità per le funzioni ML nell’Esperimento 2. Il risparmio energetico è accompagnato da un costo qualitativo più visibile rispetto alle funzioni numeriche, perché il passaggio tra modelli produce salti discreti di accuratezza.

Tabella 5.4: Variazione percentuale dello scheduler carbon-aware dell'Esperimento 2 rispetto alle due baseline.

Funzione	Zona	ΔE_{Λ_1}	$\Delta CO_{2\Lambda_1}$	ΔT_{Λ_1}	ΔQ_{Λ_1}	ΔE_{Λ_0}	$\Delta CO_{2\Lambda_0}$	ΔT_{Λ_0}	ΔQ_{Λ_0}
PiLeibniz	Francia	-66.15%	-71.89%	-71.68%	-0.05%	+81.71%	+50.85%	+10.94%	+0.15%
	Spagna	-66.28%	-69.44%	-23.27%	-0.05%	+80.98%	+64.02%	+13.58%	+0.15%
	Italia	-63.04%	-66.51%	-15.19%	-0.04%	+98.39%	+79.77%	+26.73%	+0.16%
	Germania	-63.91%	-68.41%	-14.75%	-0.05%	+93.73%	+69.56%	+28.40%	+0.15%
	Polonia	-62.50%	-65.26%	-13.46%	-0.04%	+101.28%	+86.47%	+27.79%	+0.16%
LnHarmonic	Francia	-90.35%	-92.73%	-89.15%	-0.01%	+279.03%	+185.79%	+96.77%	+0.14%
	Spagna	-90.09%	-91.68%	-88.56%	-0.01%	+289.28%	+226.98%	+114.24%	+0.13%
	Italia	-90.59%	-91.51%	-89.64%	-0.01%	+269.75%	+233.71%	+95.15%	+0.14%
	Germania	-90.45%	-91.94%	-89.14%	-0.01%	+275.08%	+216.57%	+98.91%	+0.14%
	Polonia	-90.68%	-91.40%	-89.47%	-0.01%	+266.23%	+237.83%	+94.62%	+0.14%
MonteCarlo	Francia	-91.02%	-94.82%	-82.14%	-0.61%	+14034.02%	+8059.95%	+450.04%	+4.60%
	Spagna	-91.51%	-93.58%	-83.07%	-0.61%	+13276.69%	+10012.13%	+430.90%	+4.59%
	Italia	-90.83%	-92.86%	-82.64%	-0.59%	+14332.33%	+11147.43%	+446.52%	+4.62%
	Germania	-91.84%	-93.74%	-83.49%	-0.61%	+12754.73%	+9755.88%	+414.82%	+4.60%
	Polonia	-90.07%	-91.91%	-82.08%	-0.60%	+15534.17%	+12636.41%	+467.06%	+4.61%
SentimentAnalysis	Francia	-69.73%	-82.52%	-78.36%	-10.55%	+1055.05%	+567.10%	+531.03%	+27.94%
	Spagna	-61.46%	-73.61%	-71.24%	-9.89%	+1370.69%	+907.01%	+772.25%	+28.89%
	Italia	-64.90%	-72.44%	-74.01%	-10.21%	+1239.26%	+951.65%	+691.47%	+28.43%
	Germania	-62.07%	-74.47%	-71.85%	-10.34%	+1347.24%	+874.06%	+762.29%	+28.24%
	Polonia	-64.13%	-70.17%	-72.95%	-10.14%	+1268.89%	+1038.07%	+738.24%	+28.53%
SpamDetection	Francia	-89.18%	-91.03%	-63.45%	-6.83%	+360.00%	+281.17%	+101.37%	+28.75%
	Spagna	-85.26%	-88.09%	-79.01%	-6.02%	+526.25%	+406.15%	+148.16%	+29.88%
	Italia	-79.48%	-83.87%	-72.62%	-4.80%	+772.08%	+585.39%	+235.59%	+31.56%
	Germania	-80.21%	-85.71%	-79.14%	-5.37%	+741.25%	+507.49%	+107.26%	+30.77%
	Polonia	-78.10%	-81.69%	-72.59%	-4.34%	+830.83%	+678.36%	+227.54%	+32.19%
ImageClassification	Francia	-74.51%	-81.80%	-47.64%	-9.04%	+381.71%	+243.93%	+51.67%	+23.40%
	Spagna	-62.49%	-72.69%	-59.98%	-8.18%	+608.86%	+416.07%	+56.74%	+24.55%
	Italia	-64.88%	-71.38%	-61.84%	-8.41%	+563.75%	+440.84%	+42.06%	+24.25%
	Germania	-61.86%	-72.97%	-60.05%	-8.76%	+620.84%	+410.91%	+51.99%	+23.77%
	Polonia	-63.05%	-68.51%	-60.05%	-8.49%	+598.43%	+495.12%	+54.14%	+24.14%

5.4.4 Interpretazione

L’Esperimento 2 mostra come le decisioni cambiano quando la CI viene interpretata rispetto al contesto locale anziché rispetto a una scala europea uniforme. La CRF non classifica una zona come “pulita” o “carbon-intensive” in senso assoluto, ma valuta ogni timestamp rispetto alla storia della rete locale. Per questo motivo anche zone con CI media molto diversa possono produrre decisioni intermedie: ciò che guida lo scheduler non è solo il livello medio della zona, ma la posizione del timestamp rispetto al profilo locale.

Il risultato operativo rimane un compromesso tra le due baseline. Rispetto a Λ_1 , lo scheduler riduce energia ed emissioni; rispetto a Λ_0 , evita di sacrificare eccessivamente la qualità. Il beneficio carbonico può superare il solo risparmio energetico perché le varianti più efficienti vengono selezionate proprio nei momenti localmente più sfavorevoli.

Il costo qualitativo dipende dalla forma della frontiera di Pareto: le funzioni numeriche permettono transizioni più graduali, mentre nelle funzioni ML il passaggio tra modelli distinti introduce salti più visibili. L’Esperimento 2 conferma quindi che la calibrazione locale rende lo scheduler meno dipendente dalla CI assoluta della zona; il punto operativo rimane però determinato dalla struttura della frontiera di Pareto: quando le varianti disponibili sono molte e vicine, il compromesso è graduale, mentre pochi modelli distinti producono salti più netti.

5.5 Esperimento 3: flusso di arrivo variabile

5.5.1 Obiettivo e struttura

Il terzo esperimento estende la valutazione dello scheduler carbon-aware introducendo un flusso di richieste concorrenti generato a tempo continuo. Rispetto agli Esperimenti 1 e 2, che isolano la logica decisionale tramite invocazioni sequenziali, questo esperimento verifica se le stesse relazioni tra energia, emissioni, qualità e tempo di risposta rimangono osservabili quando il sistema è attraversato da un carico variabile.

Come nell'Esperimento 2, la CI viene interpretata tramite calibrazione locale: il valore di λ dipende dalla posizione del timestamp rispetto alla distribuzione storica della zona, non da una soglia europea unica. In questo modo l'Esperimento 3 valuta il comportamento operativo della configurazione più vicina a un deployment reale.

L'analisi è articolata lungo due dimensioni, entrambe ricavate dalla stessa campagna sperimentale. La prima riguarda il *confronto quantitativo* tra le tre policy: l'obiettivo è verificare se, anche in presenza di richieste concorrenti, le relazioni tra energia, emissioni e qualità seguono il pattern osservato negli esperimenti precedenti. La seconda riguarda la *stabilità operativa* sotto carico crescente: in un deployment reale le richieste non arrivano necessariamente in modo uniforme e possono concentrarsi in burst o fasi di picco; è quindi utile osservare non solo quale variante lo scheduler seleziona, ma anche se il sistema mantiene throughput accettabile al variare del tasso di arrivo.

Il workload è deterministico: a parità di seed, la sequenza di richieste — funzione invocata, zona geografica e valore di carbon intensity — è identica per le tre policy, al fine di mantenerle comparabili.

5.5.2 Configurazione del workload

Il carico dell'Esperimento 3 è generato con k6 [28], uno strumento di load testing che permette di descrivere un workload tramite script e di controllare esplicitamente il tasso di arrivo delle richieste. A differenza dell'esecuzione sequenziale usata negli Esperimenti 1 e 2, k6 mantiene attivi più virtual user e invia nuove richieste secondo il profilo temporale configurato, indipendentemente dalla durata delle invocazioni precedenti. Questo consente di simulare un flusso continuo con tasso di arrivo variabile per fasi, osservando quando il nodo riesce a seguire il tasso configurato e quando invece inizia ad accumulare richieste in coda.

Il tempo del workload non coincide con l'orario reale di esecuzione del test, ma viene usato per simulare l'arrivo di invocazioni a partire da un punto della traccia di carbon intensity. Ogni fase è quindi ancorata a un orario iniziale della traccia, indicato da `ciHourStart`. Durante il flusso di richieste, lo script seleziona in modo deterministico la zona geografica e associa a ciascuna invocazione la carbon intensity osservata nella traccia per il contesto temporale simulato, inoltrandola poi a Serverledge tramite il campo `ci_override`. In questo modo, il workload non rappresenta solo un profilo sintetico di arrivi, ma anche una sequenza controllata e variabile di condizioni carbon-aware osservate dallo scheduler.

Il workload è composto da cinque fasi consecutive, con tasso di arrivo compreso tra 2 e 25 richieste al secondo e durata complessiva pari a 30 minuti. Le prime tre fasi simulano fasce temporali associate alla mattina, al mezzogiorno e alla sera, con tassi pari rispettivamente a 2, 5 e 10 req/s; le ultime due aumentano progressivamente la pressione sul nodo, raggiungendo 15 e 25 req/s. Il tasso configurato è mantenuto tramite l'esecutore `constant-arrival-rate`, che forza k6 a generare un numero pre-

fissato di nuove iterazioni al secondo per ciascuna fase. La Figura 5.16 mostra il profilo configurato.




Figura 5.16: Profilo del workload configurato in k6. Le prime tre fasi rappresentano il regime moderato usato per il confronto quantitativo; le ultime due aumentano il tasso di arrivo per valutare il comportamento operativo sotto stress.

Il workload è eterogeneo sia rispetto alla funzione invocata sia rispetto alla zona geografica associata al segnale di carbon intensity. Le richieste sono distribuite tra sei funzioni e cinque zone europee, come mostrato nella Figura 5.17. Questa scelta evita che i risultati dipendano da un singolo profilo computazionale o da una sola traiettoria di CI: il nodo deve servire funzioni con costi energetici diversi e applicare la logica carbon-aware a segnali provenienti da reti elettriche con caratteristiche differenti.




Figura 5.17: Composizione del workload: distribuzione per funzione invocata (sinistra), per zona CI (centro) e heatmap funzione × zona (destra). A parità di seed, la sequenza di richieste è identica per tutte e tre le policy.

5.5.3 Confronto quantitativo tra le policy

La Tabella 5.5 riporta, per ciascuna funzione, la variazione percentuale di *adaptive-ci* rispetto alle due baseline, aggregata sulle diverse fasi del workload. Le colonne ΔT indicano la variazione del *tempo di risposta* medio per invocazione, senza considerare eventuali tempi di accodamento.

Tabella 5.5: Variazione percentuale dello scheduler carbon-aware dell’Esperimento 3 rispetto alle due baseline.

Funzione	<i>adaptive-ci</i> vs Λ_1				<i>adaptive-ci</i> vs Λ_0			
	ΔE_{Λ_1}	$\Delta CO_{2\Lambda_1}$	ΔT_{Λ_1}	ΔQ_{Λ_1}	ΔE_{Λ_0}	$\Delta CO_{2\Lambda_0}$	ΔT_{Λ_0}	ΔQ_{Λ_0}
LnHarmonic	−89.8%	−92.8%	−90.8%	−0.13%	+300.2%	+180.0%	+154.3%	+0.1%
MonteCarlo	−91.7%	−91.5%	−83.5%	−0.6%	+13.000%	+11.000%	+548.2%	+4.6%
PiLeibniz	−64.1%	−66.4%	−41.6%	−0.26%	+92.8%	+81.0%	+115.6%	+0.2%
SentimentAnalysis	−70.4%	−76.5%	−77.2%	−11.8%	+1.000%	+752.4%	+3.200%	+26.2%
SpamDetection	−77.7%	−75.4%	−36.7%	−3.9%	+846.4%	+1.300%	+1.700%	+32.8%
ImageClassification	−65.4%	−70.7%	−57.2%	−8.6%	+554.7%	+454.1%	+52.2%	+24.0%

I risultati confermano, anche in presenza di richieste concorrenti, il comportamento osservato negli Esperimenti 1 e 2. Rispetto alla baseline a massima qualità (Λ_1), *adaptive-ci* riduce il consumo energetico e le emissioni di CO_2 per tutte le funzioni, collocandosi in una regione intermedia tra i due estremi della frontiera di Pareto. Il

confronto con Λ_0 mostra il lato opposto del compromesso: *adaptive-ci* consuma più della baseline energetica, ma mantiene una qualità sensibilmente superiore. Il tempo di risposta segue in generale la complessità computazionale della variante selezionata.

La Figura 5.18 mostra la distribuzione percentuale delle varianti selezionate da *adaptive-ci* per ciascuna funzione, aggregata sull'intero workload. Questa figura serve a verificare che lo scheduler non collassi su una scelta fissa sotto carico, ma continui a modulare la selezione in funzione del segnale di carbon intensity ricevuto.




Figura 5.18: Distribuzione percentuale delle varianti selezionate da *adaptive-ci* per funzione. L'ordine va dalla variante meno costosa (sinistra) a quella più costosa (destra). Le varianti agli estremi della frontiera di Pareto compaiono con frequenza residua: lo scheduler occupa la regione intermedia del trade-off, con una distribuzione coerente con i valori medi di CI campionati nelle diverse fasi orarie.

La distribuzione conferma un comportamento già osservato negli Esperimenti 1 e 2: le varianti agli estremi — quella a minima energia e quella a massima qualità — compaiono solo nei momenti in cui la CI è sistematicamente molto bassa o molto alta rispetto alla storia della zona. La grande maggioranza delle invocazioni ricade su varianti intermedie, con pesi che variano tra le funzioni in funzione della struttura della loro frontiera di Pareto. Questo segnala che lo scheduler non è disturbato dalla concorrenza delle richieste: il piano di controllo legge il segnale ambientale in modo stabile e lo traduce in scelte coerenti anche sotto carico.

5.5.4 Stabilità operativa sotto carico crescente

Il sistema è eseguito su un singolo nodo serverless. Quando una richiesta arriva mentre il nodo sta già eseguendo un'invocazione, essa viene accodata fino a quando una risorsa di esecuzione torna disponibile: se il tempo medio di servizio supera quanto il tasso di arrivo consente di sostenere, le richieste si accumulano e il sistema entra progressivamente in saturazione.

La policy più esposta a questo comportamento è Λ_1 , perché seleziona sempre la variante a massima qualità. Per le funzioni ML la differenza tra varianti può essere molto marcata: modelli più accurati richiedono tempi di esecuzione superiori e riducono la capacità effettiva del nodo. Sotto carico crescente, Λ_1 accumula richieste in coda anche quando lo scheduler opera correttamente.

La Figura 5.19 confronta il throughput effettivo — richieste completate per secondo — con il tasso configurato da k6. Λ_0 e *adaptive-ci* seguono il profilo configurato in tutte le fasi; Λ_1 inizia a divergere già dalla fase *Medium* e si stabilizza intorno a 1,25 req/s nelle fasi successive, indipendentemente dal tasso configurato: il nodo è saturo e la sua capacità effettiva è limitata dal tempo di esecuzione delle varianti ad alta qualità.




Figura 5.19: Throughput effettivo rispetto al tasso di arrivo configurato da k6, per fase e policy. Λ_1 raggiunge la saturazione già dalla fase *Medium* e si stabilizza attorno a 1,25 req/s nelle fasi successive; Λ_0 e *adaptive-ci* seguono il profilo configurato fino alla fase *Peak*.

5.5.5 Interpretazione

I risultati dell'Esperimento 3 completano la valutazione dello scheduler carbon-aware verificando se il comportamento osservato negli Esperimenti 1 e 2 si conserva in presenza di richieste concorrenti. In particolare, l'esperimento sposta l'attenzione dal solo effetto della selezione della variante su energia, emissioni e qualità, alla sua interazione con la capacità del sistema di sostenere un carico variabile.

In questo scenario, *adaptive-ci* mantiene il ruolo emerso negli esperimenti precedenti: riduce energia ed emissioni rispetto a Λ_1 e preserva la qualità rispetto a Λ_0 . La presenza di concorrenza, quindi, non altera la semantica della decisione carbon-aware: il tempo di risposta continua a dipendere principalmente dal costo computazionale della variante selezionata. Tuttavia, rende più visibile una conseguenza operativa di tale decisione, ossia il suo impatto sulla stabilità del sistema al crescere del carico.

Questa differenza emerge chiaramente quando aumenta il tasso di arrivo. Λ_0 rimane stabile perché seleziona sempre varianti leggere, mentre Λ_1 raggiunge rapidamente il proprio limite di capacità: il throughput effettivo non segue più il carico configurato e si assesta intorno a 1,25 req/s. *Adaptive-ci* evita questo comportamento, mantenendo un throughput effettivo aderente al profilo configurato, con una lieve divergenza solo alla pressione massima. Il risultato mostra quindi che la scelta dinamica della variante non rappresenta soltanto un compromesso tra qualità ed emissioni, ma contribuisce anche a preservare la stabilità del sistema sotto carico variabile.

5.6 Conclusioni

Il capitolo ha verificato sperimentalmente che lo scheduler proposto traduce la carbon intensity in scelte coerenti lungo la frontiera di Pareto delle varianti disponibili. La calibrazione europea dell'Esperimento 1 mostra il comportamento atteso su una scala comune: nelle zone a bassa CI lo scheduler resta vicino a Λ_1 , mentre nelle zone più carbon-intensive si sposta verso varianti più efficienti. Con calibrazione locale, usata negli Esperimenti 2 e 3, la decisione diventa relativa alla storia della singola zona e non dipende solo dalla CI assoluta.

I risultati principali sono i seguenti:

- rispetto a Λ_1 , lo scheduler riduce sistematicamente energia ed emissioni. Nell'Esperimento 2 il risparmio energetico è compreso tra il 62% e il 92% per funzione e zona, mentre la riduzione stimata di CO₂ arriva fino al 94.82%;
- il costo qualitativo rimane contenuto nelle funzioni numeriche (ΔQ circa 0.01–0.61% nell'Esperimento 2), mentre è più visibile nelle funzioni ML, dove i salti tra modelli portano a perdite comprese tra circa 4.34% e 10.55%;

- rispetto a Λ_0 , lo scheduler mantiene una qualità superiore: nell'Esperimento 2 il guadagno qualitativo è circa 0.13–4.62% per le funzioni numeriche e 23.40–32.19% per le funzioni ML;
- sotto carico variabile, *adaptive-ci* mantiene piena stabilità operativa in tutte le cinque fasi del workload; il risparmio di CO₂ rispetto a Λ_1 si attesta tra il 66% e il 93% a seconda della funzione, confermando che il beneficio ambientale si accumula in modo proporzionale anche sotto carico sostenuto. Rispetto a Λ_0 , tuttavia, il consumo energetico risulta superiore — fino a oltre un ordine di grandezza per alcune funzioni — a fronte di un guadagno qualitativo sensibile, in particolare nelle funzioni ML.

Questi risultati indicano che la riduzione delle emissioni non deriva da una degradazione indiscriminata della qualità, ma da una selezione contestuale delle varianti. Il vincolo principale resta la forma della frontiera di Pareto: quando sono disponibili molte varianti vicine, il compromesso è graduale; quando le varianti sono pochi modelli distinti, il risparmio energetico comporta salti qualitativi più evidenti.

Capitolo 6

Conclusioni e sviluppi futuri

6.1 Sintesi dei contributi

Questa tesi ha affrontato il problema dell'efficienza energetica nel paradigma Function-as-a-Service a partire da una lacuna concreta: le piattaforme serverless non dispongono, in generale, di meccanismi nativi per adattare l'esecuzione delle funzioni al costo carbonico dell'energia disponibile nel momento e nel luogo dell'invocazione. Nel comportamento tradizionale, una funzione viene eseguita nella propria versione di riferimento indipendentemente dal contesto energetico, senza distinguere tra un periodo in cui la rete elettrica è alimentata prevalentemente da fonti rinnovabili e uno in cui è dominata da fonti fossili.

Il contributo complessivo del lavoro consiste nell'estensione della piattaforma Serverledge con un modello di esecuzione carbon-aware, nel quale la scelta della variante non è fissata staticamente ma viene determinata a runtime in funzione della carbon intensity rilevata al momento nella zona di esecuzione, dei profili energetici osservati e del livello di qualità associato alle alternative disponibili. Questo contributo si articola in quattro direzioni principali.

Il primo contributo è il modello di funzione logica con varianti. Una funzione logica non corrisponde a una sola implementazione, ma a un insieme di varianti compatibili

dal punto di vista dell'interfaccia e dello scopo, ma diverse per costo energetico e qualità del risultato.

Il secondo contributo riguarda il monitoraggio energetico a granularità di funzione. Tramite l'integrazione di Kepler con Prometheus, il sistema raccoglie metriche di consumo a livello di container e le associa alle singole invocazioni tramite un worker periodico. I profili energetici ottenuti vengono aggiornati nel tempo con una media mobile esponenziale e memorizzati in etcd, rendendoli disponibili allo scheduler durante la selezione. Questo meccanismo permette di superare una visione puramente statica del consumo, adattando le stime al comportamento osservato sul nodo corrente.

Il terzo contributo è l'integrazione dell'incertezza nella selezione. Nelle fasi iniziali, quando alcune varianti sono state osservate poche volte, il sistema applica una stima ottimistica ispirata al principio Lower Confidence Bound. In letteratura tale principio è l'analogo del più noto Upper Confidence Bound (UCB) nei problemi di massimizzazione: poiché l'obiettivo è minimizzare il consumo energetico, la stima ottimistica si ottiene abbassando il limite di confidenza, favorendo così le varianti meno campionate. Queste ultime saranno esplorate con maggiore probabilità, riducendo il rischio che una stima iniziale imprecisa escluda prematuramente alternative potenzialmente efficienti.

Il quarto contributo è lo scheduler carbon-aware. A partire dalla carbon intensity della zona di esecuzione, il sistema calcola un parametro λ tramite la Carbon Response Function (CRF) calibrata sulla distribuzione storica locale. Tale parametro regola una scalarizzazione lineare della frontiera di Pareto energia-qualità: valori elevati di λ privilegiano varianti più accurate, mentre valori ridotti orientano la selezione verso varianti più efficienti. La calibrazione locale consente di interpretare la carbon intensity non come valore assoluto, ma come posizione rispetto al comportamento tipico della rete elettrica considerata.

6.2 Risultati principali

La valutazione sperimentale ha considerato sei funzioni, tre numeriche e tre di classificazione, su cinque zone europee con profili di carbon intensity differenti. Gli esperimenti hanno confrontato lo scheduler carbon-aware con due baseline statiche: Λ_1 , che seleziona sempre la variante a massima qualità, e Λ_0 , che seleziona sempre la variante a minima energia.

L'Esperimento 1 ha verificato il comportamento della logica decisionale con una calibrazione europea comune. I risultati mostrano che lo scheduler si sposta lungo la frontiera di Pareto in modo coerente con il segnale carbonico: nelle zone a bassa carbon intensity tende a selezionare varianti più accurate, mentre nelle zone più carbon-intensive privilegia varianti più efficienti.

L'Esperimento 2 ha introdotto una calibrazione locale della CRF, interpretando ogni valore di carbon intensity rispetto alla storia della zona. Questa scelta produce un comportamento più equilibrato: anche zone con CI media elevata possono generare decisioni intermedie quando il valore corrente è ordinario rispetto alla propria distribuzione storica. Rispetto alla baseline Λ_1 , lo scheduler ottiene risparmi energetici compresi tra il 62% e il 92% a seconda della funzione e della zona, con una riduzione stimata delle emissioni di CO₂ fino al 94,82%. Il costo qualitativo rimane contenuto per le funzioni numeriche, con perdite comprese tra circa 0,01% e 0,61%, mentre risulta più evidente nelle funzioni ML, dove i passaggi tra modelli distinti producono riduzioni di qualità comprese tra il 4,34% e il 10,55%. Rispetto alla baseline Λ_0 , lo scheduler mantiene invece un guadagno qualitativo compreso tra 0,13% e 4,62% per le funzioni numeriche e tra 23,40% e 32,19% per le funzioni ML.

L'Esperimento 3 ha esteso la valutazione a un flusso di richieste concorrenti con

carico crescente. I risultati confermano che la presenza di concorrenza non altera la semantica della decisione carbon-aware: lo scheduler continua a posizionarsi tra le due baseline, riducendo energia ed emissioni rispetto a Λ_1 e preservando qualità rispetto a Λ_0 . Inoltre, l'esperimento evidenzia un effetto operativo ulteriore. La baseline Λ_1 raggiunge rapidamente il proprio limite di capacità e si stabilizza attorno a 1,25 req/s, mentre *adaptive-ci* mantiene un throughput effettivo aderente al profilo configurato, con una divergenza visibile solo alla pressione massima. La scelta dinamica della variante contribuisce quindi non solo alla riduzione dell'impatto carbonico, ma anche alla stabilità del sistema sotto carico variabile.

Nel complesso, i risultati indicano che la riduzione delle emissioni non è ottenuta degradando indistintamente la qualità del servizio, ma scegliendo di volta in volta la variante più adatta al costo carbonico dell'esecuzione. Il beneficio emerge quando il sistema dispone di alternative sufficientemente differenziate e di un segnale ambientale capace di guidarne la scelta.

6.3 Limiti del lavoro attuale

Nonostante i risultati ottenuti, il sistema proposto presenta alcune limitazioni che definiscono i confini di validità del contributo e indicano le principali direzioni di miglioramento.

Varianti definite manualmente. Il sistema richiede che le varianti di ciascuna funzione siano progettate e registrate a priori dallo sviluppatore. Non esiste, nel prototipo attuale, un meccanismo automatico di generazione o validazione delle varianti. La copertura del trade-off energia-qualità dipende quindi dalla qualità, dalla varietà e dalla granularità delle implementazioni fornite. Questo vincolo limita la

scalabilità dell'approccio in contesti con molte funzioni o con applicazioni aggiornate frequentemente.

Qualità modellata come attributo statico. La qualità associata alle varianti è trattata come un valore noto e registrato nel sistema. Questa scelta è adeguata per una valutazione controllata, ma non cattura possibili variazioni legate al tipo di input, alla distribuzione dei dati o alla sensibilità applicativa della singola richiesta. Una stessa perdita media di qualità può essere trascurabile per alcune invocazioni e non accettabile per altre; il modello attuale non dispone di un meccanismo per distinguere automaticamente questi casi.

Granularità discreta della frontiera di Pareto. La qualità del compromesso ottenibile dipende direttamente dalla densità della frontiera di Pareto. Quando le varianti sono numerose e vicine, come nelle funzioni numeriche parametrizzabili, lo scheduler può muoversi in modo graduale tra qualità ed energia. Quando invece la frontiera è composta da pochi modelli distinti, come in molte funzioni ML, il passaggio da una variante all'altra produce salti qualitativi più marcati. Anche una logica di selezione ottimale non può individuare compromessi intermedi se tali punti non sono presenti tra le varianti disponibili.

Ambiente sperimentale controllato. La valutazione è stata condotta su un insieme limitato di funzioni rappresentative e su un'infrastruttura di laboratorio basata su un singolo nodo Serverledge. Il workload dell'Esperimento 3 introduce concorrenza e carico variabile, ma resta deterministico e sintetico. I risultati dimostrano la fattibilità del meccanismo, ma non esauriscono la varietà di condizioni presenti in ambienti

produttivi, dove intervengono autoscaling, multi-tenancy, interferenze tra applicazioni, burst non prevedibili e vincoli di latenza più stringenti.

Stima energetica e confini del calcolo carbonico. In ambienti privi di accesso diretto all'interfaccia RAPL, Kepler opera tramite modelli di stima del consumo. Il rumore introdotto da tali modelli può influenzare l'aggiornamento dei profili energetici, soprattutto per funzioni a basso consumo assoluto. Questo limite non riguarda la natura statica dei profili, che nel sistema vengono aggiornati online ed esplorati nelle fasi iniziali, ma l'accuratezza della sorgente di misura che alimenta tale aggiornamento.

Inoltre, la stima delle emissioni adottata in questo lavoro riguarda esclusivamente la componente operativa dell'esecuzione, ottenuta moltiplicando l'energia consumata dalla funzione per la carbon intensity della zona geografica considerata. Tale valore rappresenta quindi una stima delle emissioni associate all'esecuzione runtime delle invocazioni, ma non una valutazione completa dell'impronta carbonica del sistema. Non viene infatti modellata la *embodied carbon*, ovvero la quota di emissioni associata al ciclo di vita dell'hardware, dalla produzione alla dismissione [29]. Questa scelta è coerente con il perimetro del lavoro: lo scheduler proposto agisce sulla componente operativa e variabile delle emissioni, ma non pretende di stimare l'intera impronta ambientale dell'infrastruttura sottostante.

Overhead del meccanismo di monitoraggio. Il sistema di profilazione energetica introduce un costo operativo non trascurabile: la raccolta delle metriche tramite Kepler e Prometheus, il worker periodico che le associa alle singole invocazioni e le scritture in etcd per aggiornare i profili avvengono in continuità con il normale flusso di esecuzione. Tale overhead non è stato misurato esplicitamente in questo lavoro. In scenari ad alta

frequenza di invocazione o con funzioni a latenza molto ridotta, il costo relativo del monitoraggio potrebbe risultare significativo e richiedere una valutazione dedicata.

6.4 Sviluppi futuri

I limiti individuati aprono diverse direzioni di ricerca e sviluppo, sia a breve termine sia verso scenari cloud-edge più ampi.

Generazione automatica di varianti. Un'evoluzione naturale consiste nell'integrare strumenti per generare automaticamente varianti alternative, riducendo il costo di definizione manuale del trade-off energia–qualità. Per le funzioni generali, tecniche di traduzione e rifattorizzazione automatica del codice, come quelle esplorate in [24], potrebbero produrre implementazioni funzionalmente equivalenti ma con consumo energetico ridotto, da registrare direttamente come varianti nel sistema.

Per le funzioni ML, tecniche di compressione del modello svolgono un ruolo analogo: a partire da un modello di riferimento, è possibile derivare varianti con gradi progressivi di approssimazione. Il *pruning* rimuove pesi o componenti poco influenti sull'output, riducendo il costo computazionale a fronte di una lieve perdita di accuratezza [30]. La quantizzazione riduce la precisione numerica di pesi e attivazioni, ottenendo un effetto simile con un approccio diverso [30]. La distillazione addestra un modello più compatto a riprodurre il comportamento di un modello più grande, costruendo esplicitamente un'alternativa leggera [31]. Ciascuna di queste tecniche produce un punto distinto sul trade-off energia–accuratezza e può quindi essere registrata come variante aggiuntiva. Una frontiera più densa di varianti ridurrebbe i salti qualitativi osservati nelle funzioni ML e permetterebbe allo scheduler di modulare il compromesso con maggiore continuità.

Calibrazione adattiva e predittiva della carbon intensity. La CRF è attualmente calibrata su dati storici. Una calibrazione periodica basata su finestre mobili permetterebbe di adattarsi a variazioni strutturali del mix energetico locale. Un passo ulteriore consiste nell'integrare previsioni di carbon intensity, così da pianificare le scelte non solo rispetto al valore corrente ma anche rispetto all'evoluzione attesa della rete elettrica.

Scheduling distribuito multi-nodo. In un deployment cloud-edge federato, lo scheduler dovrebbe decidere congiuntamente sia la variante sia il nodo di esecuzione. In questo scenario, l'obiettivo non sarebbe spostare sempre l'esecuzione verso la zona con minore carbon intensity, ma valutare quando tale spostamento consente di preservare una variante di qualità più elevata senza introdurre costi eccessivi in termini di trasferimento, latenza ed energia aggiuntiva.

L'estensione multi-nodo richiederebbe quindi di considerare, per ciascuna coppia nodo-variante, il compromesso tra qualità, consumo energetico della variante, carbon intensity della zona di esecuzione e costo associato al trasferimento. Il problema passerebbe così da una selezione locale della variante a una decisione congiunta di routing e scheduling carbon-aware, in cui il beneficio ambientale ottenuto eseguendo in una zona più favorevole deve essere confrontato con il costo introdotto dallo spostamento dell'invocazione.

Integrazione con politiche di SLA e pricing. La selezione carbon-aware introduce una differenziazione del servizio: a parità di funzione logica, l'utente può ricevere varianti diverse in base al contesto ambientale e alle preferenze espresse. Uno sviluppo futuro consiste nel rendere questa scelta parte del contratto di servizio, permettendo all'utente di specificare vincoli su qualità minima, latenza, impatto carbonico massi-

mo o costo economico. In un modello pay-as-you-go, tali preferenze potrebbero essere riflesse anche in politiche di pricing differenziate.

Elenco delle figure

2.1	Esempio di domini di potenza definiti dal modello RAPL. Il dominio <i>Package</i> rappresenta il consumo energetico complessivo della CPU, mentre domini più specifici, come <i>PP0</i> e <i>DRAM</i> , forniscono stime riferite rispettivamente ai core di calcolo e alla memoria principale.	24
2.2	Architettura concettuale di PowerAPI. I contatori di prestazione hardware e le misure energetiche aggregate (RAPL) vengono combinati dal modello SmartWatts per stimare il consumo energetico dei singoli processi.	27
2.3	Architettura di Kepler.	29
2.4	Architettura di E ² FIS. I nodi edge sono caratterizzati da differenti capacità computazionali e profili di consumo. Il modulo di <i>Scheduling computation</i> determina periodicamente l’allocazione delle funzioni e il sottoinsieme di nodi da mantenere attivi.	33
2.5	Architettura di alto livello di GreenFaaS: monitoraggio degli endpoint, stima del costo energetico dei trasferimenti e scheduling energy-aware per l’allocazione dei task in ambienti federati eterogenei.	35

2.6	Pipeline di traduzione automatica proposta in <i>Code Once, Run Green</i> . La trasformazione avviene in fase di build tramite un processo iterativo di conversione e validazione del codice, con passaggi di recupero in caso di errori di compilazione o di test.	40
2.7	Schema concettuale di JouleGuard. Il <i>System Energy Optimizer</i> (SEO) identifica la configurazione di sistema più efficiente; l' <i>Application Accuracy Optimizer</i> (AAO) regola il livello di approssimazione dell'applicazione per rispettare il budget energetico, massimizzando l'accuratezza. .	42
2.8	Effetto della Virtual Capacity Curve (VCC) sul profilo di carico di un cluster. La barra superiore indica i livelli di carbon intensity nel corso della giornata. La curva VCC (in rosso) riduce la capacità disponibile per i workload flessibili nelle ore ad alta carbon intensity, spostando il carico (aree arancione e blu) verso le ore più pulite della giornata. Il carico inflexible (in viola) non viene alterato.	47
2.9	Architettura di GreenCourier. Il management cluster ospita lo scheduler carbon-aware e il Metrics Server, che interroga sorgenti di carbon intensity (WattTime, ElectricityMaps). I provider cluster, distribuiti in diverse regioni europee, sono collegati tramite Ligo come nodi virtuali. Lo scheduler assegna ciascuna invocazione alla regione con la carbon intensity più favorevole.	50
3.1	Architettura di Kepler per la raccolta dei consumi energetici in ambienti bare-metal e virtuali. In ambienti bare-metal, Kepler accede direttamente ai contatori hardware tramite RAPL, ottenendo misurazioni real-time senza necessità di modelli predittivi.	57

3.2	Architettura dell'infrastruttura di monitoraggio energetico e scheduling carbon-aware. I componenti di monitoraggio esterni (Kepler, Prometheus, Grafana) sono separati dagli store interni (etcd, InfluxDB), con Serverledge al centro che interagisce con entrambi i livelli. Lo scheduler carbon-aware integra la logica di selezione della variante — basata su frontiera di Pareto, scalarizzazione tramite λ , esplorazione LCB e consenso utente — e riceve il segnale di carbon intensity tramite query periodica a una sorgente esterna.	58
3.3	Struttura delle chiavi etcd per la funzione logica PiLeibniz. Le chiavi sotto <code>/function/</code> contengono i profili completi; l'indice sotto <code>/index/logical/</code> consente la lookup efficiente delle sole varianti richieste.	67
3.4	Schema del feedback loop energetico. Il worker periodico legge le metriche cumulative da Kepler tramite Prometheus e il numero di invocazioni dal contatore locale, calcola i delta, applica un filtro EMA e aggiorna il profilo persistito in etcd, archiviando contestualmente i campioni in InfluxDB.	68
5.1	Energia di invocazione ed errore relativo delle varianti di PiLeibniz. Le varianti esatte presentano errore nullo, mentre le varianti approssimate riducono progressivamente l'energia diminuendo il numero di termini della serie. L'errore resta contenuto per le varianti intermedie e cresce solo per le approssimazioni più spinte, evidenziando una frontiera energia-accuratezza densa e modulabile.	88

5.2	Energia di invocazione e <code>quality_score</code> delle varianti di SentimentAnalysis. Il passaggio a modelli più leggeri riduce sensibilmente il costo energetico, ma la qualità diminuisce per salti discreti, riflettendo la natura architetaturalmente distinta delle varianti ML.	88
5.3	Frontiere di Pareto per le due funzioni rappresentative. Le varianti dominate non vengono considerate dallo scheduler; i punti non dominati definiscono i soli candidati selezionabili tramite scalarizzazione.	89
5.4	Regioni di selezione delle varianti al variare di λ . Le soglie verticali derivano dai profili energia-qualità delle varianti Pareto-ottimali; nei diversi esperimenti cambia la traiettoria dei valori di λ , non questa mappa di selezione.	90
5.5	Distribuzione della carbon intensity oraria per zona nella traccia usata negli esperimenti. Le zone sono ordinate per CI media crescente da sinistra a destra.	93
5.6	Carbon Response Function europea utilizzata per trasformare la CI nel parametro λ e collocazione delle zone considerate. La funzione mappa le CI più basse verso $\lambda \approx 1$ (preferenza per la qualità) e le CI più alte verso $\lambda \approx 0$ (preferenza per il risparmio energetico).	95
5.7	Distribuzione delle varianti selezionate per le funzioni numeriche nell'Esperimento 1.	97
5.8	Distribuzione delle varianti selezionate per le funzioni ML nell'Esperimento 1.	98

5.9	Trade-off energia-qualità per due funzioni rappresentative nell'Esperimento 1. PiLeibniz mostra una riduzione progressiva dell'energia con perdita qualitativa contenuta; SpamDetection evidenzia invece un risparmio più netto accompagnato da un costo qualitativo maggiore quando viene selezionata la variante keyword.	100
5.10	Distribuzione annuale della carbon intensity per zona e fasce utilizzate per il campionamento dei timestamp dell'Esperimento 2. La selezione bilanciata tra valori bassi, medi e alti evita che il campione sia concentrato solo attorno alle condizioni più frequenti della rete.	104
5.11	Esempi di Carbon Response Function locali utilizzate nell'Esperimento 2 per trasformare la carbon intensity oraria nel parametro λ . Francia e Polonia rappresentano due estremi della distribuzione osservata: la stessa funzione decisionale viene traslata e scalata rispetto ai valori tipici della zona. Il parametro k controlla la rapidità della transizione: valori più alti rendono più brusco il passaggio da $\lambda \approx 1$ a $\lambda \approx 0$, mentre valori più bassi producono una variazione più graduale.	105
5.12	Distribuzione delle varianti selezionate per le funzioni numeriche nell'Esperimento 2. La calibrazione locale mantiene lo scheduler in una regione intermedia della frontiera: le varianti più efficienti crescono nei timestamp più sfavorevoli, ma le scelte non collassano sistematicamente sulla variante a energia minima.	110

5.13	Distribuzione delle varianti selezionate per le funzioni ML nell'Esperimento 2. Le transizioni sono discrete perché ogni variante corrisponde a un modello distinto; la calibrazione locale produce quindi combinazioni diverse di modelli nelle cinque zone, senza imporre una soglia globale unica.	111
5.14	Trade-off energia-qualità per le funzioni numeriche nell'Esperimento 2. Il costo qualitativo resta molto contenuto: le curve di qualità sono quasi sovrapposte alla baseline accurata, mentre l'energia media si riduce sensibilmente.	112
5.15	Trade-off energia-qualità per le funzioni ML nell'Esperimento 2. Il risparmio energetico è accompagnato da un costo qualitativo più visibile rispetto alle funzioni numeriche, perché il passaggio tra modelli produce salti discreti di accuratezza.	113
5.16	Profilo del workload configurato in k6. Le prime tre fasi rappresentano il regime moderato usato per il confronto quantitativo; le ultime due aumentano il tasso di arrivo per valutare il comportamento operativo sotto stress.	118
5.17	Composizione del workload: distribuzione per funzione invocata (sinistra), per zona CI (centro) e heatmap funzione $\times$ zona (destra). A parità di seed, la sequenza di richieste è identica per tutte e tre le policy. . . .	119

5.18	Distribuzione percentuale delle varianti selezionate da <i>adaptive-ci</i> per funzione. L'ordine va dalla variante meno costosa (sinistra) a quella più costosa (destra). Le varianti agli estremi della frontiera di Pareto compaiono con frequenza residua: lo scheduler occupa la regione intermedia del trade-off, con una distribuzione coerente con i valori medi di CI campionati nelle diverse fasi orarie.	120
5.19	Throughput effettivo rispetto al tasso di arrivo configurato da k6, per fase e policy. Λ_1 raggiunge la saturazione già dalla fase <i>Medium</i> e si stabilizza attorno a 1,25 req/s nelle fasi successive; Λ_0 e <i>adaptive-ci</i> seguono il profilo configurato fino alla fase <i>Peak</i>	122

Elenco dei codici

- 3.1 File di definizione delle varianti per la funzione `PiLeibniz`. Le prime due varianti sono esatte (`is_approximate: false`) e differiscono per runtime e consumo. (omesse per brevità le quattro varianti intermedie). 61
- 3.2 File di definizione delle varianti per la funzione `ImageClassification`. Il campo `quality_score` riporta la Top-1 accuracy su ImageNet pubblicata dagli autori di ciascun modello, espressa in $[0, 1]$ 64

List of Algorithms

1	Calcolo del peso λ dalla carbon intensity corrente	78
2	SELECTPARETOVARIANT: selezione carbon-aware	83

Bibliografia

- [1] W. Shi, J. Cao, Q. Zhang, Y. Li, and L. Xu, “Edge computing: Vision and challenges,” *IEEE Internet of Things Journal*, vol. 3, no. 5, pp. 637–646, 2016.
- [2] A. Radovanović, R. Koningstein, I. Schneider, B. Chen, A. Duarte, B. Roy, D. Xiao, M. Haridasan, P. Hung, N. Care, S. Talukdar, E. Mullen, K. Smith, M. Cottman, and W. Cirne, “Carbon-aware computing for datacenters,” *IEEE Transactions on Power Systems*, 2022.
- [3] M. Chadha, T. Subramanian, E. Arima, M. Gerndt, M. Schulz, and O. Abboud, “GreenCourier: Carbon-aware scheduling for serverless functions,” in *9th International Workshop on Serverless Computing (WoSC '23)*. ACM, 2023, pp. 18–23.
- [4] G. Russo, T. Mannucci, V. Cardellini, and F. Lo Presti, “Serverledge: Decentralized function-as-a-service for the edge-cloud continuum,” in *2023 IEEE International Conference on Pervasive Computing and Communications (PerCom)*, 2023, pp. 131–140.
- [5] M. Amaral *et al.*, “Kepler: A framework to calculate the energy consumption of containerized applications,” in *Proceedings of IEEE CLOUD 2023*, 2023. [Online]. Available: <https://research.ibm.com/publications/kepler-a-framework-to-calculate-the-energy-consumption-of-containerized-applications>

- [6] Electricity Maps, “Electricity maps — historical carbon intensity data,” <https://www.electricitymaps.com>, 2024, accessed: 2025.
- [7] H. Hoffmann, “Jouleguard: energy guarantees for approximate applications,” in *Proceedings of the 25th Symposium on Operating Systems Principles*, ser. SO-SP '15. New York, NY, USA: Association for Computing Machinery, 2015, p. 198–214.
- [8] E. van Eyk, L. Toader, S. Talluri, L. Versluis, A. Uta, and A. Iosup, “Serverless is more: From PaaS to present cloud computing,” *IEEE Internet Computing*, vol. 22, no. 5, pp. 8–17, 2018.
- [9] Q. Luo, S. Hu, C. Li, G. Li, and W. Shi, “Resource scheduling in edge computing: A survey,” *IEEE Communications Surveys & Tutorials*, vol. 23, no. 4, pp. 2131–2165, 2021.
- [10] International Energy Agency, “Electricity 2025 – emissions,” 2025, consultato: aprile 2026. [Online]. Available: <https://www.iea.org/reports/electricity-2025/emissions>
- [11] M. Lipp, A. Kogler, D. Oswald, M. Schwarz, C. Easdon, C. Canella, and D. Gruss, “PLATYPUS: Software-based Power Side-Channel Attacks on x86,” in *2021 IEEE Symposium on Security and Privacy (SP)*. IEEE, 2021.
- [12] G. Fieni, R. Rouvoy, and L. Seinturier, “SmartWatts: Self-Calibrating Software-Defined Power Meter for Containers,” in *CCGRID 2020 - 20th IEEE/ACM International Symposium on Cluster, Cloud and Internet Computing*, Melbourne, Australia, May 2020. [Online]. Available: <https://inria.hal.science/hal-02470128>

- [13] D. Freina, M. Jansen, and A. Trivedi, “A survey of energy measurement methodologies for computer systems,” 2024.
- [14] Intel Corporation, “Intel running average power limit (rapl),” <https://www.intel.com/content/www/us/en/developer/articles/technical/software-security-guidance/advisory-guidance/running-average-power-limit-energy-reporting.html>, 2023.
- [15] V. Ostapenco, L. Lefèvre, A.-C. Orgerie, and B. Fichel, “Exploring rapl as a power capping leverage for power-constrained infrastructures,” in *Algorithms and Architectures for Parallel Processing*, T. Zhu, J. Li, and A. Castiglione, Eds. Singapore: Springer Nature Singapore, 2025, pp. 323–333.
- [16] M. Hähnel, B. Döbel, M. Völpl, and H. Härtig, “Measuring energy consumption for short code paths using rapl,” in *ACM SIGMETRICS Performance Evaluation Review*. New York, NY, USA: Association for Computing Machinery, 2012, p. 84–90. [Online]. Available: <https://doi.org/10.1145/2425248.2425252>
- [17] PowerAPI Project. (2023) Hwpc sensor – powerapi documentation. [Online]. Available: https://powerapi.org/reference/overview/#usage_1
- [18] ——. (2023) Smartwatts energy model. [Online]. Available: <https://powerapi.org/reference/formulas/smartwatts/>
- [19] V. Shponarskyi, “Monitoring environmental impact of kubernetes clusters,” <https://medium.com/@vasyl.shponarskyi/monitoring-environmental-impact-of-kubernetes-clusters-8c81f72ac55f>, 2022.

- [20] Red Hat, “Introducing kepler: Efficient power monitoring for kubernetes,” <https://next.redhat.com/2023/08/22/introducing-kepler-efficient-power-monitoring-for-kubernetes/>, 2023.
- [21] F. Righetti, B. Cornacchia, G. R. Russo, N. Tonellotto, V. Cardellini, and C. Vallati, “Energy-efficient function invocation scheduling for edge faas platforms,” in *2025 IEEE International Conference on Smart Computing (SMARTCOMP)*, 2025, pp. 18–25.
- [22] A. Kamatar, V. Hayot-Sasson, Y. Babuji, A. Bauer, G. Rattihalli, N. Hogade, D. Milojevic, K. Chard, and I. Foster, “Greenfaas: Maximizing energy efficiency of hpc workloads with faas,” 2024. [Online]. Available: <https://arxiv.org/abs/2406.17710>
- [23] S. Mittal, “A survey of techniques for approximate computing,” *ACM Computing Surveys*, vol. 48, no. 4, pp. 1–33, 2016.
- [24] S. Werner, M. Kähler, and A. Hakamian, “Code once, run green: Automated green code translation in serverless computing,” in *2025 IEEE International Conference on Cloud Engineering (IC2E)*, 2025, pp. 105–113.
- [25] M. Amaral, S. Choochotkaew, E. K. Lee, H. Chen, and T. Eilam, “Exploring Kepler’s potentials: unveiling cloud application power consumption,” 2023, cNCF Blog. [Online]. Available: <https://www.cncf.io/blog/2023/10/11/exploring-keplers-potentials-unveiling-cloud-application-power-consumption/>
- [26] P. Auer, N. Cesa-Bianchi, and P. Fischer, “Finite-time analysis of the multiarmed bandit problem,” *Machine Learning*, vol. 47, no. 2–3, pp. 235–256, 2002.

- [27] European Environment Agency, “Greenhouse gas emission intensity of electricity generation in europe,” <https://www.eea.europa.eu/en/analysis/indicators/greenhouse-gas-emission-intensity-of-1>, pubblicato: 6 novembre 2025; consultato: maggio 2026.
- [28] Grafana Labs, “Grafana k6 Documentation,” <https://grafana.com/docs/k6/latest/>, consultato: maggio 2026.
- [29] U. Gupta, Y. G. Kim, S. Lee, J. Tse, H.-H. S. Lee, G.-Y. Wei, D. Brooks, and C.-J. Wu, “Chasing carbon: The elusive environmental footprint of computing,” in *Proceedings of the 27th IEEE International Symposium on High-Performance Computer Architecture (HPCA)*. IEEE, 2021, pp. 854–867.
- [30] S. Han, H. Mao, and W. J. Dally, “Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding,” in *International Conference on Learning Representations (ICLR)*, 2016.
- [31] G. Hinton, O. Vinyals, and J. Dean, “Distilling the knowledge in a neural network,” *arXiv preprint arXiv:1503.02531*, 2015.